

대규모 언어 모델에 대한 포괄적인 개요

Humza Naveeda, Asad Ullah Khanb, Shi Qiuc, Muhammad Saqibde, Saeed Anwarf, Muhammad Usmanf, Naveed Akhtarh, Nick Barnesi, Ajmal Mianj

시드니 대학교, 시드니, 호주
공학 및 기술 대학교 (UET), 라호르, 파키스탄
홍콩 중국대학교 (CUHK), 홍콩특별행정구, 중국
시드니 공과대학교 (UTS), 시드니, 호주
커먼웰스 과학 산업 연구 기구 (CSIRO), 시드니, 호주
킹 파흐드 석유 및 광물 대학교 (KFUPM), 다호란, 사우디아라비아
SDAIA-KFUPM 인공지능 공동 연구 센터 (JRCAT), 다호란, 사우디아라비아
멜버른 대학교 (UoM), 멜버른, 호주
호주 국립대학교 (ANU), 캔버라, 호주
서호주 대학교 (UWA), 퍼스, 호주

초록

최근 대형 언어 모델(Large Language Models, LLMs)은 자연어 처리 작업 및 그 이상에서 놀라운 역량을 보여주었습니다. LLM의 이러한 성공은 이 방향으로 많은 연구 기여를 이끌어냈습니다. 이러한 연구는 아키텍처 혁신, 향상된 훈련 전략, 컨텍스트 길이 개선, 미세 조정, 다중 모달 LLM, 로봇 공학, 데이터셋, 벤치마킹, 효율성 등 다양한 주제를 포함합니다. 기술의 빠른 발전과 LLM 연구에서의 정기적인 breakthrough 덕분에 이 방향에서의 진전을 전체적으로 파악하는 것이 상당히 도전적으로 변했습니다. LLM에 대한 빠르게 등장하는 방대한 문헌을 고려할 때, 연구 커뮤니티가 이 분야의 최신 발전에 대한 간결하면서도 포괄적인 개요를 유익하게 활용할 수 있어야 합니다. 이 글은 LLM 관련 개념의 광범위한 문헌 개요를 제공합니다. 우리의 독립적이고 포괄적인 LLM 개요는 관련 배경 개념을 논의하며 LLM 연구의 최전선에 있는 고급 주제를 다룹니다. 이 리뷰 기사는 체계적인 조사뿐만 아니라 연구자와 실무자들이 기존 연구의 광범위하고 유익한 요약에서 통찰을 얻어 LLM 연구를 발전시킬 수 있도록 하는 빠르고 포괄적인 참고 자료를 제공하는 것을 목표로 합니다.

키워드:

대형 언어 모델, LLMs, chatGPT, 증강 LLMs, 멀티모달 LLMs, LLM 훈련, LLM 벤치마킹

1. 소개

언어는 인간의 의사소통과 자기 표현, 그리고 기계와의 상호작용을 촉진하는 데 기본적인 역할을 합니다. 일반화된 모델에 대한 필요성은 번역, 요약, 정보 검색, 대화 상호작용 등 복잡한 언어 작업을 처리해야 하는 기계에 대한 요구가 증가함에 따라 생겨났습니다. 최근에는 주로 transformers [1], 계산 능력의 증가, 그리고 대규모 훈련 데이터의 가용성 덕분에 언어 모델에서 상당한 돌파구가 발견되었습니다. 이러한 발전은 다양한 작업에서 인간 수준의 성능을 근사할 수 있는 LLM의 생성을 가능하게 함으로써 혁신적인 변화를 가져왔습니다 [2, 3]. 대규모

Papers Released over Years




그림 1: "Large Language Model", "Large Language Model + Fine-Tuning", 및 "Large Language Model + Alignment" 키워드를 포함한 논문이 발표된 연도별 추세.

동일한 기여

이메일 주소: humza_naveed@yahoo.com (Humza Naveed), aukhanee@gmail.com (Asad Ullah Khan), shiqiu@cse.cuhk.edu.hk (Shi Qiu), muhammad.saqib@data61.csiro.au (Muhammad Saqib), saeed.anwar@kfupm.edu.sa (Saeed Anwar), muhammad.usman@kfupm.edu.sa (Muhammad Usman), naveed.akhtar1@unimelb.edu.au (Naveed Akhtar), nick.barnes@anu.edu.au (Nick Barnes), ajmal.mian@uwa.edu.au (Ajmal Mian)

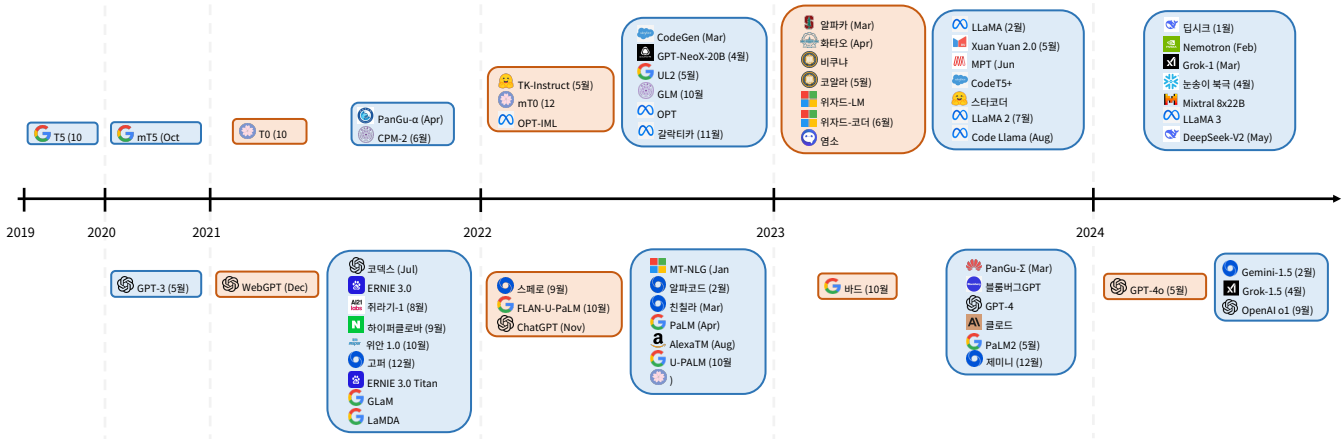


그림 2: LLM 출시의 연대순 표시: 파란 카드들은 '사전 훈련된' 모델을 나타내고, 오렌지 카드들은 '지시 조정된' 모델에 해당합니다. 상반부의 모델들은 오픈 소스 이용 가능성을 의미하고, 하반부의 모델들은 폐쇄형 소스입니다. 이 차트는 지시 조정된 모델과 오픈 소스 모델로의 증가하는 추세를 보여주며, 자연어 처리 연구의 진화하는 경관과 추세를 강조합니다.

언어 모델(LLMs)은 일관된 커뮤니케이션을 통해 텍스트를 처리하고 생성할 수 있는 최첨단 인공지능 시스템으로 부상하였으며 [4], 여러 작업에 일반화할 수 있습니다 [5, 6].

자연어 처리(NLP)의 역사적 발전은 통계 모델링에서 신경 언어 모델링으로, 그리고 다시 사전 학습된 언어 모델(PLMs)에서 LLM으로 진화해왔습니다. 기존의 언어 모델링(LM)은 특정 작업에 맞춘 모델을 감독 환경에서 훈련시키는 반면, PLMs는 대규모 텍스트 코퍼스에서 자기 지도 학습 방식으로 훈련되어 다양한 NLP 작업 간에 공유할 수 있는 일반적인 표현을 학습하는 것을 목표로 합니다. 다운스트림 작업을 위한 세부 조정(fine-tuning) 후, PLMs는 전통적인 언어 모델링(LM)의 성능 향상을 초월합니다. 더 큰 PLMs는 더 많은 성능 향상을 가져오며, 이는 모델 매개변수(수십에서 수백억)와 훈련 데이터 세트(수십 기가바이트 및 테라바이트)를 크게 증가시켜 PLMs가 LLM으로 전환되는 원인이 되었습니다. 이러한 발전에 따라 문헌에서 많은 LLM이 제안되었습니다. 출시된 LLM의 수가 증가하는 추세와 지난 몇 년 동안 제안된 몇 가지 중요한 LLM의 이름은 각각 그림 1과 그림 2에 나타나 있습니다.

LLM에 대한 초기 연구는 T5 [10]와 mT5 [11]와 같은 모델이었으며, 이들은 GPT-3 [6]가 LLM이 미세 조정 없이도 다운스트림 작업에 제로샷 성능이 가능하다는 것을 보여주기 전까지 전이 학습을 사용했습니다. LLM은 작업 설명 및 예시로 프롬프트를 주었을 때 작업 쿼리에 정확하게 응답합니다. 하지만, 사전 훈련된 LLM은 사용자 의도를 따르지 못하고, 제로샷 설정에서 퍼포먼스가 몇 번의 샷보다 좋지 않습니다. 작업 지침 데이터 [16, 17, 18, 19]로 미세 조정하고 인간의 선호와 일치시킴으로써 [20, 21] 보지 못한 작업에 대한 일반화가 향상되어 제로샷 성능이 크게 개선되고 잘못된 행동이 줄어듭니다.

더 나은 일반화와 도메인 적응 외에도, LLM은 추론, 계획, 의사 결정, 맥락 내 학습, 제로샷 설정에서의 응답 등의 emergent abilities를 갖추고 있는 것으로 보입니다. 이러한 능력은 그들이 거대한 규모로 인해 습득한 것으로 알려져 있으며, 사전 훈련된 LLM이 이러한 속성을 갖추도록 특별히 훈련되지 않았음에도 불구하고 그렇습니다. 이러한 능력 덕분에 LLM은 다중 모드, 로봇 공학 등 다양한 환경에서 널리 채택되고 있습니다.

도구 조작, 질문 응답, 자율 에이전트 등. 이러한 분야에서도 작업 특화 훈련[25, 26, 27, 28, 29, 30, 31]이나 더 나은 프롬프트[32]를 통해 다양한 개선이 제안되었다.

LLM의 다양한 작업을 인간 수준의 성능으로 해결하는 능력은 느린 훈련과 추론, 광범위한 하드웨어 요구사항, 그리고 더 높은 운영 비용이라는 대가를 치르게 합니다. 이러한 요구사항은 LLM의 채택을 제한했으며, 더 나은 아키텍처 [15, 33, 34, 35]와 훈련 전략 [36, 37, 21, 38, 39, 40, 41]을 고안할 기회를 열었습니다. 파라미터 효율적인 튜닝 [38, 41, 40], 가지치기 [42, 43], 양자화 [44, 45], 지식 증류, 그리고 컨텍스트 길이 보간 [46, 47, 48, 49] 등은 효율적인 LLM 활용을 위해 널리 연구되는 방법들 중 일부입니다.

LLM의 다양한 작업에서의 성공 덕분에 연구 문헌은 최근 LLM 관련 기여가 대거 유입되는 경험을 하였습니다. 연구자들은 LLM 문헌을 설문조사 [50, 51, 52, 53] 및 주제별 설문조사 [54, 55, 56, 57, 58]에 정리하였습니다. 이러한 설문조사와는 달리, 우리 기여는 LLM 연구의 일반적인 방향에 대한 포괄적이면서도 간결한 개요를 제공하는 데 초점을 맞추고 있습니다. 이 기사에서는 사전 훈련된 LLM의 구조 및 훈련 세부 사항을 요약하고, 파인튜닝, 다중 모달 LLM, 증강 LLM, 데이터셋, 평가, 응용, 도전 과제 등과 같은 개념의 세부 사항을 더 깊이 다루어 독립적이고 포괄적인 개요를 제공합니다. 우리의 주요 기여는 다음과 같이 요약됩니다.

- 우리는 LLM 연구의 발전에 대한 설문을 제시하며, 방향에 대한 간결하고 포괄적인 개요를 제공합니다.
- 우리는 아키텍처와 훈련 세부 사항에 대한 세밀한 내용을 포함한 사전 훈련된 모델의 광범위한 요약을 제시합니다.
- 우리는 인기 있는 기여의 주요 발견을 요약하고 실무자들이 이 기술을 효과적으로 활용할 수 있도록 LLM의 주요 설계 및 개발 측면에 대해 자세히 논의합니다.

이 독립적인 기사에서는 LLMs의 일반적인 방향을 포괄적으로 제시하기 위해 배경, 사전 훈련, 미세 조정 등 다양한 개념을 다룹니다.

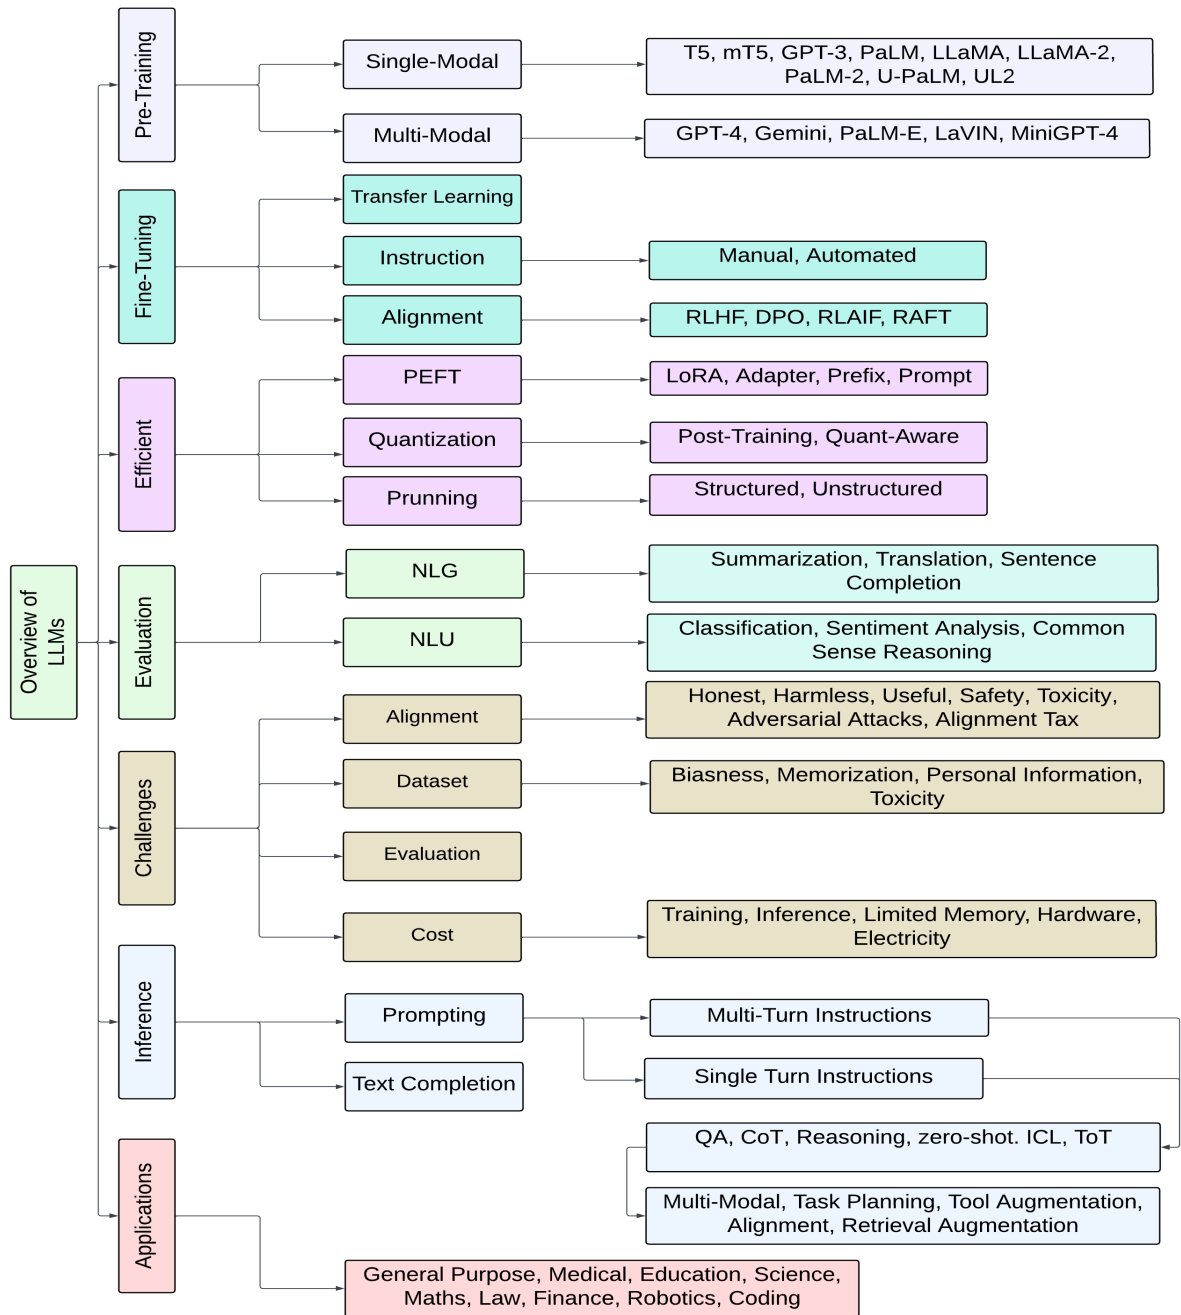


그림 3: LLM의 더 넓은 개요로, LLM을 일곱 가지 부분으로 나누고 있다: 1. Pre-Training 2. Fine-Tuning 3. Efficient 4. Inference 5. Evaluation 6. Applications 7. 도전 과제

다중 모달 LLMs, 증강 LLMs, LLMs 기반 에이전트, 데이터셋, 평가 등.

우리는 이 연구 방향의 표준화된 전망을 보장하기 위해 기존 용어를 대략적으로 따릅니다. 예를 들어, [50]에 따라 우리의 조사에서는 10B 매개변수 이상의 사전 훈련된 LLM에 대해 논의합니다. 더 작은 사전 훈련 모델에 관심이 있는 독자들은 [51, 52, 53]을 참조하시기 바랍니다.

이 논문의 구성은 다음과 같습니다. 섹션 2에서는 LLM의 배경에 대해 논의하고, 섹션 3에서는 LLM 개요, 아키텍처, 훈련 파이프라인과 전략, 미세 조정에 초점을 맞춥니다.

다양한 영역에서의 활용. 4장에서는 이러한 모델의 작동에 중요한 역할을 하는 구성 및 매개변수를 강조합니다. 요약 및 논의는 3.8장에서 제시됩니다. LLM 훈련 및 평가, 데이터셋과 벤치마크는 5장에서 논의되며, 이후 7장과 8장에서 각각 도전 과제와 향후 방향, 결론이 이어집니다.

2. 배경

이 섹션에서는 LLM과 관련된 기본 개념을 이해하기 위한 관련 배경을 제공합니다. LLM의 필수 구성 요소에 대해 간략하게 논의하고, 세부 사항에 관심이 있는 독자들에게는 원본 작업을 참조하도록 안내합니다.

2.1. 토큰화

토큰화 [59]는 LLM 훈련에서 텍스트를 분해되지 않는 단위인 토큰으로 분석하는 필수 전처리 단계입니다. 토큰은 토큰화 과정에 따라 문자, 서브워드 [60], 기호 [61] 또는 단어가 될 수 있습니다. LLM에서 일반적으로 사용되는 토큰화 방식으로는 워드피스 [62], 바이트 쌍 인코딩(BPE) [61], 그리고 유니그램LM [60]이 있습니다. 독자들은 [63]을 참조하여 자세한 조사를 확인할 것을 권장합니다.

2.2. 인코딩 위치

트랜스포머는 입력 시퀀스를 병렬로 처리하며 서로 독립적입니다. 게다가 트랜스포머의 어텐션 모듈은 위치 정보를 포착하지 않습니다. 결과적으로 트랜스포머 [64]에서는 위치 인코딩이 도입되어 위치 임베딩 벡터가 토큰 임베딩에 추가됩니다. 위치 임베딩의 변형에는 절대적, 상대적 또는 학습된 위치 인코딩이 포함됩니다. 상대적 인코딩 내에서는 Alibi와 RoPE가 LLM에서 널리 사용되는 위치 임베딩 두 가지입니다.

Alibi [65]: 토큰 위치 간의 거리가 멀어질수록 증가하는 스칼라 편향을 주의 점수에서 뺍니다. 이는 최근 토큰을 주의에 우선적으로 사용하도록 합니다.

RoPE [66]: 입력 시퀀스에서 토큰의 절대 위치에 비례하는 각도로 쿼리와 키 표현을 회전시켜, 토큰 간의 거리와 함께 감소하는 상대 위치 인코딩 방식이 탄생합니다.

2.3. LLMs에서의 주의(attention)

주의는 모델이 관련된 토큰에 더 많은 강조를 주도록 중요성에 따라 입력 토큰에 가중치를 할당합니다. 트랜스포머의 주의 메커니즘은 입력 시퀀스에 대해 쿼리, 키 및 값 매핑을 계산하며, 여기서 주의 점수는 쿼리와 키를 곱하여 얻고, 이후 값을 가중치로 사용합니다. 아래에서는 LLM에서 사용되는 다양한 주의 전략에 대해 논의합니다.

Self-Attention [64]: 동일한 블록(인코더 또는 디코더)에서 쿼리, 키 및 값을 사용하여 주의를 계산합니다.
크로스 어텐션: 이는 인코더-디코더 아키텍처에서 사용되며, 인코더 출력은 쿼리가 되고 키-값 쌍은 디코더에서 옵니다.

희소 주의 [67]: 자기 주의는 $O(n^2)$ 시간 복잡성을 가지며, 이는 긴 시퀀스에서는 비현실적이 됩니다. 계산 속도를 높이기 위해 희소 주의 [67]는 속도 향상을 위해 슬라이딩 윈도우에서 반복적으로 주의를 계산합니다.

Flash Attention [68]: 메모리 접근은 GPU를 사용한 주의(attention) 계산에서 주요 병목 현상이다. 속도를 높이기 위해 flash attention은 입력 타일링을 활용하여 GPU 고대역폭 메모리(HBM)와 온칩 SRAM 간의 메모리 읽기 및 쓰기를 최소화한다.

2.4. 활성화 함수

활성화 함수는 신경망의 곡선 맞춤 능력에서 중요한 역할을 합니다 [69]. 이 섹션에서는 LLM에서 사용되는 활성화 함수에 대해 논의합니다.

ReLU [70]: 정류 선형 유닛(ReLU)은 다음과 같이 정의됩니다:

$$\text{ReLU}(x) = \max(0, x) \quad \text{죄}$$

GeLU [71]: 가우시안 에러 선형 단위(GeLU)는 ReLU, 드롭아웃(dropout) [72] 및 존아웃(zoneout) [73]의 조합입니다. GLU 변형 [74]: 게이트드 선형 단위(Gated Linear Unit) [75]는 선형 변환과 시그모이드 변환(σ)된 입력의 선형 투영의 요소별 곱(\otimes)인 신경망 층입니다.

$$\text{GLU}(x, W, V, b, c) = (xW + b) \otimes \sigma(xV + c), \quad \text{죄}$$

여기서 X 는 계층의 입력이며, l, W, b, V 및 c 는 학습된 매개변수입니다. LLM에서 사용되는 다른 GLU 변형 [74]은 다음과 같습니다:

$$\begin{aligned} \text{ReLU}(x, W, V, b, c) &= \max(0, xW + b) \otimes, \\ \text{GEGLU}(x, W, V, b, c) &= \text{GELU}(xW + b) \otimes (xV + c), \\ \text{S wiGLU}(x, W, V, b, c, \beta) &= \text{S wish}\beta(xW + b) \otimes (xV + c). \end{aligned}$$

2.5. 레이어 정규화

레이어 정규화는 더 빠른 수렴을 이끌어내며, transformers [64]의 통합된 구성 요소입니다. Layer-Norm [76]과 RMSNorm [77] 외에도 LLM은 레이어 정규화를 사전에 적용하여 멀티-헤드 주의(MHA) 전에 사용합니다 [78]. 사전 정규화는 LLM에서 훈련 안정성을 제공하는 것으로 나타났습니다. 또 다른 정규화 변형인 DeepNorm [79]은 사전 정규화에서 발생하는 더 큰 그래디언트 문제를 해결합니다.

2.6. 분산 LLM 훈련

이 섹션에서는 분산 LLM 훈련 접근 방식에 대해 간략히 설명합니다. 더 많은 세부사항은 [13, 37, 80, 81]에서 확인할 수 있습니다.
데이터 병렬 처리: 데이터 병렬 처리는 모델을 여러 장치에 복제하여 배치의 데이터가 장치 간에 나누어지는 방식입니다. 각 훈련 반복의 끝에서 가중치가 모든 장치 간에 동기화됩니다.

텐서 병렬성: 텐서 병렬성은 장치 간에 텐서 계산을 분할합니다. 이는 수평 병렬성 또는 층 내 모델 병렬성으로도 알려져 있습니다.

파이프라인 병렬 처리: 파이프라인 병렬 처리는 모델 레이어를 서로 다른 장치에 분산합니다. 이것은 수직 병렬 처리로도 알려져 있습니다.

모델 병렬성: 텐서 병렬성과 파이프라인 병렬성의 조합을 모델 병렬성이라고 합니다.

3D 병렬성: 데이터 병렬성, 텐서 병렬성 및 모델 병렬성의 조합을 3D 병렬성이라고 합니다.

최적화기 병렬 처리: 제로 중복 최적화기로 알려진 최적화기 병렬 처리는 메모리 소비를 줄이면서 통신 비용을 최대한 낮게 유지하기 위해 장치 간에 최적화기 상태 분할, 그래디언트 분할 및 파라미터 분할을 구현합니다.

2.7. 라이브러리

LLM 훈련에 일반적으로 사용되는 라이브러리는 다음과 같습니다:

Transformers [82]: 이 라이브러리는 훈련, 미세 조정, 추론 및 사용자 정의 모델 개발을 위한 API와 함께 다양한 사전 훈련된 변환기 모델에 대한 액세스를 제공합니다.

DeepSpeed [36]: 깊은 학습 모델의 확장 가능한 분산 훈련 및 추론을 위한 라이브러리.

Megatron-LM [80]: 대규모 LLM 훈련을 위한 GPU 최적화 기술을 제공합니다.

JAX [83]: 고성능 수치 계산 및 확장 가능한 기계 학습을 위한 파이썬 라이브러리입니다. 기본 파이썬 및 NumPy 함수를 구분하고 이를 GPU에서 실행할 수 있습니다.

Colossal-AI [84]: 분산 딥러닝 모델을 작성하기 위한 구성 요소 모음입니다.

BMTrain [81]: 효율적인 독립형 LL

Ms 훈련 코드를 작성하기 위한 라이브러리입니다.

FastMoE [85]: PyTorch에서 mixture-of-experts (MoE) 모델을 구축하기 위한 API를 제공합니다.

MindSpore [86]: 모바일, 엣지 및 클라우드 컴퓨팅에 확장 가능한 딥 러닝 학습 및 추론 프레임워크.

PyTorch [87]: Facebook AI Research lab (FAIR)에서 개발한 딥 러닝 모델을 구축하기 위한 프레임워크입니다. PyTorch의 주요 특징으로는 동적 계산 그래프와 파이썬 스타일의 코딩이 포함됩니다.

Tensorflow [88]: Google에서 작성한 딥 러닝 프레임워크입니다. TensorFlow의 주요 특징은 그래프 기반 계산, 즉시 실행, 확장성 등이 있습니다.

MXNet [89]: Apache MXNet은 Python, C++, Scala, R 등 여러 언어로 프로그램을 작성할 수 있는 딥 러닝 프레임워크입니다. 또한 동적 및 정적 계산 그래프에 대한 지원도 제공합니다.

2.8. 데이터 전처리

이 섹션은 LLMs 훈련에 사용되는 데이터 전처리 기술을 간략하게 요약합니다.

품질 필터링: 더 나은 결과를 위해서는 훈련 데이터의 품질이 필수적입니다. 데이터 필터링에 대한 몇 가지 접근 방식은 다음과 같습니다: 1) 분류기 기반 접근 방식과 2) 휴리스틱 기반 접근 방식. 분류기 기반 접근 방식은 고품질 데이터로 분류기를 훈련시키고 필터링을 위한 텍스트의 품질을 예측하는 반면, 휴리스틱 기반 접근 방식은 언어, 메트릭, 통계 및 키워드와 같은 필터링을 위한 규칙을 적용합니다.

데이터 중복 제거: 중복된 데이터는 모델 성능에 영향을 미치고 데이터 암기를 증가시킬 수 있으므로, LLM을 훈련하기 위해 데이터 중복 제거는 전처리 단계 중 하나입니다. 이는 문장, 문서 및 데이터셋과 같은 여러 수준에서 수행될 수 있습니다.

프라이버시 감소: LLM의 대부분의 교육 데이터는 웹 소스를 통해 수집됩니다. 이 데이터에는 개인 정보가 포함되어 있으므로, 많은 LLM은 개인 정보를 학습하지 않기 위해 이름, 주소 및 전화번호와 같은 정보를 필터링하기 위해 휴리스틱 기반 방법을 사용합니다.

2.9. 아키텍처

여기에서 우리는 LLMs에서 사용되는 변형된 transformer 아키텍처에 대해 논의합니다. 그 차이는 적용에 따라 발생합니다.




그림 4: 언어 모델에서의 주의 패턴 예시, 이미지는 [93]에서 가져온 것이다.

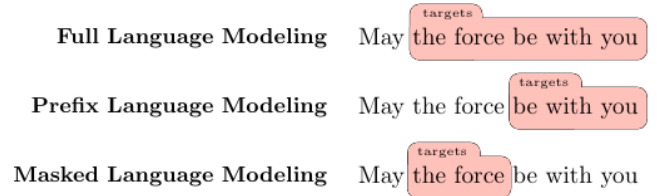


그림 5: 언어 모델 학습 목표의 예, 이미지 출처 [93].

트랜스포머 블록의 주의력과 연결성이다. 이러한 아키텍처의 주의력 패턴에 대한 설명은 그림 4에 나와 있다.

인코더 디코더: 이 아키텍처는 인코더를 통해 입력을 처리하고, 중간 표현을 디코더에 전달하여 출력을 생성합니다. 여기서 인코더는 자기 주의를 이용하여 전체 시퀀스를 보고, 디코더는 교차 주의를 구현하여 시퀀스를 하나씩 처리합니다.

인과 디코더: 인코더가 없고 디코더를 사용하여 출력을 처리하고 생성하는 구조의 일종으로, 예측된 토큰은 오직 이전 시간 단계에만 의존한다.

프리픽스 디코더: 이것은 비인과적 디코더로도 알려져 있으며, 주의 계산이 과거 정보에 엄격히 의존하지 않고 주의가 양방향이라는 특징이 있습니다. 비인과적 주의 마스크의 예는 그림 4에 나와 있습니다.

Mixture-of-Experts: 이는 병렬 독립 전문가와 토큰을 전문가에게 라우팅하는 라우터를 가진 변형된 트랜스포머 아키텍처입니다. 이러한 전문가들은 주목 블록[90] 이후의 피드 포워드 층입니다. Mixture-of-Experts (MoE)는 효율적인 희소 아키텍처로, 밀집 모델과 비슷한 성능을 제공하며, 한 번에 몇몇 전문가만 활성화시켜 모델 크기를 늘려도 계산 비용을 증가시키지 않을 수 있습니다[91, 92].

2.10. 사전 훈련 목표

이 섹션에서는 LLM의 사전 훈련 목표에 대해 설명합니다. 더 자세한 내용은 논문 [93]을 참조하세요.

전체 언어 모델링: 이전 토큰을 바탕으로 미래 토큰을 예측하도록 요구받는 자가 회귀 언어 모델링 목표로, 그 예시는 그림 5에 설명되어 있다.

접두사 언어 모델링: 비인과적 훈련 목표로, 접두사가 무작위로 선택되고 나머지 목표 토큰만 사용하여 손실을 계산합니다. 예시는 Figure 5에 나와 있습니다.

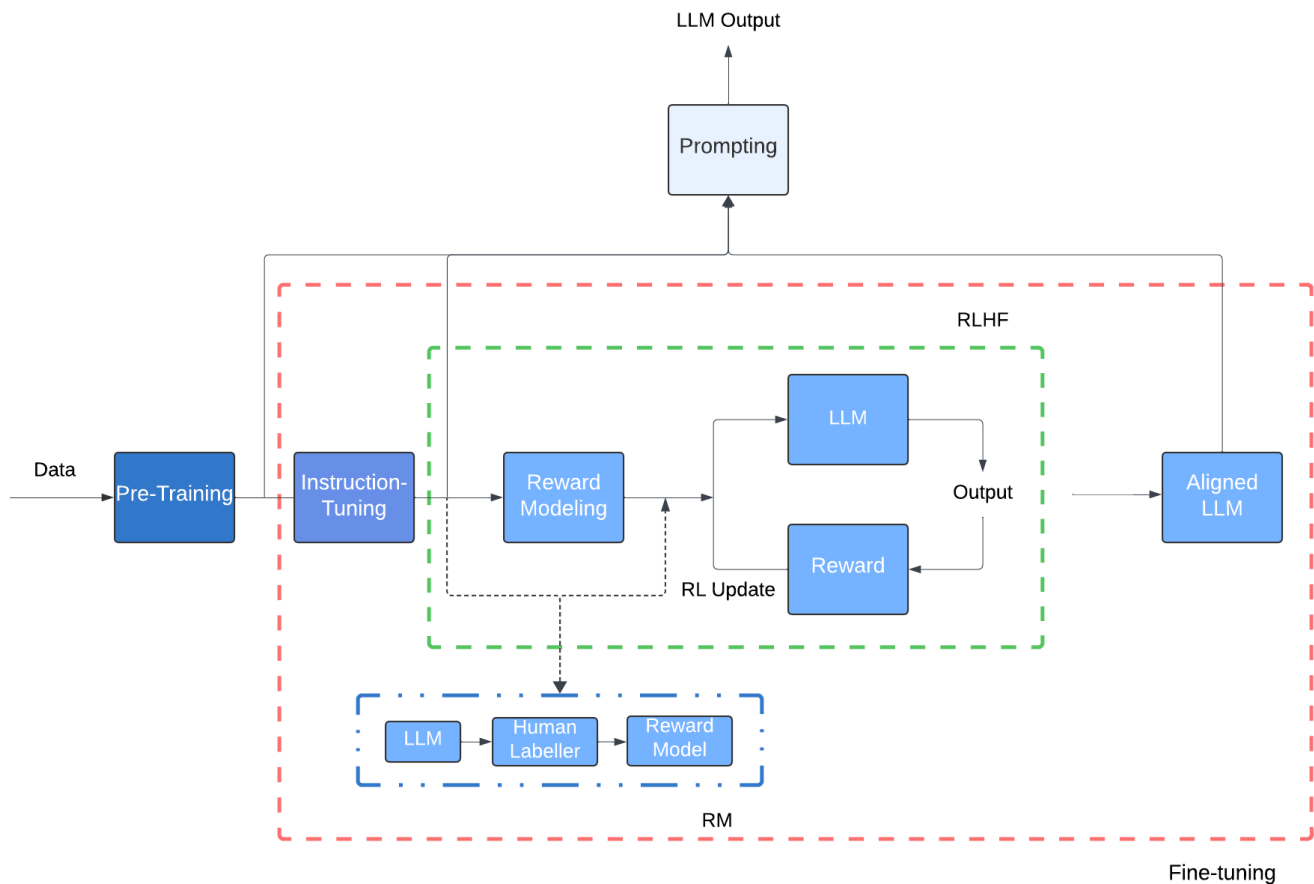


그림 6: 사전 훈련부터 프롬프트/활용까지 LLM의 다양한 단계를 나타내는 기본 흐름 다이어그램. LLM에게 응답 생성을 프롬프트하는 것은 사전 훈련, 지시 조정 또는 정렬 조정과 같은 다양한 훈련 단계에서 가능합니다. “RL”은 강화 학습을, “RM”은 보상 모델링을, “RLHF”는 인간 피드백을 통한 강화 학습을 나타냅니다.

마스크 언어 모델링: 이 훈련 목표에서는 토큰이나 스펀(토큰의 시퀀스)이 무작위로 마스크되고, 모델은 과거와 미래의 맥락을 바탕으로 마스크된 토큰을 예측하도록 요청받습니다. 예시는 Figure 5에 나와 있습니다.

통합 언어 모델링: 통합 언어 모델링은 인과적, 비인과적, 그리고 마스크된 언어 훈련 목표의 조합입니다. 여기서 마스크된 언어 모델링에서는 주의(attention)가 양방향이나 단방향으로, 왼쪽에서 오른쪽 또는 오른쪽에서 왼쪽 문맥에만 주의를 기울입니다.

2.11. LLMs 규모 법칙

스케일링 법칙은 모델 성능의 개선을 예측하는 모델 매개변수, 데이터셋 크기 및 계산 자원의 최적 조합을 연구합니다. 손실이 모델 크기, 데이터셋 크기 및 계산 자원에 따라 멍법칙에 따라 증가한다는 것이 입증되었습니다 [95]. 이 연구는 더 큰 모델이 더 나은 성능을 위해 빅데이터보다 더 중요하다는 것을 제안합니다. 또 다른 스케일링 법칙의 변형 [96]은 모델 크기와 학습 토큰의 수가 동일하게 스케일링되어야 한다고 제안합니다.

2.12. LLMs 적응 단계

이 섹션에서는 LLM의 적응 단계, 즉 다운스트림 작업 및 활용을 위한 사전 훈련에서 미세 조정까지의 기본 개념을 논의합니다. LLM의 다양한 훈련 단계와 추론의 예는 그림 6에 나와 있습니다. 본 논문에서는 정렬 조정을 인간의 선호와 일치시키는 것으로 지칭하며, 문헌에서는 때때로 다른 목적으로 정렬이라는 용어를 사용합니다.

2.12.1. 사전 훈련

처음 단계에서 모델은 입력에 따라 다음 토큰을 예측하기 위해 대량의 말뭉치에서 자기 지도 방식으로 훈련됩니다. LLM의 설계 선택은 2.5, 2.4, 2.10 섹션에서 다양한 빌딩 블록과 손실 함수가 있는 인코더-디코더에서 디코더 전용 아키텍처까지 다양합니다.

2.12.2. 파인튜닝

LLM을 미세 조정하는 다양한 스타일이 있습니다. 이 섹션에서는 미세 조정 방법에 대해 간략하게 논의합니다. 전이 학습: 미리 훈련된 LLM은 다양한 작업에서 잘 수행됩니다 [6, 15]. 하지만 성능을 향상시키기 위해서는

하류 과제에서는, 사전 훈련된 모델이 과제별 데이터 [10, 11]로 미세 조정되어 전이 학습으로 알려져 있습니다.

Instruction-tuning: 모델이 사용자 쿼리에 효과적으로 응답할 수 있도록 미리 훈련된 모델은 인스트럭션 형식의 데이터, 즉 인스트럭션과 입력-출력 쌍에 대해 미세 조정됩니다. 인스트럭션은 일반적으로 모델이 프롬프트와 입력에 따라 응답하도록 안내하는 일반 자연어의 다중 작업 데이터를 포함합니다. 이러한 유형의 미세 조정은 제로샷 일반화와 하위 작업 성능을 향상시킵니다. 인스트럭션 데이터의 형식 지정과 다양한 스타일에 대한 자세한 내용은 [16, 50, 97]에서 확인할 수 있습니다.

정렬 조정: LLM은 잘못된, 편향된, 그리고 유해한 텍스트를 생성하는 경향이 있습니다. 이를 도움이 되고, 정직하며, 해롭지 않게 만들기 위해 모델은 인간의 피드백을 사용하여 정렬됩니다. 정렬 과정은 LLM에게 예상치 못한 응답을 생성하도록 요청한 후, 그러한 응답을 피하도록 매개변수를 업데이트하는 것을 포함합니다.

이는 LLM이 인간의 의도와 가치를 따라 작동하도록 보장합니다. 모델은 도움이 되고, 정직하며, 해롭지 않은 세 가지 기준을 충족할 경우 “정렬된” 모델로 정의됩니다.

연구자들은 모델 정렬을 위해 인간 피드백을 포함한 강화 학습(RLHF)을 활용합니다. RLHF에서는 시연에 대해 미세 조정된 모델이 보상 모델링(RM)과 강화 학습(RL)을 통해 추가적으로 학습되며, 이는 그림 6에 나타나 있습니다. 아래에서는 RLHF에서 RM과 RL 파이프라인에 대해 간략히 논의합니다.

보상 모델링: 생성된 응답을 인간의 선호도에 따라 순위 매기기 위해 분류 목표를 사용하여 모델을 훈련합니다. 분류기를 훈련하기 위해 인간이 HHH 기준에 따라 LLM이 생성한 응답에 주석을 달습니다.

강화 학습: 보상 모델과 결합되어 다음 단계에서 정렬을 위해 사용됩니다. 이전에 훈련된 보상 모델은 LLM이 생성한 응답을 선호하는 것과 비선호하는 것으로 순위를 매기며, 이는 모델을 근접 정책 최적화(PPO)와 정렬하는 데 사용됩니다. 이 과정은 수렴할 때까지 반복됩니다.

2.12.3. 프롬프트/활용

프롬프트는 훈련된 LLM에 응답을 생성하도록 요청하는 방법으로, Figure 6에 설명되어 있습니다. LLM은 다양한 프롬프트 설정에서 프롬프트될 수 있으며, 훈련 없이 지침에 맞게 조정되거나 다른 경우에는 서로 다른 프롬프트 스타일을 포함하는 데이터에 대한 미세 조정을 통해 조정될 수 있습니다 [16, 101, 102]. 프롬프트 엔지니어링에 대한 좋은 가이드는 [32]에서 확인할 수 있습니다. 아래에서는 널리 사용되는 다양한 프롬프트 설정에 대해 논의하겠습니다.

제로샷 프롬프트: LLM은 제로샷 학습자이며 이전에 본 적 없는 질문에 응답할 수 있습니다. 이러한 프롬프트 방식은 LLM이 프롬프트에서 어떤 예시도 보지 않고 사용자 질문에 응답하도록 요구합니다.

문맥 내 학습: 소수 샷 학습으로도 알려져 있으며, 여기서 여러 개의 입력-출력 시연 쌍이 모델에 제공되어 원하는 응답을 생성합니다. 이러한 적응 방식은 소수 샷 학습이라고도 합니다. 문맥 내 학습(ILC) 템플릿 형식에 대한 논의는 [54, 50, 18, 16]에서 확인할 수 있습니다. LLM에서의 추론: LLM은 제로 샷 추론 기이며 논리 문제, 작업 계획, 비판적 사고 등과 같은 문제에 대한 답변을 생성하도록 자극할 수 있습니다. 이유를 생성하는 것은 다양한 프롬프트 스타일을 사용해야만 가능합니다.

이러한 이유로 LLM을 추론 작업에서 더욱 향상시키기 위해 많은 방법[16, 97]이 추론 데이터셋으로 훈련하고 있습니다. 우리는 아래에서 추론을 위한 다양한 프롬프트 기술에 대해 논의합니다.

Chain-of-Thought (CoT): 입력과 출력에 집계된 추론 정보를 포함한 데모를 통해 모델이 단계별로 추론하여 결과를 생성하는 프롬프트의 특수한 경우입니다. CoT 프롬프트에 대한 자세한 내용은 [55, 103, 101]에서 확인할 수 있습니다.

자기 일관성: 여러 응답을 생성하고 가장 빈번한 답변을 선택하여 CoT 성능을 향상시킵니다 [104].

Tree-of-Thought (ToT): 문제 해결을 위한 다양한 추론 경로를 탐색하며 앞으로 나아가고 다시 되돌아갈 수 있는 가능성을 제공합니다 [105].

단일 턴 지침: 이 프롬프트 설정에서는 LLM에 모든 관련 정보를 포함한 질문을 한 번만 한다. LLM은 제로샷 또는 Few-shot 설정에서 문맥을 이해하여 응답을 생성한다.

다단계 지침: 복잡한 작업을 해결하기 위해서는 LLM과의 여러 차례 상호작용이 필요하며, 다른 도구들로부터의 피드백과 응답이 다음 라운드를 위한 LLM의 입력으로 제공됩니다. 이러한 방식으로 LLM을 반복적으로 사용하는 것은 자율 에이전트에서 일반적입니다.

3. 대형 언어 모델

이 섹션에서는 LLM을 검토하며, 그들의 아키텍처, 훈련 목표, 파이프라인, 데이터셋 및 세부적인 미세 조정 사항을 간략하게 설명합니다.

3.1. 사전 훈련된 LLMs

여기에서는 NLP 분야의 연구 및 개발 방향을 변화시킨 중요한 발견들과 함께 여러 유명한 사전 훈련된 LLM의 요약물을 제공합니다. 이러한 LLM은 NLU 및 NLG 분야에서 성능을 상당히 향상시켰으며, 하위 작업에 맞게 널리 세부 조정되었습니다. 게다가, 우리는 성능을 향상시키는 사전 훈련된 LLM의 주요 발견과 통찰을 표 1과 2에서 확인합니다.

3.1.1. 일반 목적

T5 [10]: 모든 NLP 문제를 위한 통합 텍스트-투-텍스트 훈련을 사용하는 인코더-디코더 모델이 그림 7에 표시되어 있다. T5는 전통적인 트랜스포머 모델 [64]에서 잔여 경로 바깥에 레이어 정규화를 배치한다. 이 모델은 연속된 토큰을 단일 마스크로 대체하는 마스크 언어 모델링을 사전 훈련 목표로 사용한다. 이러한 유형의 마스크는 더 짧은 시퀀스를 생성하기 때문에 훈련 속도를 높인다. 사전 훈련 후, 모델은 다운스트림 작업을 위해 어댑터 레이어 [106]를 사용하여 미세 조정된다.

GPT-3 [6]: GPT-3 아키텍처는 GPT-2 [5]와 동일하지만 Sparse Transformer [67]와 유사하게 변환기 층에서 밀집 및 희소 주의를 사용합니다. 이는 대형 모델이 훈련 중 배치 크기를 결정하기 위해 더 낮은 학습률로 더 큰 배치 크기로 훈련할 수 있음을 보여줍니다. GPT-3는 [107]에서와 같이 경량 소음 스케일을 사용합니다. 전반적으로 GPT-3는 모델 매개변수를 175B로 증가시켜 대형 언어 모델의 성능을 개선합니다.




그림 7: 통합 텍스트-투-텍스트 훈련 예시, 출력 이미지는 [10]입니다.




그림 8: 이미지는 [108]의 기사로, PanGu-α 아키텍처의 예를 보여줍니다.

모델은 규모에 따라 개선되며 미세 조정된 모델들과 경쟁력이 있다.

mT5 [11]: mC4 데이터셋에서 훈련된 다국어 T5 모델 [10]로, 101개 언어를 지원한다. 이 데이터셋은 공개된 공통 크롤링 자료에서 추출되었습니다. 이 모델은 여러 언어를 포괄하기 위해 250,000의 더 큰 어휘 크기를 사용합니다. 특정 언어에 대한 오버피팅이나 언더피팅을 피하기 위해 mT5는 모든 언어에서 샘플을 선택하는 데이터 샘플링 절차를 적용합니다. 이 논문은 영어 데이터로 작업을 미세 조정할 때 모든 언어를 포함한 소량의 사전 훈련 데이터셋을 사용하는 것을 제안합니다. 이를 통해 모델은 정확한 비영어 출력을 생성할 수 있습니다.

PanGu-α [108]: 표준 트랜스포머 층의 끝에 쿼리 레이어가 있는 자기 회귀 모델로, 다음 토큰을 예측하기 위해 사용되며, Figure 8에 예가 표시되어 있다. 그 구조는 트랜스포머 층과 유사하지만, Eq. 3에서 제공된 주의 메커니즘에서 다음 위치를 위한 추가 임베딩이 있다.

$$a = pnWqhWkhTH \quad (3)$$

CPM-2 [12]: 비용 효율적인 사전 훈련 언어 모델(CPM-2)은 WuDaoCorpus [109] 데이터셋에서 11B 및 198B 혼합 전문가(MoE) 모델을 이중 언어(영어 및 중국어)로 사전 훈련합니다. 토큰화 과정에서는 sentencepiece 토큰라이저에서 “_” 공백 토큰을 제거합니다. 모델은 지식 상속을 통해 훈련되며, 첫 번째 단계에서는 중국어만을 사용하고 그 후에 영어 및 중국어 데이터를 추가합니다. 이 훈련된 모델은 198B MoE 모델을 초기화하기 위해 여러 번 복제됩니다. 또한, 다운스트림 작업에 모델을 사용하기 위해 CPM-2는 두 가지 방법으로 실험을 진행했습니다.

완전한 미세 조정과 프롬프트 미세 조정을 [40]와 같이 수행하여, 다양한 위치(앞, 중간, 뒤)에 프롬프트를 삽입하여 프롬프트와 관련된 매개변수만 업데이트합니다. CPM-2는 또한 100B 규모에서 추론을 위해 매개변수를 CPU에 동적으로 오프로드하는 전략을 가진 메모리 효율적인 프레임워크인 INFMOE를 제안합니다. 이 프레임워크는 데이터 이동과 추론 계산을 겹쳐서 더 낮은 추론 시간을 제공합니다.

ERNIE 3.0 [110]: ERNIE 3.0은 멀티태스킹 학습에서 영감을 얻어 Transformer-XL [111]을 백본으로 사용하는 모듈형 아키텍처를 구축합니다. 범용 표현 모듈은 모든 작업에서 공유되며, 이는 작업별 표현 모듈의 기본 블록 역할을 하며, 자연어 이해, 자연어 생성 및 지식 추출을 위해 모두 공동으로 훈련됩니다. 이 LLM은 주로 중국어에 초점을 맞추고 있으며, LLM 훈련을 위한 가장 큰 중국어 텍스트 코퍼스에서 훈련한다고 주장하며, 54개의 중국어 NLP 작업에서 최첨단 성능을 달성했습니다.

Jurassic-1 [112]: 7B-매개변수 J1-Large 모델과 178B-매개변수 J1-Jumbo 모델을 포함한 자기 회귀 언어 모델의 쌍. Jurassic-1의 훈련 어휘는 가능한 경우에 단어 경계 없이 단어 조각, 완전한 단어 및 다중 단어 표현으로 구성되며, 어휘에 없는 인스턴스는 Unicode 바이트로 해석됩니다. GPT-3 모델에 비해 Jurassic-1 모델은 더 균형 잡힌 깊이-너비 자기 주의 아키텍처 [113]와 더 빠른 예측을 위한 개선된 토큰라이저를 적용하여 더 넓은 자원을 기반으로 제로샷 학습 작업에서 유사한 성능을 달성하고, 더 많은 예시를 프롬프트로 제공할 수 있는 능력을 가지고 있어 퓨샷 학습 작업에서 우수한 성능을 보여줍니다.

HyperCLOVA [114]: GPT-3 아키텍처를 가진 한국어 모델.

Yuan 1.0 [115]: 5TB의 고품질 텍스트로 수집된 중국어 말뭉치로 훈련되었습니다. 원시 데이터를 조잡하고 세밀한 필터링 기술을 통해 처리하기 위해 Spark를 기반으로 한 대규모 데이터 필터링 시스템(MDFS)이 개발되었습니다. 에너지 비용 및 탄소 배출을 절감하기 위해 Yuan 1.0의 훈련 속도를 높이기 위해, 분산 훈련의 성능을 향상시키는 다양한 요소들이 아키텍처와 훈련에 통합되었습니다. 예를 들어, 히든 상태 크기를 증가시키면 파이프라인 및 텐서 병렬성 성능이 향상되고, 더 큰 마이크로 배치와 파이프라인 병렬성 성능을 개선하며, 더 큰 글로벌 배치 크기는 데이터 병렬성 성능을 향상시킵니다. 실제로 Yuan 1.0 모델은 텍스트 분류, Winograd Schema, 자연어 추론, 독해 과제에서 우수한 성능을 보입니다.

Gopher [116]: Gopher 모델 군은 LLM 성능에 대한 규모의 영향을 연구하기 위해 44M에서 280B 매개변수 크기로 구성된다. 280B 모델은 평가된 81%의 작업에서 GPT-3 [6], Jurassic-1 [112], MT-NLG [117] 및 기타 모델을 능가한다.

ERNIE 3.0 TITAN

[35]: ERNIE 3.0 Titan은 이전 모델보다 26배 많은 매개변수로 더 큰 모델을 훈련시켜 ERNIE 3.0을 확장한다. 이 더 큰 모델은 68개의 NLP 작업에서 다른 최신 모델들을 능가했다. LLM은 잘못된 사실로 텍스트를 생성한다. 생성된 텍스트의 사실 일관성을 제어하기 위해, ERNIE 3.0 Titan은 다중 작업 학습 설정에 신뢰할 수 있고 제어 가능한 생성(Credible and Controllable Generations)이라는 또 다른 작업을 추가한다.

추가적인 자기 감독된 적대적 및 제어 가능한 언어 모델링 손실을 사전 훈련 단계에 도입하여 ERNIE 3.0 Titan이 수동으로 선택된 사실 기반 QA 작업 세트 평가에서 다른 LLM들을 능가할 수 있게 합니다.

GPT-NeoX-20B [118]: GPT-3을 대체로 따르는 자기 회귀 모델로, 몇 가지 아키텍처 설계의 변형이 있으며, 데이터 중복 제거 없이 Pile 데이터셋에서 훈련되었습니다. GPT-NeoX는 Eq. 4에 제시된 변환기 블록 내에 병렬 주의 및 피드 포워드 층을 포함하고 있어 처리량이 15% 증가합니다. 이 모델은 회전 위치 임베딩 [66]을 사용하며, [119]와 같이 임베딩 벡터 차원의 25%에만 적용합니다. 이를 통해 성능 저하 없이 계산량을 줄입니다. GPT-3이 밀집 및 희소 층을 사용하는 반면, GPT-NeoX-20B는 밀집 층만을 사용합니다. 이러한 규모에서의 하이퍼파라미터 조정은 어렵기 때문에, 모델은 방법 [6]에서 하이퍼파라미터를 선택하고 20B 모델을 위해 13B와 175B 모델 간의 값을 보간합니다. 모델 훈련은 텐서 및 파이프라인 병렬성을 사용하여 GPU 간에 분산됩니다.

$$x + \text{Attn}(\text{LN}(x)) + \text{FF}(\text{LN}(x)) \quad (4)$$

OPT [14]: GPT-3의 복제품으로 개발된 클론으로, GPT-3 성능을 복제하는 모델을 오픈소스화하기 위한 것입니다. OPT의 훈련은 동적 손실 스케일링(dynamic loss scaling) [120]을 사용하고, 손실 발산이 관찰될 때마다 이전 체크포인트에서 더 낮은 학습률로 재시작합니다. 전반적으로 OPT-175B 모델의 성능은 GPT3-175B 모델과 비슷합니다.

BLOOM [13]: LLM을 오픈소스화하기 위해 R

OOTs 코퍼스에서 훈련된 인과적 디코더 모델입니다. BLOOM의 구조는 Figure 9에 나타나 있으며, ALiBi 위치 임베딩, 임베딩 층 후에 추가된 정규화 층과 같은 차이점이 있습니다. 이러한 변화는 훈련을 안정화하고 향상된 다운스트림 성능을 제공합니다.

GLaM [91]: 일반 언어 모델(GLaM)은 희소하게 활성화된 디코더 전용 전문가 혼합(MoE) 구조를 사용하는 언어 모델의 집합을 나타냅니다 [121, 90].

더 많은 모델 용량을 확보하면서 계산을 줄이기 위해, 전문가가는 희소하게 활성화되어 각 입력 토큰을 처리하는 데 가장 좋은 두 개의 전문가만 사용됩니다. 가장 큰 GLaM 모델인 GLaM (64B/64E)은 GPT-3 [6]보다 약 7배 크지만, 입력 토큰당 활성화되는 매개변수는 일부분에 불과합니다. 가장 큰 GLaM (64B/64E) 모델은 GPT-3에 비해 전반적으로 더 나은 결과를 얻으면서도 GPT-3의 훈련 에너지를 3분의 1만 소비합니다.

MT-NLG [117]: GPT-2 아키텍처를 기반으로 한 530B 인과 디코더로, 대략 3배의 GPT-3 모델 매개변수를 가지고 있습니다. MT-NLG는 다양한 공개 데이터셋에서 수집된 필터링된 고품질 데이터로 훈련되었으며, 여러 종류의 데이터셋을 단일 배치로 혼합하여 GPT-3보다 여러 평가에서 우수한 성능을 보입니다.

Chinchilla [96]: Gopher [116]와 동일한 데이터셋에서 훈련된 인과 디코더로, 약간 다른 데이터 샘플링 분포(MassiveText에서 샘플링됨)를 가지고 있다. 모델 아키텍처는 Gopher에 사용된 것과 비슷하지만, Adam 대신 Adam W 최적화기를 사용한다. Chinchilla는

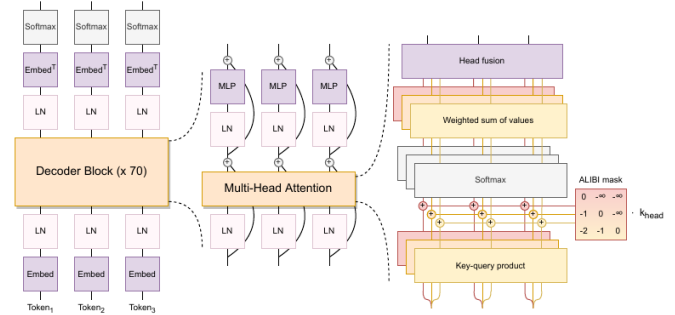


그림 9: [13]에서 출처를 얻은 BLOOM 아키텍처 예시.

모델 크기는 훈련 토큰이 두 배로 늘어날 때마다 두 배가 되어야 한다는 관계가 있습니다. 70백만에서 160억 이상의 매개변수를 가진 400개 이상의 언어 모델이 5억에서 500억 토큰에 걸쳐 훈련되어 주어진 예산 하에서 계산 최적화 훈련에 대한 추정을 얻습니다. 저자들은 Gopher(280B)와 동일한 계산 예산으로 70B 모델을 훈련시키지만 데이터는 4배 더 많습니다. 이 모델은 파인튜닝 후 다양한 다운스트림 작업에서 Gopher [116], GPT-3 [6] 및 기타 모델을 능가합니다.

AlexaTM [122]: 인코더-디코더 모델로, 인코더 가중치와 디코더 임베딩이 사전 훈련된 인코더로 초기화되어 훈련 속도를 높인다. 인코더는 초기 100k 스텝 동안 고정되어 있다가 이후에는 end-to-end 훈련을 위해 해제된다. 모델은 노이즈 제거 및 인과 언어 모델링(CLM) 목표의 조합으로 훈련되며, 모드 전환을 위해 시작 부분에 [CLM] 토큰을 연결한다. 훈련 중 CLM 작업은 20%의 시간 동안 적용되어 문맥 내 학습 성능을 향상시킨다.

PaLM [15]: Eq. 4와 유사한 병렬 주의와 피드포워드 계층을 가진 인과 디코더로, 훈련 속도를 15배 높입니다. 기존의 트랜스포머 모델에 대한 추가 변경 사항으로는 SwiGLU 활성화, RoPE 임베딩, 디코딩 중 계산 비용을 절약하는 다중 쿼리 주의 및 공유 입력-출력 임베딩이 포함됩니다. 훈련 중 손실 급증이 관찰되었고, 이를 해결하기 위해 모델 훈련은 급증 전 100단계 이전 체크포인트에서 재시작되었으며, 급증 근처의 200-500 배치를 건너뛰었습니다. 게다가, 540B 모델 규모에서 모델이 훈련 데이터의 약 2.4%를 기억하는 것으로 나타났으며, 이 숫자는 더 작은 모델에서는 더 낮았습니다.

PaLM-2 [123]: PaLM의 더 작은 다국어 변형으로, 더 나은 품질의 데이터셋에서 더 큰 반복에 대해 훈련되었습니다. PaLM-2는 PaLM보다 상당한 개선을 보여주며, 크기가 작아짐에 따라 훈련 및 추론 비용을 줄입니다. 유해성 및 암기를 줄이기 위해 특별한 토큰을 추가하며, 이는 사전 훈련 데이터의 일부와 함께 사용되어 해로운 응답 생성이 감소하는 것으로 나타났습니다.

U-PaLM [124]: 이 방법은 UL2(UL2Restore 라고도 불림) 목표를 사용하여 0.1% 추가 계산으로 PaLM을 훈련시키며 [125], 동일한 데이터셋을 사용하여 다양한 NLP 작업에서 제로샷, 퓨샷, 상식 추론, CoT 등을 포함하여 기존 선보다 상당히 뛰어난 성능을 보인다. UL2R로 훈련하는 것은 인과 디코더 PaLM을 비인과 디코더 PaLM으로 변환하고 50% 순차적 디노이징, 25% 일반 디노이징, 그리고 25% 극단적 디노이징 손실 함수를 적용하는 것을 포함한다.

UL2 [125]: 여러 가지 노이즈 제거기(MoD) 목표를 사용하여 훈련된 인코더-디코더 아키텍처입니다. 노이즈 제거기에는 1) R-Denoiser: 일반적인 스펙 마스크, 2) S-Denoiser: 긴 시퀀스의 연속 토큰을 손상시키는 방식, 3) X-Denoiser: 많은 수의 토큰을 무작위로 손상시키는 방식이 포함됩니다. 사전 훈련 중에 UL2는 R, S, X에서 노이즈 제거 토큰을 포함하여 노이즈 제거 설정을 나타냅니다. 이는 작업을 업스트림 훈련 모드 중 하나에 결합해야 하는 다운스트림 작업의 미세 조정 성능을 향상시키는 데 도움이 됩니다. 이러한 MoD 스타일의 훈련은 여러 벤치마크에서 T5 모델을 능가합니다.

GLM-130B [33]: GLM-130B는 GLM [126]과 유사한 자기 회귀 마스크 채우기 사전 훈련 목표를 사용하여 훈련된 이중 언어(영어와 중국어) 모델입니다. 이 훈련 방식은 GPT-3가 단방향인 것에 비해 모델을 양방향으로 만듭니다. GLM과는 달리, GLM-130B의 훈련에는 자기 감독형 마스크 채우기와 함께 소량의 다중 작업 지침 사전 훈련 데이터(총 데이터의 5%)가 포함됩니다. 훈련을 안정화하기 위해 임베딩 레이어 그래디언트 축소가 적용됩니다.

LLaMA [127, 21]: 7B에서 70B 파라미터까지 다양하게 구성된 디코더 전용 언어 모델 세트입니다. LLaMA 모델 시리즈는 파라미터 효율성과 지침 조정에서 커뮤니티에서 가장 유명합니다.

LLaMA-1 [127]: 효율적인 인과적 주의를 구현하며 [128], 마스크된 주의 가중치와 키퀴리 점수를 저장하거나 계산하지 않습니다. 또 다른 최적화는 [129]와 같이 역전파에서 재계산되는 활성화 수를 줄이는 것입니다.

LLaMA-2 [21]: 이 작업은 대화 생성을 위한 더 안전하고 개선된 LLaMA-2-Chat 모델의 미세 조정에 더 집중하고 있습니다. 사전 학습된 모델은 더 긴 컨텍스트 길이와 그룹화된 킴리 주의를 이용하여 40% 더 많은 훈련 데이터를 포함하고 있습니다.

LLaMA-3/3.1 [130]: LLaMA-2에 비해 일곱 배 더 큰 데이터셋에서 훈련된 모델의 집합으로, 두 배의 컨텍스트 길이를 가지고 있으며, 이전 버전 및 다른 모델들을 능가합니다.

PanGu-Σ [92]: PanGu-α에서 파라미터를 복사하고 Random Routed Experts (RRE)를 사용해 조정하여 조정된 1조 스케일의 자기회귀 모델이며, 아키텍처 다이어그램은 그림 10에 나와 있습니다. RRE는 MoE 아키텍처와 유사하지만 두 번째 수준에서 토큰이 학습 가능한 게이팅 방법 대신 도메인 내의 전문가에게 무작위로 라우팅되는 점에서 차별화됩니다. 모델의 하단 계층은 모든 도메인에서 밀집하게 활성화되고 공유되는 반면, 상단 계층은 도메인에 따라 희소하게 활성화됩니다. 이 훈련 스타일은 작업별 모델을 추출할 수 있게 해주며 지속적인 학습의 경우 파국적 망각 효과를 줄여줍니다.

Mixtral8x22b [131]: 각각의 고유한 전문가 8명을 가진 혼합 전문가(MoE) 모델은 각 층에서 각 토큰을 두 명의 전문가에게 할당하고, 출력 결과를 더하여 결합합니다.

Snowflake Arctic [132]: Arctic LLM은 밀집형(Dense)과 전문가 혼합(Mixture-of-experts, MoE) 아키텍처의 하이브리드입니다. MoE(128×3.66B MLP 전문가)는 밀집형 변환기(10B)와 병렬로 작동하며, 활성화된 전문가가 두 개만 존재합니다. 이 모델은 다른 MoE LLMs [131, 133]에 비해 많은 전문가를 보유하고 있어 모델 용량을 늘리고 다양한 구성에 대해 여러 전문가 중에서 선택할 수 있는 기회를 제공합니다. 이 모델은 480B 매개변수를 가지고 있으며, 순전파(Forward pass) 동안 활성화되는 매개변수는 17B에 불과하여,

계산이 상당히 중요합니다.

Grok [133, 134]: Grok는 XAI에서 출시한 Grok-1과 Grok-1.5를 포함한 LLM의 가족입니다.

Grok-1 [133]: Grok-1은 314B 매개변수를 가진 언어 MoE 모델(여덟 명의 전문가)로, 토큰당 두 명의 전문가가 활성화됩니다.

Grok-1.5는 더 긴 문맥 길이와 향상된 성능을 갖춘 다중 모달 LLM입니다.

제미니 [135, 136]: 제미니는 멀티 모달 기능과 중요한 언어 모델링 성능 향상이 추가된 Bard(PaLM 기반)를 대체합니다.

Gemini-1 [135]: MMLU 벤치마크에서 인간 수준의 능력을 처음으로 달성한 자동 회귀 모델.

Gemini-1.5 [136]: MoE 아키텍처를 갖춘 다중 모달 LLM은 Gemini-1의 발견을 바탕으로 구축되었습니다. 이 모델은 2M의 컨텍스트 윈도우를 가지고 있으며 최대 10M 토큰에 대한 정보를 추론할 수 있습니다. 이렇게 큰 컨텍스트 윈도우는 이전에는 달성된 적이 없으며 성능 향상에 큰 영향을 미치는 것으로 나타났습니다. Nemotron-4 340B [137]: 98%의 합성 데이터와 2%의 수동으로 주석이 달린 데이터로 정렬된 디코더 전용 모델입니다. 대량의 합성 데이터를 활용하면 모델 성능이 크게 향상됩니다. 논문에서는 모델 사전 훈련의 후반 단계에서 이전에 본 데이터의 더 작은 하위 집합과 함께 정렬 데이터를 도입하여 사전 훈련 단계에서 최종 훈련 단계로의 원활한 전환을 가능하게 하는 것을 제안했습니다. 더 나은 지시 따르기 모델을 훈련하기 위해 더 약한 모델을 반복적으로 더 강한 모델로 훈련합니다. 더 약한 지시 조정 모델이 생성한 합성 데이터는 기본 모델을 훈련하는 데 사용되며, 이후 감독 세밀 조정을 통해 더 약한 모델을 능가합니다.

DeepSeek [138]: DeepSeek는 LLM의 스케일링 법칙을 자세히 연구하여 최적의 비임베딩 모델 크기와 훈련 데이터를 결정합니다. 실험은 1e17에서 3e20까지의 8개의 예산에 대해 수행되었습니다. 각 컴퓨터 예산은 열 개의 서로 다른 모델/데이터 규모에 대해 테스트되었습니다. 배치 크기와 학습률 또한 주어진 컴퓨터 예산에 맞게 조정되었으며, 배치 크기는 증가된 컴퓨터 예산에 따라 증가하고 학습률은 감소해야 함을 발견했습니다. 다음은 최적의 배치 크기(B), 학습률(η), 모델 크기(M) 및 데이터(D)에 대한 방정식입니다:

$$B_{opt} = 0.2920.C0.3271$$

$$\eta_{opt} = 0.3118.C-0.1250$$

$$M_{opt} = M_{base}.Ca \quad (5)$$

$$D_{opt} = D_{base}.Cb$$

$$M_{base} = 0.1715, D_{base} = 5.8316, a = 0.5243, b = 0.4757$$

DeepSeek-v2 [139]: MoE 모델로, 키-값(KV) 캐시를 잠재 벡터로 압축하여 추론 비용을 줄이는 다중 헤드 잠재 주의(Multi-Head Latent Attention, MLA)를 도입합니다. MLA는 다중 헤드 주의(Multi-Head Attention, MHA) 및 그룹화 쿼리 주의(Grouped Query Attention, GQA), 다중 쿼리 주의(Multi-Query Attention, MQA)와 같은 다른 효율적인 주의 메커니즘보다 더 나은 성능을 달성합니다. MLA 덕분에 DeepSeek-v2는 DeepSeek [138]에 비해 5.76배 더 빠른 추론 처리량을 달성합니다.

3.1.2. 코딩

CodeGen [140]: CodeGen은 PaLM [15]과 유사한 아키텍처를 가지고 있습니다. 즉, 병렬 attention, MLP 레이어, 그리고 RoPE 임베딩을 포함합니다. 이 모델은 자연어와 프로그래밍 언어 데이터에 대해 순차적으로 훈련됩니다(첫 번째 데이터셋에서 훈련한 후, 두 번째 데이터셋에서 훈련하는 방식으로) 다음 데이터셋에서 훈련됩니다.

1) PILE, 2) BIGQUERY, 3) BIGPYTHON. CodeGen은 코드를 합성하기 위해 단단계 접근 방식을 제안했습니다. 그 목적은 이전 프롬프트와 생성된 코드를 입력으로 받아 다음 코드 시퀀스를 생성하기 위한 다음 프롬프트가 주어지는 긴 시퀀스의 생성을 단순화하는 것입니다. CodeGen은 단단계 프로그램 합성을 평가하기 위해 Multi-Turn Programming Benchmark (MTPB)를 오픈소스합니다.

Codex [141]: 이 LLM은 문서 문자열에서 코드를 생성하기 위해 공개 Python Github 저장소의 하위 집합으로 교육받았습니다. 컴퓨터 프로그래밍은 종종 요구 사항을 충족하기 전에 프로그램이 디버깅되고 업데이트되는 반복적인 과정입니다. 비슷하게, Codex는 주어진 설명에 대해 반복 샘플링을 통해 프로그램의 100버전을 생성하여 단위 테스트를 통과하는 문제의 77.5%에 대해 작동하는 솔루션을 제공합니다. 그 강력한 버전은 Github Copilot2를 구동합니다.

AlphaCode [142]: 300M에서 41B 파라미터에 이르는 대형 언어 모델 세트, 경쟁 수준의 코드 생성 작업을 위해 설계되었습니다. 다중 쿼리 주의(multi-query attention) [143]를 사용하여 메모리와 캐시 비용을 줄입니다. 경쟁 프로그래밍 문제는 깊은 추론과 복잡한 자연어 알고리즘에 대한 이해를 요구하기 때문에, AlphaCode 모델은 인기 있는 언어로 필터링된 GitHub 코드를 기반으로 사전 학습된 후 CodeContests라는 새로운 경쟁 프로그래밍 데이터셋에서 미세 조정됩니다. CodeContests 데이터셋은 주로 Codeforces 플랫폼에서 수집된 문제, 해결책, 테스트 케이스로 구성됩니다. 사전 학습은 표준 언어 모델링 목표를 사용하며, GOLD [144]와 템퍼링 [145]이 CodeContests 데이터에 대한 미세 조정의 훈련 목표로 작용합니다. AlphaCode의 성능을 평가하기 위해 Codeforces 플랫폼에서 시뮬레이션된 프로그래밍 대회가 개최되며, 전반적으로 AlphaCode는 5000명 이상의 경쟁자 중 상위 54.3%에 랭크되며, Codeforces 등급은 최근 참여 사용자 중 상위 28%에 해당합니다.

CodeT5+ [34]: CodeT5+는 CodeT5 [146]를 기반으로 하며, 얇은 인코더와 깊은 디코더로 구성되어 있고, 여러 단계에서 훈련되었습니다. 처음에는 단일 모드 데이터(코드)로 훈련되었고, 이후에는 이모드 데이터(텍스트-코드 쌍)로 훈련되었습니다. 각 훈련 단계는 서로 다른 훈련 목표를 가지고 있으며, 작업에 따라 다른 모델 블록인 인코더, 디코더 또는 둘 다를 활성화합니다. 단일 모드 사전 훈련에는 스펠 디노이징과 CLM 목표가 포함되며, 이모드 사전 훈련 목표는 대조 학습, 일치 및 텍스트-코드 쌍에 대한 CLM을 포함합니다. CodeT5+는 작업 모드를 활성화하기 위해 텍스트와 함께 특별한 토큰을 추가합니다. 예를 들어, 대조 손실을 위한 [CLS], 텍스트-코드 매칭을 위한 [Match] 등이 있습니다.

StarCoder [147]: SantaCoder 아키텍처를 가진 디코더 전용 모델로, Flash attention을 사용하여 컨텍스트 길이를 8k로 확장합니다. StarCoder는 이름을 필터링하기 위해 인코더를 훈련합니다.

훈련 데이터에서 이메일 및 기타 개인 데이터를 추출합니다. 이의 미세 조정된 변형은 HumanEval 및 MBPP 벤치마크에서 PaLM, LLaMA, LAMDA보다 뛰어난 성능을 보입니다.

3.1.3. 과학적 지식

Galactica [148]: 4,800만 개의 논문, 교과서, 강의 노트, 수백만 개의 화학 물과 단백질, 과학 웹사이트, 백과사전 등을 포함한 방대한 curated corpus의 인류 과학 지식이 metaseq library3를 사용하여 학습되며, 이는 PyTorch와 fairseq [149]를 기반으로 합니다. 이 모델은 < work > 토큰으로 추론 데이터셋을 감싸 모델에 단계별 추론 맥락을 제공하며, 이는 추론 과제에서 성능을 개선하는 것으로 나타났습니다.

3.1.4. 대화

LaMDA [150]: 디코더 전용 모델로, 공개 대화 데이터, 공개 대화 발화, 그리고 공개 웹 문서로 사전 훈련되었으며, 사전 훈련 데이터의 90% 이상이 영어로 되어 있습니다. LaMDA는 품질, 안전성 및 근거를 가진 응답을 생성하는 것을 목표로 훈련됩니다. 이를 달성하기 위해 모델의 안전성과 품질 측면을 향상시키기 위해 판별적 및 생성적 미세 조정 기술이 통합됩니다. 그 결과, LaMDA 모델은 다양한 작업을 수행하는 일반 언어 모델로 활용될 수 있습니다.

3.1.5. 금융

BloombergGPT [151]: 재무(블룸버그 아카이브의 “FINPILE”)와 일반 목적 데이터셋을 사용하여 훈련된 비인과적 디코더 모델. 모델의 구조는 BLOOM [13] 및 OPT [14]와 유사하다. 이 모델은 접근 방식 [113]을 사용하여 모델의 다양한 블록에 50B 파라미터를 할당한다. 효과적인 훈련을 위해 BloombergGPT는 최대 시퀀스 길이를 사용하기 위해 문서를 <|endoftext|>와 함께 패킹하고, 1024에서 2048까지 시작하는 워업 배치 크기를 사용하며, 훈련 중에 학습률을 여러 번 수동으로 감소시킨다.

Xuan Yuan 2.0 [152]: 일반 목적, 금융, 일반 목적 지침 및 금융 기관 데이터셋의 조합으로 교육된 BLOOM의 [13] 아키텍처를 가진 중국 금융 챗 모델입니다. Xuan Yuan 2.0은 재앙적 망각을 피하기 위해 사전 훈련과 미세 조정 단계를 결합하였습니다.

3.2. 미세 조정된 LLMs

사전 훈련된 LLM은 보지 못한 작업에 대한 뛰어난 일반화 능력을 가지고 있습니다. 그러나 일반적으로 다음 토큰 예측을 목표로 훈련되기 때문에 LLM은 사용자 의도를 따르는 데 제한된 능력을 가지며 비윤리적이거나 유독한, 혹은 부정확한 응답을 생성하기 쉬운 경향이 있습니다 [20]. 효과적으로 활용하기 위해 LLM은 지침을 따르도록 미세 조정되며 [16, 17, 97], 안전한 응답을 생성하게 됩니다 [20]. 이는 또한 제로샷, 퓨샷 및 크로스타스크 일반화를 증가시키며 [97, 16, 18], 최소한의 계산 증가, 예를 들어 PaLM 540B의 전체 사전 훈련의 0.2% 정도로 가능합니다 [16].

이번 섹션에서는 다양한 세밀하게 조정된 LLM과 효과적인 세밀 조정을 위한 전략을 검토합니다.

²<https://github.com/features/copilot> ³<https://codeforces.com/>

표 1: 사전 훈련된 대형 언어 모델의 주목할 만한 발견과 통찰.

모델들	발견 및 인사이트
T5	<ul style="list-style-type: none"> • 매개변수를 공유하지 않을 때, 매개변수를 공유하는 인코더와 디코더는 동일하게 작동한다. • 파인튜닝 모델 레이어(어댑터 레이어)는 기존의 분류 레이어만 훈련하는 방법보다 더 효과적이다.
GPT-3	<ul style="list-style-type: none"> • LLM의 몇 번 학습한 성능은 제로 샷보다 더 우수하여 LLM이 메타 학습자임을 시사한다.
mT5	<ul style="list-style-type: none"> • 대규모 다국어 모델은 다운스트림 작업에서 단일 언어 모델과 동등한 성능을 보입니다. 그러나 작은 다국어 모델은 성능이 떨어집니다.
PanGu-α	<ul style="list-style-type: none"> • LLM은 몇 가지 예시로도 뛰어난 능력을 보여줍니다
CPM-2	<ul style="list-style-type: none"> • 프롬프트 파인튜닝은 전체 모델 파인튜닝에 필적하는 성능을 달성하면서 매우 적은 수의 파라미터만 업데이트하는 것을 요구합니다. • 프롬프트 파인튜닝은 전체 모델 파인튜닝에 비해 수렴하는 데 더 많은 시간이 걸린다. • 문장 사이에 prompt tokens를 삽입하면 모델이 문장 간 관계와 긴 시퀀스를 이해하는 데 도움이 될 수 있다. • 분석에서 CPM-2는 프롬프트가 모델을 위한 제공자(추가 맥락) 및 집계자(입력 텍스트와 정보를 집계)로 작용한다고 발견했다.
ERNIE 3.0	<ul style="list-style-type: none"> • 보편적인 표현 모듈과 작업별 표현 모듈이 포함된 모듈형 LLM 아키텍처는 미세 조정 단계에서 도움을 줍니다. • 특정 작업에 맞춘 표현 네트워크의 매개변수를 미세 조정 단계에서 최적화하는 것은 강력한 사전 훈련 모델을 활용하는 효율적인 방법입니다.
쥐라기-1	<ul style="list-style-type: none"> • LLM의 성능은 네트워크 크기와 밀접한 관련이 있다. • 실행 성능을 개선하기 위해 더 많은 작업을 순차적으로 (깊이) 수행하기 보다는 병렬로 (폭) 수행할 수 있습니다. • 같은 문맥 길이에서 더 많은 텍스트를 효율적으로 나타내고 적합하게 하기 위해, 모델은 단어 경계에 제한을 두지 않고 SentencePiece 토크나이저를 훈련하기 위해 더 큰 어휘를 사용합니다. 이는 few-shot learning 작업에서도 추가적인 이점을 제공합니다.
하이퍼클로바	<ul style="list-style-type: none"> • 프롬프트 기반 조정을 통해 모델의 성능을 개선할 수 있으며, 입력의 역방향 경량이 접근 가능한 경우 최첨단 모델의 성능을 종종 능가할 수 있다.
위안 1.0	<ul style="list-style-type: none"> • 사전 학습 및 미세 조정 사례에서 뛰어난 모델 아키텍처는 제로샷 및 퓨샷 학습에서 대조적인 행동을 보일 수 있다.
고퍼	<ul style="list-style-type: none"> • 상대 인코딩은 모델이 훈련보다 더 긴 시퀀스를 평가할 수 있게 해줍니다.
ERNIE 3.0 Titan	<ul style="list-style-type: none"> • 실제 텍스트와 생성된 텍스트를 구별하기 위한 추가적인 자기 지도적 적대적 손실이 ERNIE 3.0과 비교하여 모델 성능을 향상시킵니다. • 병렬 주의 메커니즘 + FF 레이어는 연속 레이어와 동일한 성능으로 훈련 속도를 15% 향상시킵니다.
GPT-NeoX-20B	<ul style="list-style-type: none"> • Residuals 전에 [153]의 방식을 사용하여 feed-forward 출력 레이어를 초기화하면 깊이와 너비가 증가함에 따라 활성화가 커지는 것을 방지할 수 있다. • Pile에 대한 훈련이 다섯 번의 시도에서 GPT-3보다 더 뛰어난

다음 페이지에 계속됩니다.

모델들	결과 및 통찰
OPT	<ul style="list-style-type: none"> 손실이 발산할 경우, 더 낮은 학습률로 이전 체크포인트에서 훈련을 재시작합니다. 모델은 반복적인 텍스트를 생성하고 루프에 갇히기 쉬운 경향이 있다.
갤럭시카	<ul style="list-style-type: none"> Galactica의 성능은 검증 세트, 도메인 내 및 도메인 외 벤치마크 전반에 걸쳐 계속해서 개선되었으며, 이는 기존 LLM 연구보다 우수한 여러 번의 코퍼스 반복에도 불구하고 나타났습니다. 작업 기억 토큰 접근법은 수학적 MMLU 및 MATH 벤치마크에서 기존 방법들에 비해 강력한 성능을 달성할 수 있습니다. 그리고 PubMedQA(77.6%) 및 MedMCQA dev(52.9%)와 같은 여러 하위 작업에서 새로운 최첨단 결과를 기록합니다.
GLaM	<ul style="list-style-type: none"> 모델 용량은 각 트랜스포머 층의 피드 포워드 레이어를 혼합 전문가(mixture-of-experts, MoE)로 교체함으로써 감소된 연산으로 유지될 수 있다. 필터링된 데이터로 훈련된 모델은 NLG와 NLU 작업 모두에서 consistently 더 나은 성능을 보이며, 여기서 필터링의 효과는 전층 작업에서 더 두드러진다. 필터링된 사전 훈련 말뭉치는 LLM의 생성 능력에 중요한 역할을 하며, 특히 다운스트림 작업에 있어 더욱 그렇습니다. GLaM MoE 모델의 확장은 MoE 레이어에서 전문가의 크기나 수를 늘림으로써 이루어질 수 있습니다. 고정된 계산 예산이 주어졌을 때, 더 많은 전문가가 더 나은 성능에 기여합니다.
LaMDA	<ul style="list-style-type: none"> 모델은 다양한 외부 정보 자원과 도구를 호출하는 방법을 학습하도록 세밀하게 조정될 수 있습니다. 더 높은 효과성과 효율성을 위해 트랜스포머 모델은 얇은 인코더와 깊은 디코더로 비대칭적으로 구성될 수 있다.
알파코드	<p>더 나은 성능을 달성하기 위해서는 대규모 업샘플링을 수행한 후 샘플을 필터링하고 클러스터링하여 compact set으로 만드는 전략을 사용하는 것이 필요하다.</p> <ul style="list-style-type: none"> 대규모 샘플링을 용이하게 하기 위해 설계된 새로운 샘플링 효율적인 변환기 아키텍처의 활용이 중요하다. 문제 설명을 간소화하면 모델의 성능을 효과적으로 향상시킬 수 있다.
친칠라	<ul style="list-style-type: none"> 모델 크기와 훈련 토큰 수는 비례적으로 조정되어야 합니다: 모델 크기가 두 배가 될 때마다 훈련 토큰 수 역시 두 배가 되어야 합니다. 영어 중심 모델은 비영어 모델에 비해 영어로 번역할 때 더 나은 번역 결과를 낳는다. 일반화된 모델은 전문화된 소형 모델들과 동등한 성능을 발휘할 수 있다.
PaLM	<ul style="list-style-type: none"> 더 큰 모델은 훈련 데이터 기억의 비율이 더 높다. 540B 규모에서도 성능이 아직 포화 상태에 이르지 않았으므로, 더 큰 모델이 더 나은 성능을 발휘할 가능성이 큼니다.
AlexaTM	<ul style="list-style-type: none"> Encoder-decoder 아키텍처는 decoder-only보다 맥락에 대한 양방향 주의를 고려할 때 LLM을 훈련하는 데 더 적합하다. 인과 언어 모델링(Causal Language Modeling, CLM) 과제를 추가하면 모델이 효율적인 맥락 내 학습을 통해 이익을 얻을 수 있음 각 Transformer 레이어의 시작에 레이어 정규화를 배치하는 것은 훈련 안정성을 향상시킵니다.

다음 페이지에 계속된 표

모델들	발견 및 통찰
U-PaLM	<ul style="list-style-type: none"> • 다양한 잡음 제거기를 혼합하여 훈련하면 PaLM을 추가로 몇 개의 FLOPs로 훈련했을 때보다 더 좋은 성능을 발휘한다. • 다양한 디노이저를 혼합하여 훈련하면 인필링 능력과 개방형 텍스트 생성의 다양성이 향상됩니다.
UL2	<ul style="list-style-type: none"> • 모드 전환 훈련은 하위 작업에서 더 나은 성능을 발휘할 수 있게 합니다. • CoT 프롬프트가 UL2에 대한 표준 프롬프트보다 우수하다.
GLM-130B	<ul style="list-style-type: none"> • 소량의 다중 작업 지시 데이터와 함께 하는 사전 훈련 데이터는 전체 모델 성능을 향상시킨다.
CodeGen	<ul style="list-style-type: none"> • 코드 생성에 대한 다단계 프롬프트는 사용자 의도를 더 잘 이해하고 코드 생성을 향상시킵니다.
LLaMA	<p>모델의 스케일링 시 지속적인 성능 향상이 관찰됩니다.</p> <ul style="list-style-type: none"> • 더 작은 모델은 더 많은 훈련 데이터와 컴퓨팅 시간을 통해 좋은 성능을 발휘할 수 있다.
PanGu-Σ	<ul style="list-style-type: none"> • 희소 모델은 낮은 계산 비용으로 대규모 모델의 이점을 제공합니다. <p>무작위 경로 전문가는 재앙적 망각 효과를 줄이며, 이는 지속적인 학습에 필수적입니다.</p> <ul style="list-style-type: none"> • 랜덤 라우팅 전문가를 통해 배포 시 도메인 특정 하위 모델을 추출할 수 있으며, 이는 비용 효율적이면서도 원본과 유사한 성능을 유지합니다.
BloombergGPT	<ul style="list-style-type: none"> • 일반 목적 데이터와 작업 특정 데이터로의 사전 훈련은 다른 모델 능력에 해를 끼치지 않으면서 작업 성능을 향상시킨다.
XuanYuan 2.0	<ul style="list-style-type: none"> • 단일 훈련에서 사전 훈련과 미세 조정 단계를 결합하는 것은 재앙적인 잊음을 피할 수 있다.
CodeT5+	<ul style="list-style-type: none"> • Causal LM은 인코더-디코더 아키텍처에서 모델의 생성 능력에 매우 중요하다. • span corruption, Causal LM, matching 등과 같은 여러 훈련 목표는 상호 보완되어 성능을 향상시킵니다.
스타코더	<ul style="list-style-type: none"> • Anthropic의 HHH 프롬프트는 모델이 파인 튜닝 없이 지침을 따르게 합니다.
LLaMA-2	<ul style="list-style-type: none"> • 필터링되지 않은 데이터로 훈련된 모델은 더 독성이 강하지만 파인튜닝 후 하위 작업에서 더 나은 성능을 발휘할 수 있습니다. • 필터링되지 않은 데이터로 훈련된 모델은 안전 정렬을 위해 더 적은 샘플을 필요로 합니다.
PaLM-2	<ul style="list-style-type: none"> • 데이터 품질은 더 나은 모델을 훈련하는 데 중요하다. • 모델과 데이터 크기는 1:1 비율로 조정되어야 합니다. • 더 작은 모델이 더 큰 반복을 위해 훈련된 경우, 더 큰 모델보다 성능이 우수하다.
LLaMA-3/3.1	<ul style="list-style-type: none"> • 배치 크기를 점진적으로 증가시키면 손실이 급증하지 않으면서 훈련이 안정화됩니다. • 최종 훈련 단계에서 고품질 데이터는 모델 성능을 향상시킵니다. • 모델의 컨텍스트 길이 창을 단계적으로 늘리면 다양한 시퀀스 길이에 더 잘 적응할 수 있습니다.
Nemotron-40B	<ul style="list-style-type: none"> • 이전에 정렬된 모델에서 생성된 데이터를 활용하여 합성 데이터에 대해 반복적으로 정렬된 모델이 경쟁력 있는 성능을 달성합니다.
DeepSeek	<ul style="list-style-type: none"> • 배치 크기는 계산 예산이 증가함에 따라 증가해야 하며, 학습률은 감소해야 합니다.
DeepSeek-v2	<ul style="list-style-type: none"> • 멀티 헤드 잠재 주의(Multi-head latent attention, MLA)는 멀티 헤드 주의(Multi-head attention, MHA)보다 더 나은 성능을 보이며, 훨씬 더 작은 KV 캐시를 요구하므로 데이터 생성 속도가 더 빠릅니다.

표 2: 교육 최적화된 대형 언어 모델에 대한 주요 통찰과 발견.

모델들	결과 및 통찰
T0	<ul style="list-style-type: none"> 다중 작업 프롬프트는 제로샷 일반화를 가능하게 하고 기준선보다 우수한 성능을 보입니다. 데이터셋 작업당 단 한 번의 프롬프트만으로도 성능이 향상될 수 있다.
WebGPT	<ul style="list-style-type: none"> 모델이 관련 정보를 효과적으로 필터링하고 활용할 수 있도록 하기 위해, 인간 라벨러는 검색된 문서의 유용성에 대한 질문에 답하는 데 중요한 역할을 한다. 세밀하게 조정된 언어 모델을 텍스트 기반 웹 브라우징 환경과 상호작용하게 하면 모방 학습과 강화 학습을 통해 엔드 투 엔드 검색 및 합성을 개선할 수 있습니다. 참조가 포함된 답변 생성은 라벨러들이 답변의 사실 정확성을 쉽게 판단할 수 있게 도와줄 수 있다.
Tk-INSTRUCT	<ul style="list-style-type: none"> 지침 조정은 보지 못한 작업의 강력한 일반화를 이끈다. 더 많은 작업이 일반화를 개선하는 반면, 단순히 작업 인스턴스를 늘리는 것은 도움이 되지 않는다. 감독된 훈련 모델이 일반화된 모델보다 더 낫다. 지침과 예시로 사전 훈련된 모델은 다양한 유형의 입력에 대해 잘 작동한다.
mT0와 BLOOMZ	<ul style="list-style-type: none"> Instruction tuning은 이전에 본 적 없는 작업에 대한 제로샷 일반화를 가능하게 합니다. 다국어 훈련은 영어와 비영어 모두에 대해 더욱 향상된 제로샷 일반화를 이끌어냅니다. 기계 번역된 프롬프트에 대한 훈련은 비영어 프롬프트가 포함된 보류된 작업의 성능을 향상시킵니다. 다국어 사전 훈련된 언어 모델에 대한 영어 전용 파인 튜닝만으로도 다른 사전 훈련된 언어 작업에 일반화할 수 있다.
OPT-IML	<p>여러 작업 예제로 배치를 만드는 것은 더 나은 성능을 위해 중요하다.</p> <ul style="list-style-type: none"> 단순히 비례 샘플링만으로는 충분하지 않으며, 더 나은 일반화/성능을 위해 훈련 데이터셋도 비례해야 한다. 완전히 검증된 작업과 부분적으로 감독된 작업의 성능은 작업이나 범주를 확대함으로써 향상되지만, 완전 감독된 작업에는 아무런 효과가 없다. 소량, 즉 사전 훈련 데이터의 5%를 파인 튜닝하는 동안 포함하는 것이 효과적이다. 1%의 추론 데이터만으로 성능이 향상되며, 더 많은 데이터는 성능을 저하시킵니다. 대화 데이터 추가는 성능을 저하시킨다.
스패로우	<ul style="list-style-type: none"> 레이블러의 판단과 잘 정의된 정렬 규칙이 모델이 더 나은 응답을 생성하는 데 도움을 줍니다. 좋은 대화 목표는 에이전트와 평가자를 위한 구체적인 자연어 규칙으로 세분화될 수 있다. 강화 학습(RL)과 재정렬의 조합은 선호 승률과 적대적 탐색에 대한 회복력 측면에서 최적의 성능을 발휘합니다.
플란	<ul style="list-style-type: none"> CoT로 파인튜닝하면 보류된 작업에서 성능이 향상됩니다. CoT 데이터와 함께 미세 조정하는 것은 추론 능력을 향상시킨다. CoT 튜닝은 제로샷 추론을 향상시킵니다. 작업이 많아질수록 성과가 향상됩니다. Instruction fine-tuning은 사전 학습된 모델에 대해 도전적인 사용성을 개선합니다. instruction tuning을 통한 모델 성능 개선은 계산 효율적입니다. 멀티태스킹 프롬프트는 LLM의 제로샷 일반화 능력을 가능하게 합니다.
WizardCoder	<ul style="list-style-type: none"> 재작성된 지침 조정 데이터를 복합 세트로 파인튜닝하면 성능이 향상됩니다.
LLaMA-2-Chat	<ul style="list-style-type: none"> 모델은 안전한 시연에 대한 미세 조정을 통해 안전한 응답을 작성하는 법을 배우고, 추가적인 RLHF 단계가 모델의 안전성을 더욱 향상시키고 탈옥 공격에 덜 취약하게 만듭니다.
리마	<ul style="list-style-type: none"> 품질이 낮은 데이터도 세밀하게 조정된 모델의 일반화에 충분하다.

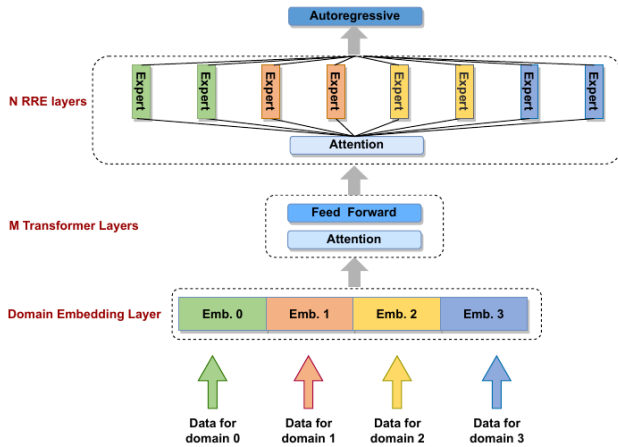


그림 10: 이 예시는 [92]에서 출처한 이미지에 나타난 PanGu-X architecture를 설명합니다.

3.2.1. 수동으로 생성된 데이터셋을 활용한 지시 튜닝

문헌에서는 다양한 설계 선택을 가진 수많은 수작업 지침 조정 데이터셋이 LLM을 지침 조정하기 위해 제안되고 있다. 세밀하게 조정된 LLM의 성능은 데이터셋, 지침 다양성, 프롬프트 템플릿, 모델 크기, 그리고 훈련 목표와 같은 여러 요인에 따라 달라진다. 이를 염두에 두고, 수동으로 생성된 데이터셋을 사용하여 다양한 세밀하게 조정된 모델들이 문헌에서 등장하고 있다.

모델 T0 [17]와 mT0(다국어) [154]는 기존 데이터셋을 프롬프트 데이터셋으로 변환하는 템플릿을 사용합니다. 이들은 제로샷 및 홀드아웃 작업에서 일반화에 대한 개선을 보여주었습니다. Tk-Instruct [18]는 T5 모델을 인컨텍스트 지침으로 파인튜닝하여 시험 시 인컨텍스트 지침을 제공할 때 보지 못한 작업에 대한 일반화를 연구했습니다. 이 모델은 크기는 작지만, 즉 11B 파라미터로 GPT-3의 175B보다 작음에도 불구하고 Instruct-GPT를 능가했습니다.

작업 및 프롬프트 설정 증가: 제로샷과 몇 샷 성능은 작업 수집 및 프롬프트 스타일을 확장함으로써 상당히 향상됩니다. OPT-IML과 Flan은 각각 2k 및 1.8k 작업 데이터셋을 구성했습니다. 작업 크기를 단순히 늘리는 것만으로는 충분하지 않으며, OPT-IML과 Flan은 데이터셋에 제로샷, 몇 샷, CoT와 같은 더 많은 프롬프트 설정을 추가합니다. 이어서, CoT Collection은 1.88M CoT 샘플에 대해 Flan-T5를 추가로 미세 조정합니다. 또 다른 방법은 T0, Flan 등과 함께 하는 기호적 작업을 사용하는 것입니다.

3.2.2. LLMs로 생성된 데이터셋을 활용한 Instruction-Tuning

지침 조정 데이터셋을 생성하려면 지침과 입력-출력 쌍을 신중하게 작성해야 하며, 이는 종종 인간에 의해 작성되고, 크기가 작고, 다양성이 부족합니다. 이를 극복하기 위해 self-instruct [19]는 이용 가능한 LLM에게 지침 조정 데이터셋을 생성하도록 유도하는 방법을 제안했습니다. Self-instruct는 수동으로 생성된 데이터셋인 SUPER-NATURALINSTRUCTIONS(1600개 이상의 작업이 포함된 데이터셋) [18]로 훈련된 모델들을 33% 초과하여 성능을 발휘했습니다. 이 방법은 175개의 작업, 1개의 지침, 작업당 1개의 샘플로 시작하여 새로운 지침(52,000개)과 인스턴스(82,000개의 입력-출력 쌍)를 반복적으로 생성합니다.

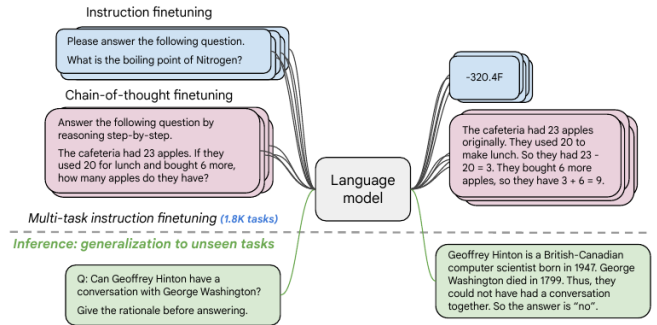


그림 11: 예시 이미지는 [16]에서 가져온 Flan 트레이닝 패러다임의 사례를 보여준다.

GPT-3 [6]. 이와는 달리, Dynosaur [155]는 Huggingface의 데이터셋 메타데이터를 사용하여 LLM이 여러 작업 지침 조정 데이터셋을 생성하도록 유도합니다. LLaMA 튜닝: 문헌의 다양한 모델이 GPT-3 [6] 또는 GPT-4 [157]로 생성된 데이터셋을 사용하여 LLaMA [156]를 지침 조정합니다. 이 중에서 Alpaca [158], Vicuna [159], LLaMA-GPT-4 [160]는 일반 목적의 세밀하게 조정된 모델 몇 가지로, Alpaca는 text-davinci-003에서 52k 샘플로 훈련되었고, Vicuna는 ShareGPT.com에서 70k 샘플로 훈련되었으며, LLaMA-GPT-4는 GPT-

4. Goat [161]는 ChatGPT로부터 데이터를 생성하여 산술 작업(100만 샘플)을 위해 LLaMA를 미세 조정하며, GPT-4, PaLM, BLOOM, OPT 등을 초월하며 LLaMA의 숫자에 대한 일관된 토큰화 덕분에 성공을 거두었다. HuaTuo [162]는 8,000개의 지침으로 생성된 QA 데이터셋으로 미세 조정된 의료 지식 모델이다.

복잡한 지시: Evol-Instruct [163, 164]는 LLM에게 주어진 지시를 더 복잡한 집합으로 변환하도록 유도합니다. 지시는 복잡한 문구로 재작성된 지시를 반복적으로 발전시키고 새로운 지시를 생성하면서 점진적으로 발전합니다. 이러한 자동화된 지시 생성 방식으로 WizardLM [163] (250k 지시에 대해 세밀하게 조정된 LLaMA)는 Vicuna와 Alpaca를 능가하며, WizardCoder [164] (StarCoder에 대해 세밀하게 조정된)는 Claude-Plus, Bard 등보다 우위에 있습니다.

3.2.3. 인간의 선호에 맞추기

인간의 선호를 LLM에 통합하는 것은 바람직하지 않은 행동을 완화하고 정확한 출력을 보장하는 데 상당한 이점을 제공합니다. 정렬에 대한 초기 작업으로는 InstructGPT [20]가 있으며, 이는 3단계 접근 방식을 사용하여 GPT-3를 정렬합니다. 즉, 지침 조정, 보상 모델링, 강화 학습(RL)을 통한 미세 조정입니다. 시연에 대해 감독된 미세 조정된 GPT-3가 응답을 생성하도록 질의되며, 이에 대해 인간 레이블러가 인간의 가치를 기준으로 순위를 매기고, 보상 모델이 순위가 매겨진 데이터로 훈련됩니다. 마지막으로, GPT-3는 보상 모델로부터 생성된 데이터에 보상을 적용하여 인접 정책 최적화(PPO)로 훈련됩니다. LLaMA 2-Chat [21]는 보상 모델링을 유용성과 안전 보상으로 나누고 PPO에 중독 샘플링을 추가하여 정렬을 개선합니다. LLaMA 2-Chat의 초기 네 가지 버전은 중독 샘플링으로 미세 조정되고, 그 후 PPO로 조정됩니다.

거부 샘플링의 장점.

지원 증거와의 정렬: 이 정렬 방식은 모델이 증거와 사실이 포함된 응답을 생성할 수 있게 하며, 환각을 줄이고 인간을 더 효과적으로 지원하여 모델의 출력에 대한 신뢰를 증가시킵니다. RLHF 훈련 방식과 유사하게, 보상 모델은 질문에 대한 답변에서 웹 인용이 포함된 생성된 응답을 순위 매기는 데 훈련되며, 이는 나중에 모델 훈련에 사용됩니다. GopherCite [165], WebGPT [166], 및 Sparrow [167]와 같은 방식입니다. Sparrow [167]의 순위 모델은 두 개의 가지로 나뉘며, 선호 보상과 규칙 보상이 있습니다. 여기서 인간 주석자가 모델을 적대적으로 조사하여 규칙을 위반하도록 합니다. 이 두 가지 보상이 함께 응답을 순위 매겨 RL로 훈련합니다.

SFT와 직접 정렬하기: RLHF 파이프라인의 PPO는 복잡하고 메모리를 많이 소모하며 불안정하여 여러 모델, 보상, 가치, 정책 및 참조 모델이 필요하다. [168, 169, 170]에서와 같이 감독된 세부 조정(SFT) 파이프라인에 최소한의 변경을 포함함으로써 이 복잡한 정렬 파이프라인을 피할 수 있으며, PPO와 유사한 또는 더 나은 성능을 발휘할 수 있다. 직접 선호 최적화(DPO) [168]는 인간이 선호하는 응답에 대해 모델을 직접 훈련시켜, 선호하는 응답과 선호하지 않는 응답의 가능성을 극대화하며, 샘플당 중요성 가중치를 부여한다. 보상 순위 조정 RAFT [169]는 보상 모델에 의해 순위가 매겨진 응답을 바탕으로 모델을 조정한다. 선호 순위 최적화(PRO) [171]과 RRHF [170]는 모델이 인간의 선호와 감독 손실에 따라 응답을 순위 매기도록 별점이 부과된다. 한편, 회고의 사슬(CoH) [172]는 보상 대신 언어로 모델에 피드백을 제공하여 좋은 응답과 나쁜 응답을 학습하도록 돕는다.

합성 피드백에 맞추기: LLM을 인간 피드백에 맞추는 것은 느리고 비용이 많이 듭니다. 문헌에서는 LLM이 쿼리에 대해 유용하고 정직하며 윤리적인 응답을 생성하도록 유도하고, 새로 생성된 데이터셋을 사용하여 미세 조정하는 반자동 프로세스를 제안합니다. Constitutional AI [173]는 RLHF에서 인간 피드백을 AI로 대체하며, 이를 AI 피드백에서의 RL(RLAIF)이라고 부릅니다. AlpacaFarm [174]는 LLMs API를 사용하여 인간 피드백을 모방하는 프롬프트를 설계합니다. Constitutional AI와 반대로, AlpacaFarm은 인간의 실수를 복제하기 위해 피드백에 노이즈를 주입합니다. Self-Align [98]은 ICL 예제를 사용하여 LLM을 유도하며, 응답이 유용하고 윤리적으로 간주되기 위해 포함해야 할 내용을 LLM에게 지시합니다. 동일한 LLM은 이후에 새로운 데이터셋으로 미세 조정됩니다.

프롬프트 정렬: LLM은 훈련 없이도 원하는 응답을 생성하기 위해 프롬프트로 조작될 수 있다 [175, 176]. [176]의 자기 수정 프롬프트는 지침과 CoT를 질문과 연결하여 모델이 실제 답변 전에 도덕적 안전성을 보장하는 전략에 따라 지침을 따르도록 안내한다. 이 전략은 생성된 응답에서 피해를 상당히 줄이는 것으로 나타났다.

레드팀/재개발/적대적 공격: LLM은 적대적 탐색을 통해 해로운 행동, 환각, 개인 정보 유출 및 기타 약점을 나타냅니다. 모델은 안전성에 맞춰 조정되어 있음에도 불구하고 해로운 응답을 생성하는 데 취약합니다. 레드팀은 LLM이 해로운 출력을 생성하도록 유도하는 불법적인 출력을 처리하기 위한 일반적인 접근 방식입니다.

레드팀을 통해 수집된 데이터셋은 안전성을 위해 모델을 미세 조정하는 데 사용됩니다. 레드팀은 주로 인간 주석자에 의존하지만, 또 다른 작업 [180]에서는 LLM을 레드팀하여 다른 LLM에 해로운 결과를 초래하는 프롬프트를 찾습니다.

3.2.4. 계속된 사전 훈련

미세 조정이 모델의 성능을 향상시키지만, 이전에 학습한 정보를 재앙적으로 잊게 만든다. 매 반복마다 미세 조정 데이터를 몇 개의 무작위로 선택된 사전 학습 샘플과 연결하면 네트워크의 망각을 피할 수 있다 [181, 152]. 이는 미세 조정 데이터가 적고 원래의 용량을 유지해야 하는 경우 LLM을 적응시키는 데에도 효과적이다. 프롬프트 기반 지속적인 사전 학습(PCP) [182]은 모델을 작업과 관련된 텍스트와 지침으로 훈련한 다음, 최종적으로 하류 작업을 위한 지침 조정 단계에서 모델을 조정한다.

3.2.5. 샘플 효율성

데이터를 미세 조정할 때 사용하는 데이터는 일반적으로 사전 훈련 데이터보다 수 배 작지만, 여전히 수용 가능한 성능을 위해서는 충분히 커야 하며, 비례에 맞는 컴퓨팅 자원이 필요하다. 기존 문헌 [183, 184]에서는 적은 데이터로 성능에 미치는 영향을 연구한 결과, 적은 데이터로 훈련된 모델이 더 많은 데이터로 훈련된 모델보다 성능이 향상될 수 있음을 발견하였다. [183]에서는 전체 다운로드 스트림 데이터의 25%만으로도 최첨단 성능을 달성할 수 있다고 한다. [184]에서는 전체 명령어 조정 데이터의 0.5%를 선택하여 모델 성능을 2% 개선하였으며, 이는 완전한 데이터 조정과 비교한 결과이다. 적은 것이 더 많은 정렬 (LIMA) [185]는 1000개의 신중하게 생성된 예제만을 사용하여 모델을 미세 조정하였으며, GPT-4와 유사한 성능을 달성하였다.

3.3. 컨텍스트 윈도우 증가

LLMs는 비싼 주의(attention)와 높은 메모리 요구사항으로 인해 제한된 컨텍스트 윈도우로 훈련됩니다. 제한된 시퀀스 길이로 훈련된 모델은 추론 시에 보지 못한 길이에 일반화할 수 없습니다 [186, 49]. 반면에, ALiBi [65] 위치 인코딩이 있는 LLM은 제로샷 길이 외삽을 수행할 수 있습니다. 그러나 ALiBi는 표현력이 떨어지고 [66] 여러 벤치마크에서 성능이 열등하며 [46], 많은 LLM은 제로샷 외삽을 수행할 수 없는 RoPE 위치 임베딩을 사용합니다. 더 긴 컨텍스트 길이는 긴 문서를 더 잘 이해하고, 인-컨텍스트 학습에 더 많은 샘플을 제공하며, 더 큰 추론 과정을 수행하는 등의 이점이 있습니다. 파인튜닝 중에 컨텍스트 길이를 확장하는 것은 느리고 비효율적이며 계산적으로 비용이 많이 듭니다 [49]. 따라서 연구자들은 아래에서 논의될 다양한 컨텍스트 윈도우 외삽 기법을 사용합니다.

위치 보간: [49]는 외삽하는 대신 사전 훈련된 컨텍스트 창 내에서 위치 인코딩을 보간하는 것이 더 효과적임을 보여줍니다. 이 연구는 성능을 원래 컨텍스트 크기와 비교했을 때 줄이지 않고도 더 큰 창에서 더 나은 결과를 얻기 위해 1000단계의 미세 조정만으로 충분하다는 것을 입증합니다. Giraffe [46]는 RoPE에서 파워 스케일링을 사용하고, YaRN [47]은 NTK 인식 보간을 제안했습니다.

효율적인 주의 메커니즘: 밀집 전역 주의를 더 큰 컨텍스트 윈도우 LLM을 훈련하는 데 주요한 제약 중 하나입니다. 로컬, 희소, 그리고 팽창된 주의와 같은 효율적인 주의 변형을 사용하면 계산 비용이 크게 줄어듭니다. LongT5 [48]는 전이성 전역 주의(TGlobal)를 제안하며, 이는 로컬 및 전역 토큰(윈도우 토큰 평균화)에 주의를 적용합니다. 이 모델은 T5 [10]의 주의를 TGlobal 주의로 대체하고, 4098 시퀀스 길이에서 모델을 사전 훈련하며, 최대 16k에 이르는 더 큰 윈도우 크기에서 미세 조정하여 긴 입력에 대한 작업 성능을 향상시킵니다. 이는 TGlobal 주의의 외삽 능력을 단지 미세 조정만으로 보여줍니다. COLT5 [187]는 두 개의 브랜치를 사용하며, 하나는 경량 주의이고 다른 하나는 중량 주의 및 피드포워드 레이어로 구성됩니다. 모든 토큰은 경량 브랜치에서 처리되고, 중요한 토큰만 중량 브랜치로 라우팅됩니다. LongNet [188]은 표준 주의를 팽창된 주의로 대체하여 시퀀스 길이를 10억 토큰으로 확장합니다. LongLoRA [189]는 미세 조정 중 밀집 주의 비용을 줄이기 위해 사용되는 시프트-쇼트 주의를 제안합니다. 그러나 추론 중에는 모델이 밀집 주의를 사용하고 전체 주의 미세 조정과 유사한 성능을 달성합니다.

훈련 없이 외삽: LM-Infinite [186]과 병렬 컨텍스트 윈도우(PCW) [190]는 사전 훈련된 LLM을 사용하여 길이 외삽이 가능하다는 것을 보여줍니다. LM-Infinite는 원본 컨텍스트 윈도우 한계 내에서 적용된 Λ -shaped attention을 제안했습니다. 마찬가지로, PCW는 더 큰 입력을 사전 훈련된 컨텍스트 길이로 나누고 각 청크에 동일한 위치 인코딩을 적용합니다.

3.4. 증강 LLMs

LLMs는 입력과 연결된 예제에서 학습할 수 있으며, 이를 맥락 증강(context augmentation), 인맥 학습(in-context learning, ICL) 또는 몇 가지 촉구(few-shot prompting)라고 합니다. 이들은 몇 가지 촉구를 통해 보지 못한 작업에 대한 뛰어난 일반화를 보여주며, LLMs가 훈련 중 습득한 능력을 넘어서는 질문에 답할 수 있게 합니다 [6, 55]. 이러한 emergent abilities는 모델을 미세 조정 없이 조정할 수 있게 해주며, 이는 비용이 많이 드는 과정입니다. 이와 별개로, 환각(hallucination), 즉 부정확하거나 안전하지 않거나 사실적으로 틀린 응답을 생성하는 것은 LLMs에서 일반적이며, 이는 맥락 데이터를 증강함으로써 피할 수 있습니다. 사용자가 쿼리에서 인맥 샘플을 제공할 수 있는 반면 [54, 32], 여기서는 외부 저장소에 프로그래밍적으로 접근하는 방법을 특별히 언급하며, 이를 증강된 LLMs(augmented LLMs)라고 부릅니다.

문헌에서는 LLM을 보강하기 위한 다양한 외부 메모리 설계를 제안하고 있습니다: 장기 [191, 192, 193, 194], 단기 [195], 기호적 [196], 비기호적 [197, 198]. 메모리는 문서, 벡터 또는 데이터베이스와 같은 다양한 형식으로 유지될 수 있습니다. 몇몇 시스템은 여러 반복에 걸쳐 정보를 유지하기 위해 중간 메모리 표현을 유지하는 반면 [194, 192], 다른 시스템은 데이터 세트에서 중요한 정보를 추출하여 기억을 위해 저장합니다 [199]. 메모리 읽기 및 쓰기 작업은 LLM의 협력 여부에 관계없이 수행되며 [192, 200, 194, 201], [195]에서 피드백 신호로 작용합니다. 아래에서는 보강된 LLM의 다양한 유형에 대해 논의합니다.




그림 12: Retrieval Augmented LLMs의 흐름도. 검색자는 입력과 유사한 문맥을 추출하여 이를 간단한 언어로 또는 Fusion-in-Decoder (FiD)를 통해 인코딩하여 LLM에 전달합니다. 작업에 따라 검색과 생성이 여러 번 반복될 수 있습니다.

3.4.1. 회수 증강 LLMs

LLM은 제한된 메모리와 구식 정보를 가질 수 있으며, 이는 부정확한 응답으로 이어질 수 있습니다. 외부의 최신 저장소에서 관련 정보를 검색하면 LLM이 정확하게 답변하고 더 많은 정보를 활용할 수 있게 됩니다. 검색 보강을 통해 작은 모델도 큰 모델과 동등한 성능을 보일 수 있는 것으로 나타났습니다. 예를 들어, 11B 모델은 [25]에서 540B PaLM과 경쟁할 수 있고, 7.5B 모델은 [193]에서 280B Gopher와 경쟁할 수 있습니다. 검색 보강 언어 모델링(RALM)은 두 가지 주요 구성 요소를 가지고 있으며, 이는 그림 12에 나와 있습니다: 1) 검색기와 2) 언어 모델. RALM에서 검색기는 LLM 응답을 이끌어내는 중요한 역할을 하는데, 잘못된 정보는 LLM을 잘못된 행동으로 유도할 수 있습니다. 이는 정확한 정보를 검색하고 쿼리와 융합하여 더 나은 성능을 발휘할 수 있는 다양한 방법의 개발로 이어집니다.

제로샷 검색 보강: 이러한 유형의 보강은 원래 LLM 아키텍처와 가중치를 변경하지 않고 BM25 [202], 최근접 이웃 또는 Bert [7]와 같은 고정된 사전 훈련 모델을 검색기로 사용합니다. 검색된 정보는 응답 생성을 위해 모델에 입력으로 제공되며, 검색이 없는 LLM에 비해 성능을 개선하는 것으로 나타났습니다 [198, 203]. 일부 시나리오에서는 작업을 완료하기 위해 여러 번의 검색 반복이 필요합니다. 첫 번째 반복에서 생성된 출력은 유사한 문서를 가져오기 위해 검색기로 전달됩니다. 미래 지향적 능동 검색(FLARE) [197]는 처음에 응답을 생성하고, 응답에 신뢰도가 낮은 토큰이 포함되어 있을 경우 관련 문서를 검색하여 출력을 수정합니다. 유사하게, RepoCoder [204]는 코드 완성을 위해 코드 스니펫을 재귀적으로 가져옵니다.

Retrieval Augmentation을 통한 훈련: Retrieval augmentation generation (RAG)에서 실패를 줄이기 위해 연구자들은 검색기와 LLM을 검색 증강 파이프라인으로 훈련시키거나 미세 조정합니다. 우리는 아래에서 해당 파이프라인의 각각의 훈련 과정에 대한 초점을 바탕으로 문헌을 논의합니다.

훈련 LLM: 검색 강화 변환기(RETRO) [193]는 RAG 파이프라인으로 사전 훈련된 작은 LLM이 RAG 없이 훈련된 GPT-3와 같은 큰 LLM보다 성능이 우수하다는 것을 보여줍니다. RETRO는 MassiveText의 2조 개 토큰 하위 집합을 사용합니다.

데이터베이스. 검색 파이프라인은 입력 쿼리를 여러 하위 집합으로 나누고 각 하위 집합에 대해 데이터베이스에서 관련 청크를 검색하여 입력 중간 표현과 함께 인코딩하여 토큰을 생성한다. 이전 청크에 자동 회귀적으로 주의를 기울이기 위해 교차 청크 주의를 사용한다. RETRO에 대한 연구 [205]에 따르면 RAG 없이 사전 훈련된 모델이 RAG를 사용하여 미세 조정된 경우, RAG로 사전 훈련한 것에서 얻은 성능 향상이 결여된다.

훈련 리트리버: LLM이 생성한 응답의 품질은 맥락 내 예제에 크게 의존합니다. 따라서, [206, 207, 208, 209]는 정확한 몇 가지 샘플을 검색하도록 리트리버를 훈련시키면서 LLM은 생성을 위해 동결 상태를 유지합니다. 검색된 샘플은 리트리버를 대조 학습으로 훈련하기 위해 진실 데이터로 순위를 매깁니다 [206, 208]. RoBERTa는 ICL 샘플 검색을 위해 [207]에서 다운스트림 작업을 위해 훈련됩니다. REPLUG [209]는 동결된 LLM 생성 출력의 감독 신호로 리트리버를 훈련합니다. 리트리버와 LLM 훈련: [25, 210, 211]에서 리트리버와 모델을 동시에 훈련함으로써 추가적인 이점을 얻을 수 있다. 이 경우, 오류가 리트리버로 되돌아가 언어 모델과 리트리버 모두를 업데이트한다. 마스킹된 언어 모델링(MLM)은 일반적인 사전 훈련 목표 [25, 211]인 반면, 리트리벌 사전 훈련 변환기(RPT) [210]는 긴 텍스트 모델링을 위한 사전 훈련 목표로 문서 청크 예측을 사용했다.

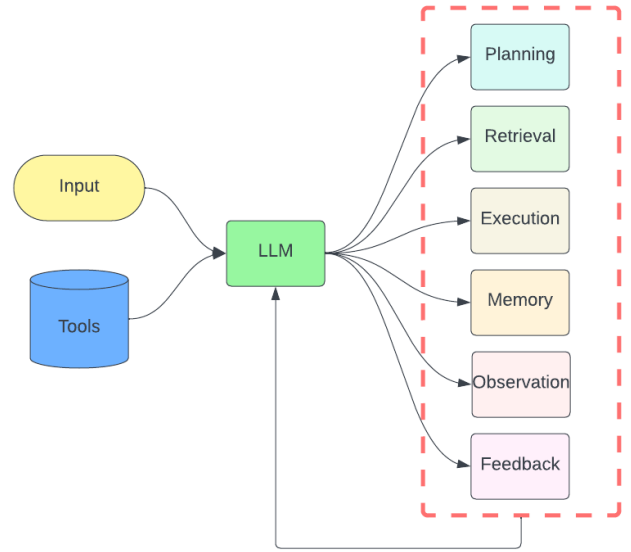


그림 13: 도구 보강 LLM의 기본 흐름 다이어그램. 입력과 사용 가능한 도구 세트들을 고려하여 모델은 작업을 완료하기 위한 계획을 생성한다. 도구 보강 LLM은 작업에 따라 리트리버, 도구 실행, 메모리 읽기-쓰기를 포함한 다양한 모듈을 반복적으로 활용한다.

인코딩된 컨텍스트 증강: 검색된 문서와 쿼리를 연결하는 것은 시퀀스 길이와 샘플 크기가 커짐에 따라 불가능해진다. 컨텍스트를 인코딩하고 이를 디코더와 결합(Fusion-in-Decoder)하여 크로스 어텐션을 사용하는 방식은 계산 비용을 크게 증가시키지 않으면서 더 많은 샘플을 증강할 수 있게 해준다 [212, 193, 210, 25].

웹 증강: 로컬에 저장된 메모리는 LLM 외부에 있지만 정보가 제한적입니다. 그러나 인터넷에는 정기적으로 업데이트되는 많은 정보가 있습니다. 정보를 로컬에 저장하는 대신, 다양한 방법이 웹 검색을 통해 쿼리 관련 컨텍스트를 검색하고 이를 LLM에 전달합니다 [213, 214, 166].

3.4.2. 도구 확장 LLMs

RAG는 쿼리에 대한 답변을 위해 LLM에 맥락을 제공하기 위해 검색기에 의존하는 반면, 도구 강화 LLM은 LLM의 추론 능력을 활용하여 작업을 하위 작업으로 나누고, 필요한 도구를 선택하며, 작업을 완료하기 위해 행동을 취함으로써 반복적으로 계획합니다 [215, 216, 217, 27]. 도구 강화 LLM의 일반적인 파이프라인은 그림 13에 나타나 있으며, 그림 13의 서로 다른 모듈은 작업 완료 시까지 루프에서 선택됩니다.

제로샷 도구 보강: LLM의 맥락 내 학습 및 추론 능력을 통해 이들은 훈련 없이 도구와 상호작용할 수 있다. 자동 추론 및 도구 사용(ART) [217]은 추론 단계와 외부 도구 호출을 시연하는 작업 라이브러리를 구축한다. 이는 유사한 작업 예제를 검색하고 LLM에 추론을 위한 맥락을 제공한다. 이와 별개로 [218]은 도구 문서만으로도 LLM이 시연 없이 도구를 사용하는 방법을 배울 수 있음을 보여준다. RestGPT [219]는 작업을 계획으로 분해함으로써 LLM과 RESTful API를 통합한다.

및 API 선택 단계. API 선택기는 작업에 적합한 API를 선택하고 실행 계획을 세우기 위해 API 문서를 이해합니다. ToolkenGPT [220]는 도구 임베딩을 다른 토큰 임베딩과 연결하여 도구를 토큰으로 사용합니다. 추론 중에 LLM은 도구 호출을 나타내는 도구 토큰을 생성하고, 텍스트 생성을 중단한 후 도구 실행 출력을 사용하여 다시 시작합니다.

도구 확장을 통한 훈련: LLM은 다양한 도구와 상호작용하도록 훈련되어, 제로샷 도구 확장의 한계를 극복하기 위한 계획 능력을 향상시킵니다 [221, 27, 222, 223]. Gorilla [221]는 API 문서에서 정보를 검색하여 LLaMA를 지시 튜닝합니다. 이는 API 문서에서 검색된 맥락 예시를 제공함으로써 GPT-4를 사용하는 self-instruct [19] 데이터 생성 파이프라인을 활용합니다. 도구 증강 언어 모델(TALM) [27]은 T5 [10]를 도구 사용을 위해 세밀하게 조정하며, 이는 도구 조작 작업을 반복적으로 완료하고 이를 훈련 세트에 포함하는 self-play 접근 방식을 사용합니다. ToolLLM [223]은 RapidAPI에서 16,000개의 API를 수집합니다. 이 목록에서 API를 샘플링하여 단일 도구 및 다중 도구 시나리오에서 instruction-tuning 데이터셋을 생성하는 데 ChatGPT를 사용합니다. 고품질 데이터셋을 위해 ToolLLM은 다양한 추론 및 계획으로 진리값을 생성하기 위해 깊이 우선 탐색 기반 결정 트리(DFSdT) 방법을 제안했습니다.

다중 모드 도구 증강: LLM의 조합적 추론 능력은 그들이 다중 모드 환경에서 도구를 조작할 수 있게 해줍니다 [215, 216, 224]. 그림 13에 나타난 파이프라인을 따르면, LLM은 일반적으로 다음과 같은 순서로 실행되는 계획을 개요합니다: 계획 → 도구 선택 → 실행 → 검사 → 생성, 사용자 쿼리에 응답하기 위해서입니다. 여기서 도구의 데이터베이스는 텍스트, 이미지 등 다양한 양식이 풍부합니다. 많은 다중 모드 도구 증강 시스템은 다중 모드 LLM을 사용하고 [31, 225, 224, 216], 다른 시스템은 단일 모드를 활용합니다.

LLMs와 다양한 모달리티 도구를 사용하여 다중 모달 쿼리를 해결하는 계획을 세우다 [226].

3.5. LLMs-Powered Agents

AI 에이전트는 계획, 의사 결정 및 복잡한 목표 달성을 위한 행동 수행이 가능한 자율적인 존재입니다. 초기에는 AI 에이전트가 규칙 기반으로 설계되어 제한된 작업을 수행하고, Clippy [227]나 Deep Blue [228]와 같은 한정된 기능만을 가지고 있었습니다. 이와 대비하여 LLMs의 동적인 상황에 반응하는 능력 덕분에 LLMs가 에이전트의 두뇌 역할을 하는 다양한 응용 프로그램에 통합될 수 있게 되었습니다. LLMs는 웹 에이전트 [166, 167], 코딩 에이전트 [229], 도구 에이전트 [27, 223], 구현된 에이전트 [26], 대화형 에이전트 [195] 등에 포함되어 최소한의 튜닝으로도 기능합니다. 아래에서는 LLMs 기반 자율 에이전트에 대한 연구를 요약합니다. 더 자세한 논의는 [230, 231]을 참조하시기 바랍니다.

LLMs가 자율 에이전트를 조정하는 역할을 합니다: LLMs는 자율 에이전트의 인지적 제어 장치입니다. 이들은 계획을 생성하고, 작업에 대해 추론하며, 작업을 완료하기 위해 메모리를 통합하고, 환경으로부터의 피드백에 따라 개요를 조정합니다. LLMs의 습득한 능력에 따라 많은 방법들이 에이전트의 성능을 향상시키기 위해 미세 조정, 더 나은 프롬프트 접근 방식을 제안하거나 다양한 모듈을 활용합니다. 자율 에이전트에서 사용되는 모듈과 전략에 대해서는 아래에서 간략히 논의합니다.

계획 및 추론: 복잡한 작업을 완료하려면 인간과 유사한 논리적 사고, 필요한 단계 계획, 현재와 미래의 방향에 대한 추론이 필요하다. 체인 오브 서 though ts [103], 트리 오브 thoughts [105], 그리고 자기 일관성 [104]과 같은 프롬프트 방법은 에이전트에 중심적인 역할을 하여 LLM이 행동을 추론하고 작업 완료를 위한 여러 경로 중에서 선택하도록 유도한다. LLM에 작업 설명과 일련의 행동이 제공되면, 그들은 어떠한 미세 조정 없이도 정확하게 계획 행동을 생성할 수 있다 [232]. 계획을 통한 추론(RAP) [233]은 재목적화된 LLM을 세계 모델로 통합하여 미래의 결과에 대해 추론하고 작업 완료를 위한 대체 경로를 탐색한다. Retroformer [234]는 회고적인 LLM을 사용하여 유용한 작업 단서를 제공함으로써 주요 LLM의 계획 및 추론 능력을 향상시킨다.

피드백: LLM은 개방형 루프 시스템에서 계획을 생성하고 에이전트가 이를 성공적으로 완료할 것이라고 가정합니다. 그러나 실제 상황은 실패와 환경으로부터의 다양한 반응으로 다릅니다. 작업을 올바르게 완료하기 위해 많은 방법이 LLM을 폐쇄형 루프에서 사용하며, 여기서 행동 반응은 피드백으로 LLM에 제공되어 필요에 따라 계획을 재평가하고 업데이트합니다 [235, 236, 237, 195]. 또 다른 연구 방향은 LLM을 보상 함수로 활용하여 인간 대신 강화 학습(RL) 정책을 훈련시키는 것입니다 [238]. 메모리: LLM은 프롬프트에서 제공된 맥락으로부터 학습할 수 있습니다. 내부 메모리에 추가하여 다양한 시스템이 외부 메모리를 사용하여 응답 기록을 저장합니다. Reflexion [195]은 이전 응답을 피드백으로 활용하여 미래의 의사 결정을 개선하기 위해 에피소드 메모리를 유지합니다. Retroformer [234]는 단기 기억을 활용하여 응답을 개선합니다 .

그리고 장기 기억에서 단기 기억은 최근의 반응을 포함하고, 장기 기억은 프롬프트에 반영하기 위해 요약된 실패한 시도를 보관합니다.

다중 에이전트 시스템: LLM은 사용자 정의 역할을 수행하고 특정 도메인 전문가처럼 행동할 수 있습니다. 다중 에이전트 시스템에서는 각 LLM에 고유한 역할이 할당되어 인간 행동을 시뮬레이션하고 다른 에이전트와 협력하여 복잡한 작업을 완료합니다 [229, 239].

물리적 환경의 LL

M: LLM은 지시를 따르는 데 능숙하지만, 물리적으로 기반한 작업에 활용하려면 적응이 필요합니다. 실제 세계에 대한 지식이 부족하기 때문입니다. 이로 인해 특정 물리적 상황에 대해 비논리적인 응답을 생성할 수 있습니다 [240, 26]. SayCan [240]은 LLM이 사용 가능한 저수준 작업 운영을 인식하도록 합니다. LLM(Say)은 작업을 완료하기 위한 고수준 계획을 수립하고 학습된 어포던스 함수를 통해 실제 세계에서 계획을 실행할 가능성을 탐색합니다(Can). SayCan은 언어 조건화된 어포던스 함수를 훈련하기 위해 강화 학습(RL)을 사용합니다. PaLM-E는 LLM이 센서에서 직접 입력을 받아 다중 모달 LLM을 훈련시켜 기반 작업을 해결할 수 있도록 합니다.

조작: 조작 분야에서 LLM은 로봇의 손재주와 적응력을 향상시키며, 물체 인식, 잡기, 협업과 같은 작업에서 뛰어난 성능을 발휘합니다. 그들은 시각적 및 공간 정보를 분석하여 물체와 상호작용하기 위한 가장 효과적인 접근 방식을 결정합니다.

네비게이션: LLMs는 로봇이 복잡한 환경을 정밀하게 그리고 적응력 있게 탐색하는 능력을 향상시킵니다 [242, 243, 244, 245]. 이들은 복잡한 환경 세부사항을 고려하여 로봇을 위한 실행 가능한 경로와 궤적을 생성합니다 [246]. 이 능력은 창고, 운송, 의료 시설, 주택과 같은 환경에서 정밀하고 동적으로 적응 가능한 네비게이션이 필요한 상황에서 매우 가치가 있습니다.

3.6. 효율적인 LLMs

LLM을 생산에 배포하는 것은 비용이 많이 듭니다. 성능을 유지하면서 운영 비용을 줄이는 것은 매력적인 연구 분야입니다. 이 섹션에서는 LLM의 효율성을 향상시키기 위해 제안된 접근법을 요약합니다.

3.6.1. 파라미터 효율적인 미세 조정

수십억 또는 수백억 개의 파라미터를 가진 LLM을 미세 조정하는 것은, GP T-3 (175B), BLOOM (176B), MT-NLG (540B) 등과 같이 계산 집약적이고 시간도 많이 소비됩니다. 전체 모델 미세 조정을 피하기 위해, 많은 파라미터 효율적 미세 조정 (PEFT) 기법 [40, 247, 41, 38, 39]이 비용을 줄이면서도 사용 가능한 모델 미세 조정 성능을 달성하려고 합니다. 전체 미세 조정 [248]과 비교했을 때, PEFT는 자원이 적은 환경에서 더 나은 성능을 발휘하고, 중간 자원 시나리오에서는 유사한 성능을 달성하며, 자원이 풍부한 경우에는 전체 미세 조정보다 성능이 떨어집니다. 다양한 PEFT 접근 방식에 대한 개요는 그림 14에 나와 있습니다.

어댑터 튜닝: 트랜스포머 블록 내에 몇 개의 학습 가능한 매개변수를 추가합니다. 어댑터 레이어는 특징 축소, 비선형성 및 축소 조정의 순서입니다 [106]. 어댑터 튜닝의 변형은 어댑터 레이어를 순차적으로 [106] 또는 병렬로 [38] 주입하고, 어댑터 혼합(AdaMix) [249]은

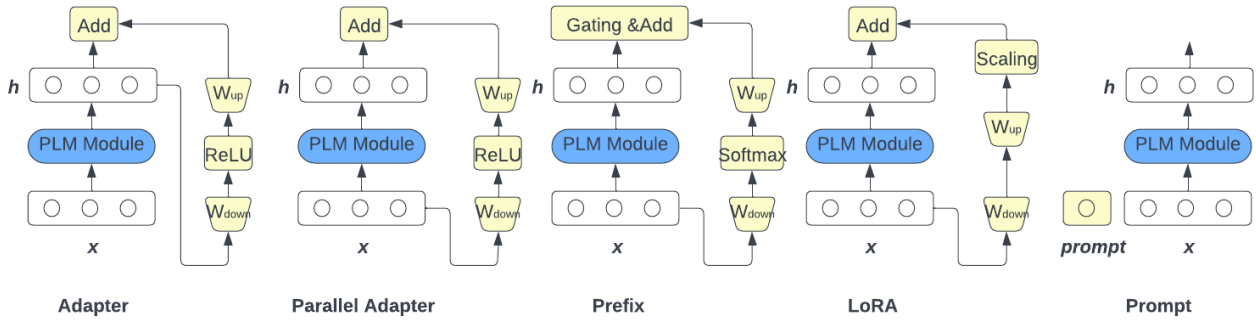


그림 14: 파라미터 효율적인 미세 조정 패러다임의 설명, 여기서 x는 입력이고 h는 숨겨진 상태입니다. 이 그림은 [38]의 제공입니다. 병렬 어댑터와 LoRA는 어댑터 조정 범주에 속합니다.

단일 레이어에서 여러 어댑터 모듈을 사용합니다. AdaMix는 입력 인스턴스를 여러 다운스케일 및 업스케일 모듈 중 하나로 무작위로 라우팅합니다. 어댑터의 혼합은 추가 지연을 피하기 위해 추론 시 평균화됩니다. Low-Rank Adaptation (LoRA) [250]은 원래 가중치를 동결하기 위해 저순위 분해 행렬을 학습합니다. 학습된 가중치는 추론을 위해 원래 가중치와 융합되어 지연을 피합니다.

프롬프트 튜닝: 프롬프트는 사전 훈련된 LLM을 다운스트림 작업에 적합하게 만드는 효과적인 방법입니다. 그러나 수동 프롬프트는 모델 예측의 불확실성을 초래하는데, 단어 하나의 변화가 성능을 떨어뜨립니다 [247]. 프롬프트 튜닝은 0.001%-3%의 추가 매개변수만 미세 조정함으로써 이 문제를 완화합니다 [251]. 이는 훈련 가능한 프롬프트 매개변수를 모델 임베딩과 결합합니다 [247, 40, 251]. 작업에 특화된 고정 이산 프롬프트는 입력 임베딩과 결합됩니다 [40]. 이산 프롬프트는 불안정을 초래하므로, P-Tuning [247]에서 프롬프트는 학습 가능한 매핑을 통해 인코딩되어 연속 프롬프트로 이름 붙여지며, 이는 이산 프롬프트와 함께 추가됩니다. 모델에서 프롬프트 인코더만 훈련 가능합니다. P-Tuning의 확장에서는 연속 프롬프트가 네트워크의 각 레이어와 결합됩니다 [251]. 점진적인 프롬프트 [252]는 재앙적인 망각을 피하고 이전에 학습된 지식을 전이하기 위해 훈련 가능한 프롬프트 임베딩을 이전에 고정된 작업 임베딩에 순차적으로 추가합니다. 프리픽스 튜닝: 프리픽스 튜닝 [41]에서는 훈련 가능한 작업 특화 프리픽스 벡터를 고정된 트랜스포머 레이어에 추가합니다. 프리픽스 벡터는 오른쪽의 컨텍스트 토큰에 의해 주의되는 가상 토큰입니다. 또한, 적응형 프리픽스 튜닝 [253]은 프리픽스와 실제 토큰의 정보를 제어하기 위한 게이팅 메커니즘을 적용합니다.

편향 조정: 소규모에서 중간 규모의 훈련 데이터에서 편향 함만 미세 조정하는 것이 BitFit [254]에서 효과적인 것으로 나타났습니다. 이 방법은 적은 훈련 데이터로 수행하는 작업에서 전체 미세 조정 성능을 달성하고, 훈련 데이터가 더 많을 때는 유사한 성능을 나타냅니다.

3.6.2. 양자화

LLMs는 추론을 위해 방대한 컴퓨팅과 메모리를 필요로 합니다. 175B 파라미터의 GPT-3 모델을 배포하려면 최소 다섯 개의 80GB A100 GPU와 350GB의 메모리가 필요합니다.

FP16 포맷 [44]. LLM을 배포하기 위한 이러한 엄격한 요구 사항은 작은 조직들이 이를 활용하기 어렵게 만듭니다. 모델 압축은 효과적인 솔루션이지만, 성능 저하라는 대가가 따르며, 특히 6B 이상의 대규모에서는 더 그렇습니다. 이러한 모델은 작은 모델에서는 존재하지 않는 매우 큰 크기의 이상치가 나타나 [255], LLM을 양자화하기 위해서는 도전적이고 전문적인 방법이 필요합니다 [44, 256].

훈련 후 양자화: 이 유형의 양자화에서는 최소한 또는 전혀 훈련이 필요하지 않으며, 모델 성능이 크게 저하되지 않습니다. LLM-8-bit [255]는 이상치 특성과 관련된 가중치에 대해 전체 정밀도 행렬 곱셈을 사용하고, 나머지 특성에 대해서는 8비트를 사용합니다. 낮은 정밀도의 곱셈 출력은 FP-16으로 변환되어 다른 출력과 연결됩니다. 양자화된 모델은 동질적인 단어 임베딩을 가지고 있으며, 이는 성능을 저하시킬 수 있습니다. 이를 해결하기 위해 토큰 수준 지식 증류가 [45]에서 사용되며, 각 모듈의 가중치 분포가 다르기 때문에 독립적인 양자화 스케일링 요소를 적용합니다. 특성 분포는 비대칭적이며 서로 다른 채널에서 나타납니다; 이상치 억제 [257]는 효과적인 양자화를 위해 채널별 활성화 분포를 이동시키고 스케일링합니다. SmoothQuant [44]는 활성화와 가중치를 INT8 형식으로 양자화하기 위해 활성화를 부드럽게 하고 양자화의 어려움을 가중치로 이전합니다. 이는 부드럽게 하는 요소의 역수와 가중치를 곱하여 몇 가지 이상치를 가중치에 도입하지만, 부드럽지 않은 활성화보다 정량화하기가 더 쉽습니다. OPTQ [256]는 최적의 뇌 압축(OBC) [258] 알고리즘을 사용하여 모델을 레이어별로 양자화하고 양자화 오류를 보상하기 위해 가중치를 업데이트합니다. 속도와 성능을 개선하기 위해 OPTQ는 가중치를 임의의 순서로 업데이트하고, 지연 업데이트를 사용하며, 더 나은 Cholesky 커널을 활용합니다. 이상치 인식 가중치 양자화(OWQ) [259]는 양자화를 위해 OPTQ 알고리즘을 사용하지만, 취약한 가중치에는 더 높은 정밀도를 부여하고, 다른 가중치에는 낮은 정밀도를 초래합니다.

양자화 인식 훈련: 성능 저하를 보완하기 위해, 양자화된 모델은 양자화 인식 훈련(QAT) [260, 261, 262]에서 미세 조정됩니다. Alpha Tuning은 이진 코딩 양자화(BCQ) [263]를 사용하여 모델을 양자화하고, 양자화 스케일링 요소만 미세 조정합니다. 이 접근 방식은 성능을 향상시킵니다.

사전 훈련된 모델의 파라미터 효율적인 미세 조정. 이와 유사하게, 파라미터 효율적이며 양자화 인식 적응(PEQA) [264]는 완전 연결 층의 정밀도를 줄이고 양자화 스케일링 파라미터만 미세 조정합니다. LLM-QAT [262]는 사전 훈련된 네트워크에서 훈련 데이터를 생성하고 지식 증류를 통해 양자화된 학생 모델을 훈련합니다. QLoRA [261]는 4비트 양자화된 사전 훈련 LLM을 LoRA [250]로 미세 조정하며, 4비트 정수와 부동 소수점에 비해 더 나은 성능을 보여줍니다.

3.6.3. 가지치기

프루닝은 모델 크기를 압축하기 위한 대안적 접근법으로, 이를 통해 LLM의 배포 비용을 크게 줄일 수 있다. 태스크에 구매받지 않는 프루닝에 비해, 태스크 특화 프루닝은 성능이 우수하게 달성될 수 있으며, 이는 모델이 다운스트림 태스크에 대해 미세 조정되고 빠른 추론을 위해 프루닝되기 때문이다. 개별 태스크에 대해 LLM을 프루닝하는 것이 가능하지만, 태스크 특화 모델의 프루닝 및 배포 비용이 높다. 이를 극복하기 위해, 모든 태스크에서 합리적인 성능을 유지하면서 모델 크기를 줄이기 위한 많은 구조화된 및 비구조화된 LLM 프루닝 방법이 제안되었다.

비구조적 가지치기: 이러한 가지치기는 구조를 유지하지 않고 덜 중요한 가중치를 제거합니다. 기존의 LLM 가지치기 방법은 LLM의 독특한 특성을 활용하는데, 이는 작은 모델에서는 드물며, 작은 부분의 은닉 상태가 큰 크기로 활성화됩니다 [255]. 가중치와 활성화에 의한 가지치기(Wanda) [265]는 입력의 노름과 가중치를 곱하여 계산된 중요도에 따라 각 행의 가중치를 가지치기합니다. 가지치기된 모델은 미세 조정이 필요하지 않아 계산 비용을 절감합니다. 이 상치 가중치 증별 희소성(OWL) [267]은 비균일 층 가지치기로 Wanda를 확장합니다. 이는 서로 다른 층에 따라 이상치의 수가 다르다는 것을 보여주므로, 모델은 각 층의 성능을 향상시키기 위해 가변 가지치기 비율을 가져야 합니다. 대조적 가지치기(CAP) [43]는 사전 훈련된 모델, 미세 조정된 모델 및 이전의 희소 모델 스냅샷 간의 대조 손실을 이용하여 희소 모델을 훈련함으로써 모델을 반복적으로 가지치기하여 작업별 및 작업 비의존 지식을 학습합니다.

구조적 프루닝: 여기서 매개변수는 그룹, 행, 열 또는 행렬 단위로 제거되어, 효과적인 하드웨어 텐서 코어 활용 덕분에 추론 속도가 빨라진다 [265]. LLM-Pruner [42]는 3단계 구조적 프루닝 전략을 채택하여, 순전파 과정 동안 서로 활성화되는 은닉 상태의 그룹을 식별하고, 중요한 그룹은 유지하며 덜 중요한 그룹은 제거하고, LoRA를 사용해 프루닝된 모델을 미세 조정한다. 희소성 유도 마스크 학습(SIMPLE) [268]은 학습 가능한 마스크를 사용해 네트워크를 프루닝한다. 유사하게, 또 다른 방법은 마스크를 학습하고 팩터화된 가중치 행렬의 중요하지 않은 1순위 요소를 제거하여 LLM을 프루닝한다 [266].

3.7. 멀티모달 LLMs

LLM의 자연어 처리 응용 프로그램에서의 성공에 영감을 받아 점점 더 많은 연구가 진행되고 있습니다.

현재 LLM이 이미지 [269, 270, 271], 비디오 [272, 273, 274], 오디오 [275, 274, 276] 등 다양한 정보의 양식을 인식할 수 있도록 지원하고 있다. 다중 양식 LLM(MLLM)은 텍스트만 처리하는 표준 LLM에 비해 상당한 이점을 제공한다. 여러 양식의 정보를 통합함으로써, MLLM은 맥락에 대한 더 깊은 이해를 달성할 수 있으며, 이는 다양한 표현이 담긴 더 지능적인 응답으로 이어진다. 중요하게도, MLLM은 인간의 지각 경험과 밀접하게 일치하여, 우리 다중 감각 입력의 협동적 특성을 활용해 세상에 대한 포괄적 이해를 형성한다 [276, 26]. 사용자 친화적인 인터페이스와 결합하여 MLLM은 직관적이고 유연하며 적응 가능한 상호작용을 제공할 수 있으며, 사용자가 다양한 입력 방법을 통해 지능형 어시스턴트와 소통할 수 있게 한다. 모델 구축 방식에 따라, 현재 MLLM은 일반적으로 세 가지 흐름으로 나눌 수 있다: 사전 훈련, 세부 조정 및 프롬프트. 이 섹션에서는 이러한 주요 흐름의 세부 사항과 시각적 추론에서 MLLM의 중요한 응용에 대해 논의할 것이다.

사전 훈련: 이 MLLM의 흐름은 통합된 엔드 투 엔드 모델을 사용하여 다양한 모달리티를 지원하는 것을 목표로 합니다. 예를 들어, Flamingo [269]는 시각과 언어 모달리티를 융합하기 위해 게이트 크로스 어텐션을 적용하며, 이는 각각 사전 훈련되고 고정된 시각 인코더와 LLM에서 수집됩니다. 또한, BLIP-2 [270]는 시각과 언어 모달리티 간의 정렬을 위한 Querying Transformer(Q-Former)를 사전 훈련하기 위한 두 단계 전략을 제안합니다: 첫 번째 단계에서는 고정된 시각 인코더에서 시각-언어 표현 학습이 부트스트랩되고, 두 번째 단계에서는 고정된 LLM이 제로샷 이미지-텍스트 생성을 위한 시각-언어 생성 학습을 부트스트랩합니다. 이와 유사하게, MiniGPT-4 [277]는 사전 훈련되고 고정된 ViT [278], Q-Former 및 Vicuna LLM [159]을 배치하여 시각과 언어 모달리티 정렬을 위해 선형 프로젝션 레이어만 학습합니다.

미세 조정: NLP 작업을 위한 지침 조정 [16]에서 파생된 연구자들은 다중 모드 지침을 사용하여 사전 훈련된 LLM을 미세 조정하고 있다 [20, 16, 97]. 이러한 방법을 따르면 LLM은 다중 모드 챗봇 [277, 271, 29] 및 다중 모드 작업 해결사 [279, 30, 280]로 쉽게 그리고 효과적으로 확장될 수 있다. 이 MLLMs의 주요 문제는 미세 조정을 위한 다중 모드 지침 추적 데이터를 수집하는 것이다 [58]. 이 문제를 해결하기 위해 벤치마크 적응 [279, 281, 282], 자가 지침 [19, 31, 283] 및 하이브리드 조합 [284, 280]의 해결책이 각각 사용된다. 원래의 언어 모드와 추가적인 모드 간의 격차를 완화하기 위해 학습 가능한 인터페이스가 고정된 사전 훈련 모델의 서로 다른 모드를 연결하는 데 도입된다. 특히, 학습 가능한 인터페이스는 파라미터 효율적인 조정 방식으로 작동할 것으로 예상되며: 예를 들어, LLaMA-Adapter [285]는 훈련을 위한 효율적인 트랜스포머 기반 어댑터 모듈을 적용하고, LaVIN [284]은 혼합 모드 어댑터를 사용하여 다중 모드 특정 가중치를 동적으로 학습한다. 학습 가능한 인터페이스와는 달리, 전문가 모델은 다중 모드를 언어로 직접 변환할 수 있다: 예를 들어, VideoChat-Text [272]는 주어진 비디오의 캡션을 생성하기 위해 Speech Recognition 전문가 모델인 Whisper [286]을 통합하여 후속 LLM의 이해를 돕는다.

프롬프트: 미세 조정 기법과는 다르게

작업 특화된 데이터셋을 기반으로 모델 매개변수를 직접 업데이트하는 반면, 프롬프트 기법은 모델에 특정 맥락, 예시 또는 지침을 제공하여 모델 매개변수를 변경하지 않고도 전문화된 작업을 수행하게 합니다. 프롬프트는 대규모 멀티모달 데이터의 필요성을 크게 줄일 수 있기 때문에, 이 기술은 MLLM을 구성하는 데 널리 사용됩니다. 특히, 멀티모달 사고의 연쇄(Chain of Thought, CoT) 문제를 해결하기 위해 LLM은 멀티모달 입력을 바탕으로 추론 과정과 답변을 생성하도록 프롬프트됩니다. 이 과정에서 다양한 학습 패러다임이 실제로 활용되는데, 예를 들어 Multimodal-CoT는 추론 생성과 답변 추론의 두 단계를 포함하며, 두 번째 단계의 입력은 원본 입력과 첫 번째 단계의 출력을 결합한 것입니다; CoT-PT는 프롬프트 튜닝과 특정 시각적 편향을 적용하여 implicitly한 추론 연쇄를 생성합니다. CoT 문제 외에도, LLM은 멀티모달 설명과 도구를 통해서도 프롬프트를 받을 수 있으며, 복잡한 작업을 효과적으로 하위 작업으로 나누는 데 기여합니다.

비주얼 추론 애플리케이션: 최신 비주얼 추론 시스템 [291, 292, 216, 293]은 더 나은 시각 정보 분석 및 비주얼-언어 통합을 위해 LLM을 적용하는 경향이 있다. 제한된 VQA 데이터셋과 소규모 신경망에 의존했던 이전 연구들 [294, 295]와는 다르게, 현재 LLM 지원 방법은 더 강력한 일반화 능력, 신생 능력 및 상호 작용성 [58]이라는 이점을 제공한다. LLM의 도움으로 비주얼 추론을 실현하기 위해 프롬프트 및 파인튜닝 기법도 활용될 수 있다. 예를 들어, PointClip V2 [292]는 LLM을 적용하여 3D 특정 프롬프트를 생성하는데, 이는 텍스트 특징으로 인코딩되고 이후 3D 인식을 위해 시각적 특징과 결합된다. 또한 GPT4Tools [31]는 LoRA [250]를 사용하여 도구 관련 지침에 따라 LLM을 파인튜닝한다. LLM은 컨트롤러 [293], 의사 결정자 [296], 또는 의미 세분화기 [291, 297]로서 비주얼 추론 연구의 진행을 크게 촉진한다.

3.8. 요약 및 논의

3.8.1. 아키텍처

LLM의 거대한 규모로 인해, 아키텍처와 훈련 전략의 사소한 변화가 성능과 안정성에 큰 영향을 미칩니다. 여기에서는 다양한 LLM에서 사용되는 핵심 아키텍처 모듈을 요약하여 성능 향상, 훈련 시간 및 메모리 감소, 그리고 훈련 안정성 향상에 대해 설명합니다.

레이어 정규화: LLM의 성능과 훈련 안정성은 레이어 정규화에 의해 상당한 영향을 받습니다. 입력을 정규화하는 프리 노름이 출력보다 더 일반적으로 LLM에서 훈련을 안정화합니다 [6, 127, 108]. BLOOM [13]과 AlexaTM [122]은 훈련을 안정화하기 위해 임베딩 레이어 이전에 추가적인 레이어 정규화를 활용하고 있으며, 반면 모델의 제로샷 일반화 능력은 부정적인 영향을 받을 수 있습니다 [13]. 그러나 다른 연구 [33]에 따르면 프리 노름은 포스트 노름에 비해 미세 조정된 모델 성능을 저하시킨다고 하며, 100B 규모 이상의 프리 노름은 안정성 측면에서 장점이 없습니다. 따라서 GLM-130B [33]는 미세 조정 후 더 나은 다운스트림 작업 성능을 위해 포스트 노름의 변형인 딥 노름을 사용했습니다.

위치 인코딩: 모델의 다른 구성 요소들처럼,

포지셔널 인코딩은 LLM의 성능과 훈련 안정성에도 영향을 미친다. BLOOM [13]은 ALiBi가 학습된 포지셔널 인코딩과 로터리 포지셔널 인코딩보다 성능이 더 뛰어나다고 발견했다. 이에 반해, GLM-130B [33]는 로터리 포지셔널 인코딩이 ALiBi보다 더 낫다고 언급하고 있다. 따라서 문헌에서는 포지셔널 인코딩에 대한 결론이 아직 없다.

병렬 주의: 이 종류의 주의에서는 피드포워드와 주의 레이어가 변환기 블록에서 순차적이지 않고 서로 병렬로 존재합니다. 이로 인해 교육 시간이 15% 단축된 것으로 나타났습니다. 문헌에서는 이러한 변화로 인한 성능 저하의 증거가 없으며, 이 방식은 모델 PaLM [15], GPT-NeoX [118], 및 CodeGen [140]에서 사용됩니다.

멀티 큐리 어텐션은 트랜스포머 블록에서 공유된 키 및 값 어텐션 헤드를 가지며, 큐리 어텐션 헤드는 일반적으로 프로젝션됩니다. 이는 메모리 사용량을 줄이고 자기 회귀 디코딩에서 샘플링 속도를 높입니다. 이 변경으로 성능 저하는 관찰되지 않았으며, 더 큰 배치 크기를 허용하여 훈련을 효율적으로 만듭니다. 멀티 큐리 어텐션은 [15, 142]에서 사용됩니다.

전문가 혼합(Mixture of Experts): 이 유형의 아키텍처는 모델을 수조 개의 매개변수까지 쉽게 확장할 수 있게 해줍니다[92, 91]. 계산 중에 몇몇 전문가만 활성화되므로 계산 효율적입니다. MoE 모델의 성능은 동일한 데이터 양을 기준으로 밀집 모델보다 더 우수하며, 밀집 모델과 유사한 성능을 달성하기 위해 미세 조정 시 필요한 계산량이 적습니다[91]. MoE 아키텍처는 재난적 망각(catastrophic forgetting)에 덜 취약하므로 지속적인 학습에 더 적합합니다[92]. 성능을 잃지 않고 다운스트림 작업을 위해 더 작은 하위 모델을 추출하는 것이 가능하여 MoE 아키텍처는 하드웨어 친화적입니다[92].

희소 vs 밀집 활성화: GPT-3 [6]은 희소 변환기 [67]를 사용하는 반면, GLaM [91]과 PanGu- χ [92]는 MoE [121] 아키텍처를 사용하여 계산 비용을 줄이고 모델 크기와 용량을 증가시킵니다. 문헌에 따르면 희소 모듈은 모델의 성능을 저하시킬 수 없습니다 [67]. 그러나 이 주장을 검증하기 위해서는 더 많은 실험이 필요합니다.

3.8.2. 훈련 전략

대규모로 모델을 훈련하는 데는 훈련 비용을 줄이고, 손실 발산을 피하며, 더 나은 성능을 달성하기 위한 여러 방법이 필요하다. 우리는 다양한 LLM에서 사용되는 이러한 주요 방법들을 요약하고 논의한다.

혼합 정밀도: 이는 LLM의 메모리 사용량을 줄이고 훈련 효율성을 높이기 위한 유명한 방법입니다. 혼합 정밀도에서는 순전파와 역전파가 FP16 형식으로 수행되지만, 옵티마이저 상태와 마스터 가중치는 FP32 형식으로 유지됩니다 [120]. 이 형식 변경과 관련된 단점은 작은 값 범위로 인해 발생하는 손실 급등으로 인한 훈련 불안정성입니다 [33]. FP16의 대안으로는 BF16이 있으며, 이는 비교적 더 큰 범위를 가지고 있고 경량 축적 및 softmax와 같은 정밀도 민감 연산을 FP32로 수행합니다 [13]. BF16은 더 나은 성능과 훈련 안정성을 제공하지만 더 많은 메모리를 사용하고 특정 하드웨어에서만 지원되며, 예를 들어 A100 GPU와 같은 장비가 필요합니다. 따라서 LLM에서의 채택은 제한적입니다.

훈련 불안정성: 손실 발산 또는 급증은 LLM에서 발생하는 일반적인 문제로, 훈련 중 여러 번 발생합니다. 이는

기울기 클리핑의 존재에서 발생합니다 [15]. 이 문제를 완화하기 위해 많은 접근 방식이 이전 체크포인트에서 훈련을 재시작할 것을 제안합니다 [15, 33, 91], [15]에서 분기 지점에서 200-500개의 이전 데이터 배치를 건너뛰고 [91]에서 배치를 재조정하는 방법입니다. 임베딩 레이어의 기울기 감소는 다른 레이어에 비해 기울기 노르무가 상당히 커서 훈련을 더욱 안정화하는 것으로 입증되었습니다 [33]. 더 큰 모델의 훈련 안정성을 개선하기 위한 또 다른 제안은 [15]처럼 밀집 레이어와 정규화 레이어에서 바이어스를 사용하지 않는 것입니다.

가중치 초기화: 이는 모델 수렴과 훈련 안정성에서 중요한 역할을 합니다. GPT-NeoX [118]는 잔차 전의 피드포워드 계층을 [153]에서와 같이 $2L\sqrt{d}$ 로 초기화하고, 다른 계층은 작은 초기화 방식을 사용합니다 [298]. 이는 깊이가 증가함에 따라 활성화가 기하급수적으로 성장하는 것을 방지합니다. MT-NLG [117]는 높은 분산의 가중치 초기화가 불안정한 훈련으로 이어진다는 것을 발견하여, 따라서 작은 초기화 방식 [298]의 유효성을 입증하였습니다. 다양한 모델은 무작위 가중치 초기화를 수행하는데, 이는 나쁜 초기화를 초래할 수 있습니다. Galactica [148]는 이러한 영향을 상쇄하기 위해 더 긴 워밍업을 제안합니다.

학습률: 적절한 학습률은 안정적인 학습에 중요하다. 워밍업과 감쇠(cosine 또는 linear)와 함께 낮은 값을 사용하는 것이 권장된다 [13, 15, 124]. 일반적으로 학습률은 $1e-4$ 에서 $8e-4$ 범위 내에 있다. 또한, MT-NLG(530B) [117]와 GPT-NeoX(20B) [118]는 GPT-3 [6] 모델을 기준으로 모델 크기에 따라 학습률을 보간하는 것을 제안한다. 이는 학습률 하이퍼파라미터 조정을 피할 수 있다.

훈련 병렬 처리: 3D 병렬 처리, 즉 데이터, 파이프라인, 텐서 병렬 처리의 결합은 LLM에서 가장 많이 사용되는 훈련 병렬 처리 접근 방식이다 [33, 15, 14, 13, 117, 115, 112]. 3D 병렬 처리 외에도 BLOOM [13]은 제로 오피티마이저 [37]를 사용하여 오피티마이저 상태를 분산시킨다. PanGu- α [108]와 PanGu- Σ [92]는 3D 병렬 처리를 넘어 오피티마이저 병렬 처리와 재재료를 추가로 포함하는 5D 병렬 처리를 적용한다.

모드 전환: 훈련 중 텍스트의 시작 부분에 작업 관련 토큰을 추가합니다. 이 토큰은 자연어 이해 및 자연어 생성 작업을 나타내며, 이는 [125, 124, 122]에서 하위 작업 성능을 향상시키는 것으로 나타났습니다. 미세 조정 및 추론 동안에는 하위 작업에 따라 토큰이 추가됩니다.

제어 가능한 텍스트 생성: 사전 훈련된 모델로부터 신뢰할 수 있고 제어된 텍스트를 생성하는 것은 도전적입니다. GPT-3 [6] 및 다른 LLM들은 생성된 텍스트를 제어하기 위해 맥락 내 학습을 사용합니다. 맥락 내 학습이 생성된 텍스트를 제어하는 데 도움을 주는 반면, ERNIE 3.0 Titan [35]은 생성된 텍스트의 신뢰성을 평가하기 위해 적대적 손실을 사용하고, 생성된 텍스트의 더 나은 제어를 위해 장르, 주제, 키워드, 감정, 길이와 같은 소프트 프롬프트를 사용할 것을 제안합니다.

제어 가능한 텍스트 생성: 사전 훈련된 모델로부터 신뢰할 수 있고 제어된 텍스트를 생성하는 것은 도전적입니다. GPT-3 [6] 및 다른 LLM들은 생성된 텍스트를 제어하기 위해 맥락 내 학습을 사용합니다. 맥락 내 학습이 생성된 텍스트를 제어하는 데 도움을 주는 반면, ERNIE 3.0 Titan [35]은 생성된 텍스트의 신뢰성을 평가하기 위해 적대적 손실을 사용하고, 생성된 텍스트의 더 나은 제어를 위해 장르, 주제, 키워드, 감정, 길이와 같은 소프트 프롬프트를 사용할 것을 제안합니다.

3.8.3. 감독된 모델 대 일반화된 모델

일반화된 모델은 다양한 작업을 좋은 성능으로 수행할 수 있지만, 아직 감독된 환경에서 훈련된 모델을 능가하지는 못했다. 감독 훈련된 모델은 여전히 다양한 NLP 작업에서 큰 차이로 최신 기술을 선도하고 있다.

3.8.4. 제로샷 대 퓨샷

LLMs는 제로샷 및 퓨샷 설정에서 좋은 성능을 발휘합니다. 그러나 제로샷과 퓨샷 간의 성능 차이는 사전 훈련 모델에서 크며 [6, 15], LLMs를 메타 학습자로 분류합니다 [6]. LLMs의 제로샷 평가 결과는 신경 기계 번역 [6]에서 비지도 방법보다 낮은 성능을 보입니다. 문헌에서는 좋은 제로샷 성능을 위해서는 사전 훈련만으로는 부족하다고 보여줍니다 [15, 16]. 제로샷 성능을 개선하기 위해 문헌에서는 지침 미세 조정을 사용하라고 제안하며, 이는 제로샷 성능을 상당히 향상시키고 기준 모델을 초과하는 성능을 보여줍니다. 지침 미세 조정은 또한 보지 못한 작업에 대한 제로샷 일반화도 개선되는 것으로 나타났습니다. 또 다른 모델인 Flan-PaLM [16]은 CoT 훈련을 통해 제로샷 추론을 가능하게 합니다.

3.8.5. 인코더 vs 디코더 vs 인코더-디코더

전통적으로 이러한 아키텍처는 서로 다른 작업에서 잘 작동합니다. 예를 들어, NLU 작업에는 인코더 전용, NLG에는 디코더 전용, 그리고 시퀀스-투-시퀀스 모델링에는 인코더-디코더가 사용됩니다. 인코더 전용 모델은 Bert [7], RoBERTa [299] 등과 같은 소형 모델로 유명하며, LLM은 디코더 전용 [6, 118, 13] 또는 인코더-디코더 [10, 11, 122]입니다. 디코더 전용 모델은 NLG 작업에 강점을 보이지만, 다양한 LLM인 PaLM [15], OPT [14], GPT-3 [6], BLOOM [13], LLaMA [156]는 NLU와 NLG 작업 모두에서 성능 향상을 보이는 디코더 전용 모델입니다. 이와 반대로 T5 [10]와 UL2 [125]는 인코더-디코더 모델이 디코더 전용 모델보다 더 우수한 성능을 발휘한다고 지적합니다. 또 다른 연구에서는 PaLM [15]가 디코더 전용 모델의 크기를 늘리는 것이 디코더 전용 아키텍처와 인코더-디코더 아키텍처 간의 성능 차이를 줄일 수 있음을 발견했습니다.

디코더 전용 아키텍처가 LLM에서 트렌드가 되었지만, 최근 제안된 많은 접근 방식 [125, 122]은 작업별 모드를 활성화하기 위해 인코더-디코더 아키텍처의 텍스트에서 모드 전환 토큰을 사용합니다. 마찬가지로, CodeT5+ [34]는 서로 다른 작업을 위한 여러 훈련 목표와 함께 인코더-디코더 아키텍처를 사용하며, 작업에 따라 인코더, 디코더 또는 둘 다를 활성화합니다. 이러한 아키텍처와 훈련 목표의 변형은 모델이 다양한 환경에서 우수한 성능을 발휘할 수 있게 해줍니다. 이러한 동적 구성 덕분에 LLM의 미래는 인코더-디코더 아키텍처에 기인할 수 있습니다.

4. 모델 구성 설정

이번 섹션에서는 사전 훈련된 모델과 지시 조정된 모델의 다양한 통계를 제공합니다. 여기에는 출판 장소, 라이선스 유형, 모델 제작자, 훈련 단계, 병렬 처리 방식 등과 같은 정보가 Table 3과 Table 4에 포함되어 있습니다. 사전 훈련된 LLM의 아키텍처 세부 사항은 Table 5에서 확인할 수 있습니다. 지시 조정된 모델에 대한 이러한 세부 사항은 불필요한데, 이는 사전 훈련된 모델을 지시 데이터셋에 맞게 미세 조정하기 때문입니다. 따라서 아키텍처 세부 사항은 기준 모델과 동일합니다. 게다가 다양한 LLM에 대한 최적화 설정은 Table 6과 Table 7에서 확인할 수 있습니다. Table 7에는 정밀도, 워밍업 및 가중치 감소에 대한 세부 사항이 포함되어 있지 않습니다. 이러한 세부 사항은 지시 조정된 모델에 대해 언급할 만큼 중요하지 않으며, 논문에서도 제공되지 않습니다.

표 3: 사전 훈련된 LLM 요약 (>10B). 이전 섹션에서 개별적으로 논의된 LLM만 요약되어 있습니다. “데이터/토큰”은 모델의 사전 훈련 데이터로, 토큰의 수 또는 데이터 크기를 나타냅니다. “데이터 정제”는 데이터 정제가 수행되었는지를 나타냅니다. 여기에는 휴리스틱(Heur), 중복 제거(Dedup), 품질 필터링(QF), 개인 정보 필터링(PF)이 포함됩니다. “비용”은 GPU/TPU의 시간당 요금에 GPU 수와 훈련 시간을 곱하여 계산된 훈련 비용입니다. 실제 비용은 인하우스 GPU 사용이나 할인요금 적용, 재훈련, 문제에 대해 작업하는 직원 수 등 여러 이유에 따라 달라질 수 있습니다. “훈련 병렬성”은 데이터 병렬성(D), 텐서 병렬성(T), 파이프라인 병렬성(P), 컨텍스트 병렬성(C), 모델 병렬성(M), 최적화 병렬성(OP), 재물질화(R)를 활용한 분산 훈련을 나타냅니다. “라이브러리” 열에서 “DS”는 Deep Speed의 약어입니다. “상업적 사용” 열에서는 라이선스가 없는 경우 모델이 비상업적 목적을 위한 것이라고 가정했습니다.

모델들	출판 장소	LicenseModel	창작자의 목적	번호 매개변수 사용	상업적 단계 훈련됨	데이터 토큰	데이 침소	번호 처리 장치	프로세싱 유닛 타임 시간	훈련 계산됨	훈련 병렬성	도서관
T5 [10]	JMLR'20	Apache-2.0	Google General 11B		최	1M1THeur+Dedup		1024	TPU v3 V100		D+M	메시 텐서플로우
GPT-3 [6]	NeurIPS'20	OpenAI	General175B			-300BDedup+QF					M	
mT5 [11]	NAACL'21	Apache-2.0	Google General 13B		최	1M1T						
PanGu- α [108]	arXiv'21	Apache-2.0	Huawei General 200B		확	260k1.1TBHeur+Dedup		2048	Ascend 910-		-D+OP+P+O+R	MindSpore
CPM-2 [12]	AI Open'21	MIT	TsinghuaGeneral198B		최	1M2.6TB	Dedup				D+M	JAXFormer
Codex [141]	arXiv'21		OpenAICoding12B			-100B	휴어					
ERNIE 3.0 [110]	arXiv'21		BaiduGeneral10B			120k3375BHeur+Dedup		384	V100		M	PaddlePaddle
Jurassic-1 [112]	화이트 페이퍼 '21	Apache-2.0	AI21 일반 178B		최	-300B		800	GPU		D+M+P	메가트론+DS 하
이퍼플로바 [114] EMNLP'21			NaverGeneral82B			-300BClf+Dedup+PF		1024	A100321h1.32 밀		M	메가트론
유안 1.0 [115]	arXiv'21	Apache-2.0	General245B		최	26k3180B Heur+Clf+Dedup		2128	GPU		D+T+P	
코퍼 [116]	arXiv'21		구글제너럴280B			-300BQF+Dedup		4096	TPU v3920h13.19 밀		D+M	JAX+Haiku E
RNIE 3.0 Titan [35]arXiv'21			BaiduGeneral260B			-300BHeur+Dedup			Ascend 910-		D+M+P+D*	PaddlePaddle
GPT-NeoX-20B [118] BigScience'22	Apache-2.0	EleutherAI	General 20B		최	150k825GB	없음	96	40G A100-		최	메가트론+DS+파이토치
OPT [14]	arXiv'22	MIT	MetaGeneral175B		최	150k180B	중복 제	992	80G A100-		D+T	메가트론
BLOOM [13]	arXiv'22	RAIL-1.0	BigScienceGeneral176B		최	-366BDedup+PR		384	80G A1002520h3.87 MILD+T+P			메가트론+DS
갈락티카 [148]	arXiv'22	Apache-2.0	MetaScience120B			225k106B	중복 제	128	80GB A100-			Metaseq
			ICML'22			600k600B	Clf	1024	TPU v4		최	GSPMD
LaMDA [150]	arXiv'22		GoogleDialog137B			3M2.81TFItered		1024	TPU v31384h4.96 밀		D+M	링보 MT
-NLG [117]	arXiv'22	Apache-v2.0	MS+Nvidia General530B			-270B		4480	80G A100-		D+T+P	메가트론+DS
알파코드 [142]	Science'22	Apache-v2.0	Google Coding 41B		최	205k967BHeur+Dedup			TPU v4		최	JAX+Haiku C
hinchilla [96]	arXiv'22		GoogleGeneral70B			-1.4TFQ+Dedup			TPUv4			JAX+Haiku
PaLM [15]	arXiv'22		GoogleGeneral540B			255k780B	Heur	6144	TPU v4		D+M	JAX+T5X AI
exaTM [122]	arXiv'22	Apache v2.0	AmazonGeneral20B			500k1.1T	필터링됨	128	A1002880h1.47 Mil		최	DS
U-PaLM [124]	arXiv'22		구글제너럴540B			20k		512	TPU v4120h0.25 Mil			
UL2 [125]	ICLR'23	Apache-2.0	Google General 20B		최	2M1T		512	TPU v4		최	JAX+T5X G
LM [33]	ICLR'23	Apache-2.0	Multiple General 130B			-400B		768	40G A1001440h3.37 Mil		M	
CodeGen [140]	ICLR'23	Apache-2.0	Salesforce Coding 16B		최	650k577BHeur+Dedup			TPU v4		D+M	JAXFormer
LLaMA [127]	arXiv'23		메타제너럴65B			350k1.4T Clf+Heur+Dedup		2048	80G A100504h4.12 밀		D+M	xFormers
	arXiv'23		HuaweiGeneral 1.085T					512	Ascend 9102400h		-D+OP+P+O+R	MindSpore
BloombergGPT [151]arXiv'23			BloombergFinance50B			139k569B	중복 제	512	40G A1001272h1.97 Mil		최	PyTorch
Xuan Yuan 2.0 [152]arXiv'23		RAIL-1.0	Du Xiaoman Finance 176B		최	-366BFiltered			80GB A100-		P	DS
CodeT5+ [34]	arXiv'23	BSD-3	SalesforceCoding16B		최	110k51.5B	중복 제	16	40G A100-			DS
StarCoder [147]	arXiv'23	OpenRAIL-M	BigCodeCoding15.5B		최	250k1TDedup+QF+PF		512	80G A100624h1.28 MILD+T+P			메가트론-LM
LLaMA-2 [21]	arXiv'23		LLaMA-2.0MetaGeneral70B		최	500k2T 최소 필터링			80G A1001.7Mh			
PaLM-2 [123]	arXiv'23		GoogleGeneral-			-Ddedup+PF+QF						
LLaMA-3.1 [120]arXiv'24			LLaMA-3.0MetaGeneral405B		변 문	1.2M15TDedup+QF		16k	80G H100 30.84Mh		D+T+P+C	PyTorch
			Apache-2.0 Mistral AI General 141B									
Snowflake Arctic [132] web'24		Apache-2.0	Snowflake General 480B		최	-3.5T					T+P	DS
Nemotron-4 340B [137]web'24		Nvidia	NvidiaGeneral340B		최	9T		6144	80G H100-		D+T+P	
딥시크 [138]	arXiv'24	MITDeepSeek	General67B		최	2TDedup+QF			300.6Kh		D+T+P	DS
DeepSeek-v2 [139]arXiv'24		MITDeepSeek	General67B		최	-8.1T	QF		H800172.8Kh		D+P	HAI-LLM

표 4: 조정된 LLMs 요약 (>10B). 모든 약어는 표 3과 동일합니다. "Data/Tokens"의 "S-"로 시작하는 항목은 훈련 샘플 수를 나타냅니다.

모델들	게시물 장소 유형	라이선스	모델 CreatorsPurpose	번호 ParamsUse	상업용 사전 훈련된 모델들	단계 훈련됨	데이터 / 토큰	개수 처리 장치 유닛 유형	프로세싱트레인. 시간	계산된 기차 요금	기차. ParallelismLibrary
WebGPT [166]arXiv'21			OpenAIGeneral175B			GPT-3					
T0 [17]		ICLR'22	Apache-2.0 BigScience General 11B		최	T5	-250B	512	TPU v3270h0.48 밀		
Tk-Instruct [18]EMNLP'22MIT			AI2+ General11B		최	T5	1000	256	TPU v34h0.0036 밀		Google T5
OPT-IML [97]arXiv'22			메타 General175B			옵트	8k	2B	40G A100-		D+TMegatron Flan-U
-PaLM [16] ICLR'22	Apache-2.0	GoogleGeneral540B			입 문	U-PaLM30k		512	TPU v4-		JAX+T5X m
T0 [154]		ACL'23	Apache-2.0 HuggingFace+ General113B			mT5					
스퍼로우 [167]arXiv'22			GoogleDialog70B			친철라-		64	TPU v3-		M
WizardCoder [164] arXiv'23	Apache-2.0	HK Bapt.Coding15B				StarCoder200S-78k					
Alpaca [158]	Github'23	Apache-2.0	StanfordGeneral13B		최	LLaMA3-EpochS-52k		8	80G A1003h	600	FSDPPyTorch
Vicuna [159]	Github'23	Apache-2.0	LMsysGeneral13B		최	LLaMA3-Epoch S-125k					FSDPPyTorch LIMA [
[185]	arXiv'23		Meta+General65B			LLaMA15-Epoch S-1000					
코알라 [300]	Github'23	Apache-2.0	UC-BerkleyGeneral13B			LLaMA2-Epoch S-472k		8	A1006h	100	-JAX/FLAX

5. 데이터셋 및 평가

LLM의 대규모 데이터 수요로 인해 훈련 및 평가 데이터셋을 생성하는 것은 비용이 많이 듭니다. 따라서 이러한 모델을 훈련하고 벤치마킹하기 위한 데이터셋은 매우 중요한 주제입니다. LLM에서 일반적으로 사용되는 데이터셋에 대한 요약이 다음에 제공됩니다.

5.1. 훈련 데이터셋

LLM의 성능은 주로 훈련 데이터의 품질, 크기 및 다양성에 의존합니다. 고 품질의 대규모 훈련 데이터셋을 준비하는 것은 힘든 작업입니다. 연구자들은 LLM의 능력을 향상시키기 위해 다양한 사전 훈련 및 미세 조정 데이터셋을 제안했습니다. 우리는 이러한 노력을 표 8에서 요약합니다. 문헌에 수많은 훈련 데이터셋이 있지만, 우리는 요약에서 가장 널리 사용되는 데이터셋을 다룹니다.

표 5: LLM의 아키텍처 세부사항. 여기서 “PE”는 위치 임베딩, “nL”은 레이어 수, “nH”는 어텐션 헤드 수, “HS”는 은닉 상태의 크기입니다.

모델들	유형	훈련 목표	주의	어휘	토큰라이저	노름	PEActivationBiasLnHHS
T5 (11B)	인코딩-디	스팬 손상	표준	32k	SentencePiece	Pre-RMSRelativeReLU	×241281024
GPT3 (175B)	원인-결과	다음 토큰	Dense+Sparse			층 LearnedGeLU	√969612288
mT5 (13B)	Enc-Dec	스팬 부패	표준	250k	SentencePiece	Pre-RMSRelativeReLU	최소합니다, 입력
PanGu-α (200B)	Causal-Dec	다음 토큰	표준	40k	BPE	층	-6412816384
CPM-2 (198B)	Enc-Dec	스팬 부패	표준	250k	SentencePiece	Pre-RMSRelativeReLU	-2464
코덱스 (12B)	Causal-Dec	다음 토큰	표준		BPE+	Pre-LayerLearnedGeLU	-969612288
ERNIE 3.0 (10B)	Causal-Dec	다음 토큰	표준		WordPiece	Post-LayerRelativeGeLU	-48644096
Jurassic-1 (178B)	Causal-Dec	다음 토큰	표준	256k	SentencePiece	Pre-LayerLearnedGeLU	√769613824
HyperCLOVA (82B)	Causal-Dec	다음 토큰	조밀한+희소한		BPE*	프리 레이어 학습된 GeLU	-648010240
Yuan 1.0 (245B)	Causal-Dec	다음 토큰	표준				-76-16384
Gopher (280B)	Causal-Dec	다음 토큰	기준	32k	SentencePiece	Pre-RMSRelativeGeLU	√8012816384
ERNIE 3.0 Titan (260B)	Causal-Dec	다음 토큰	표준		WordPiece	포스트-레이어릴레이트게를루	-4819212288
GPT-NeoX-20B	Causal-Dec	다음 토큰	병렬	50k	BPE	레이어 RotaryGeLU	√4464
OPT (175B)	Causal-Dec	다음 토큰	표준		BPE	ReLU	√9696
BLOOM (176B)	Causal-Dec	다음 토큰	표준	250k	BPE	층 ALiBi GeLU	√7011214336
Galactica (120B)	Causal-Dec	다음 토큰	표준	50k	BPE+custom	레이어 LearnedGeLU	×968010240 GLaM (1.2T)
	MoE-Dec	다음 토큰	표준	256k	SentencePiece	레이어 RelativeGeLU	√6412832768 LaMDA (137
B)	Causal-Dec	다음 토큰	표준	32k	BPE	층 RelativeGeLU	-641288192
MT-NLG (530B)	Causal-Dec	다음 토큰	표준	50k	BPE	Pre-LayerLearnedGeLU	√10512820480
AlphaCode (41B)	Enc-Dec	다음 토큰	다중 쿼리	8k	SentencePiece		-641286144
친칠라 (70B)	Causal-Dec	다음 토큰	표준	32k	SentencePiece-NFKCPre-RMSRelativeGeLU		√80648192
PaLM (540B)	원인은-Dec	다음 TokenParallel+Multi-query256k			SentencePiece	레이어 RoPESwiGLU	×1184818432
AlexaTM (20B)	인코딩-디	노이즈 제거	표준	150k	SentencePiece	Pre-LayerLearnedGeLU	√78324096
Sparrow (70B)	Causal-Dec	Pref.&Rule RM		32k	SentencePiece-NFKCPre-RMSRelativeGeLU		√161648192
U-PaLM (540B)	비인과적 결정	MoDParallel+Multi-query256k			SentencePiece	레이어 RoPESwiGLU	×1184818432
UL2 (20B)	Enc-Dec	MoD	표준	32k	SentencePiece		-64164096
GLM (130B)	비인과적-결정	AR 빈 공간 채우기	표준	130k	SentencePiece	깊은 RoPEGeGLU	√709612288
CodeGen (16B)	Causal-Dec	다음 토큰	병렬		BPE	레이어 RoPE	-3424
LLaMA (65B)	Causal-Dec	다음 토큰	표준	32k	BPE	Pre-RMSRoPESwiGLU	-80648192
PanGu-Σ (1085B)	Causal-Dec	다음 토큰	표준		BPE	융합층 FastGeLU	-40405120
BloombergGPT (50B)	Causal-Dec	다음 토큰	표준	131k	유니그램	층 ALiBi GeLU	√70407680
Xuan Yuan 2.0 (176B)	Causal-Dec	다음 토큰	자아	250k	BPE	레이어 ALiBi GeLU	√7011214336
CodeT5+ (16B)	Enc-Dec	SC+NT+Cont.+Match	표준		코드 특징		무언가 입력이 없
StarCoder (15.5B)	Causal-Dec	FIM	다중 쿼리	49k	BPE	배운	-40486144
LLaMA-2 (70B)	Causal-Dec	다음 TokenGrouped-query		32k	BPE	Pre-RMSRoPESwiGLUE	최소합니다, 번역
PaLM-2		MoD	병렬				번역할 문장을 제
LLaMA-3.1 (405B)	Causal-Dec	다음 TokenGrouped-query		128k	BPE	Pre-RMSRoPESwiGLU	-12612816384
Nemotron-4 (340B)	Causal-Dec	다음 토큰	표준	256k	SentencePiece	RoPE ReLU	×969618432
DeepSeek (67B)	Causal-Dec	다음 TokenGrouped-query		100k	BBPE	Pre-RMSRoPESwiGLU	-95648192
DeepSeek-v2 (67B)	MoE-Dec	다음 TokenMulti-Head Latent100k			BBPE	Pre-RMSRoPESwiGLU	-601285120

5.2. 평가 데이터셋 및 작업

LLM에 대한 평가는 그들의 능력과 한계를 파악하는 데 중요하다. 이 과정은 모델이 다양한 작업을 수행하며 인간 언어를 이해하고 생성하며 상호작용하는 능력을 측정한다. 언어 모델(LM)의 평가는 크게 두 가지 범주로 나뉜다: 1) 자연어 이해(NLU)와 2) 자연어 생성(NLG). NLU와 NLG의 작업은 부드럽게 범주화되며 문헌에서 종종 상호 교환적으로 사용된다는 점이 강조된다.

자연어 이해: 이는 LMs의 언어 이해 능력을 측정합니다. 여기에는 감정 분석, 텍스트 분류, 자연어 추론(NLI), 질문 응답(QA), 상식 추론(CR), 수학적 추론(MR), 독해(RC) 등 여러 작업이 포함됩니다.

자연어 생성: 이는 제공된 입력 맥락을 이해하여 LLM의 언어 생성 능력을 평가합니다. 여기에는 요약, 문장 완성, 기계 번역(MT), 대화 생성 등과 같은 작업이 포함됩니다.

각 작업에 대해 제안된 수많은 데이터셋이 있으며, LLMs는 다양한 특성에 대해 평가됩니다. 평가 데이터셋에 대한 개요를 제공하기 위해 각 범주 내에서 몇 가지 유명한 데이터셋을 간략히 논의하고, 데이터셋의 포괄적인 목록을 Table 9에 제시합니다. 또한, 우리가 사용하는 훈련 데이터셋과 평가 작업 및 벤치마크에 대한 자세한 개요를 보여줍니다.

표 10에 나와 있는 사전 훈련된 LLM과 표 11에 나와 있는 미세 조정된 LLM을 비교합니다. 또한 표 12에서는 다양한 NLP 작업에서 가장 성능이 뛰어난 LLM을 비교합니다.

5.2.1. 다중 작업

MMLU [307]: 모델이 사전 학습 동안 습득한 지식을 측정하고 57개 주제에서 제로샷 및 몇 샷 환경에서 모델을 평가하며, 세계 지식과 문제 해결 능력을 모두 테스트하는 기준입니다.

SuperGLUE [2]: GLUE [309] 벤치마크의 더 도전적이고 다양한 후속 지표인 SuperGLUE는 질문 응답, 자연어 추론, 공참조 해결 같은 다양한 언어 이해 작업을 포함합니다. 이는 언어 이해의 엄격한 테스트를 제공하도록 설계되었으며, 샘플 효율, 전이, 다중 작업, 비지도 혹은 자기 지도 학습과 같은 분야에서 상당한 진전을 요구합니다.

BIG-bench [308]: BIG-bench(Behavior of Intelligent Generative Models Benchmark)는 추론, 창의성, 윤리, 특정 분야에 대한 이해를 포함한 다양한 작업에서 LLM의 능력을 테스트하기 위해 설계된 대규모 벤치마크입니다.

GLUE [309]: General Language Understanding Evaluation (GLUE) 벤치마크는 자연어 이해를 훈련, 평가 및 분석하기 위한 자원의 모음입니다.

표 6: 사전 훈련된 LLM에 사용된 최적화 설정 요약. 대부분의 LLM에 대해 가중치 감소, 기울기 클리핑 및 드롭아웃의 값은 각각 0.1, 1.0, 0.1입니다.

들	시퀀스		LR		최적화 도구		정밀도	WeightGrad 모델	
	배치 크기 길이 LR 워밍업		부식		AdaFactor	Adam	AdamW	FP16	혼합 감소 클립 드롭아웃
T5 (11B)	21	5120.01	역 제곱근✓					최송하지만, 번역	✓
	32K	-6e-5	최	코사인		최		최	최
mT5 (13B)	1024	10240.01	역 제곱근✓					문장을 입력해 주	✓
		10242e-5						최송하지만, 입력	
CPM-2 (198B)	1024	10240.001			최			최송하지만, 번역	코
텍스 (12B)		-6e-5	최	코사인		최		최	
ERNIE 3.0 (12B)	6144	5121e-4	최	선형		최		지금 번역할 문장	최
Jurassic-1 (178B)	3.2M	20486e-5	최	코사인		최		최	최
HyperCLOVA (82B)	1024	-6e-5		코사인			최	최송하지만 입력	문
Yuan 1.0 (245B)	<10M	20481.6e-4	최	코사인 감소를 10%로		최		입력된 문장이 없	제
고퍼 (280B)	3M	20484e-5	최	코사인 감소 10%		최		최	최
ERNIE 3.0 Titan (260B)		5121e-4	최	선형		최		최	최
GPT-NeoX-20B	1538	20480.97e-5	최	코사인			최	최	최
×	2M	20481.2e-4		선형			최	최	최
LOOM (176B)	2048	20486e-5	최	코사인		최		최	최
갈락티카 (120B)	2M	20487e-6	최	10%로 선형 감소			최	제공할 영어 문장	문
LaM (1.2T)	1M	10240.01		역 제곱근✓				FP32 + ✓	최
×	256K							내용이 없습니다.	
MT-NLG (530B)	1920	20485e-5	최	코사인 감소 10%		최		최	최
알파코드 (41B)	20481536+7681e-4		번	코사인 감쇠 10%			최	최	최
친칠라 (70B)	1.5M	20481e-4	최	코사인 감쇠 10%		최		문	
PaLM (540B)	2048	20480.01		역제곱근✓				최송합니다. 번역	최
×	2M	10241e-4		선형 감소를 5%로.		최		최	최
-PaLM (540B)	32	20481e-4		코사인	최			입력된 영어 문장	U
UL2 (20B)	1024	1024		역제곱근-				문장을 제공해 주	
GLM (130B)	4224	20488e-5	최	코사인			번	최	최
드젠 (16B)	2M	20485e-5	최	코사인		최		물론입니다. 번역	최
LLaMA (65B)	4M 토큰	20481.5e-4	최	코사인 감소 10%			최	최송합니다만, 번	위
PanGu-Σ (1.085T)	512	10242e-5	해			주		최	
BloombergGPT (50B)	2048	20486e-5	위	코사인			번	최	최
uan Yuan 2.0 (176B)	2048	20486e-5	최	코사인		최		최	최
CodeT5+ (16B)	2048	10242e-4		선형			최	제	번
스타코더 (15.5B)	512	8k3e-4	최	코사인		최		최	최
LLaMA-2 (70B)	4M 토큰	4k1.5e-4	번	코사인			최	이	문
LLaMA-3.1 (405B)	16M	81928e-5	최	선형+코사인			최	최	
Nemotron-4 (340B)	2304	4096		선형				최	
딥시크 (67B)	4608	40963.2e-4	최	코사인			최	✓	최
DeepSeek-v2 (67B)	9216	4k2.4e-4	최	스텝-감소			최	최송하지만, 번역	최

표 7: 지침 조정 LLM에 사용된 최적화 설정의 요약. 그래디언트 클리핑과 드롭아웃 값은 사전 훈련된 모델과 동일하며, 지침 조정에는 어떤 모델도 가중치 감소를 사용하지 않습니다.

시퀀스					최적화 도구		학위
수여 모	배치 크기 길이 LR 워밍업			LR_Decay	AdaFactorAdamAdamWClipDropout		
WebGPT (175B)	BC:512, RM:32	-6e-5			최		
T0 (11B)	1024	12801e-3			최		✓
	1024	-1e-5		지속적인			
OPT-IML (175B)	128	20485e-5		선형	최	최	FI
an-U-PaLM (540B)	32	-1e-3		상수	최		스
패로우 (70B)	RM: 8+16, RL:16	-2e-6		최	코사인 감소를 10%까지	최	
×	512	20482e-5		최	코사인		
알파카 (13B)	128	5121e-5		최	코사인	최	입
비쿠냐 (13B)	128	-20482e-5		최	코사인	최	
리마(65B)	32	20481e-5		선형		최	최

시스템. 여기에는 다양한 언어 현상을 테스트하는 여러 가지 작업이 포함되어 있어 AI의 언어 이해를 평가하는 포괄적인 도구가 됩니다.

5.2.2. 언어 이해

WinoGrande [354]: 원래 Winograd [357] 스키마 챌린지에서 영감을 받은 대규모 데이터셋으로, 모델이 대명사 중의성을 해소하는 능력을 테스트하고 자연어에서 폭넓은 맥락을 이해하는 모델 개발을 장려합니다.

언어 텍스트.

CoQA [316]: 대화형 질문-응답 데이터셋인 CoQA는 대화 이력에 의존하는 질문과 자유 형식의 텍스트 답변이 필요한 질문으로 모델에 도전합니다. 일곱 개 도메인에서 나온 다양한 내용은 모델이 광범위한 주제와 대화 맥락을 처리할 수 있는 능력을 평가하는 엄격한 시험을 제공합니다.

WiC [317]: 이 데이터셋은 맥락에 따라 단어의 의미를 식별하는 모델의 능력을 평가하며, 관련된 작업에 도움이 됩니다.

표 8: 잘 알려진 다양한 사전 훈련 및 미세 조정 데이터셋의 세부 사항. 여기서 alignment는 인간의 선호도와 일치하는 것을 의미합니다.

데이터셋	형태	크기/샘플 작업		직송하	CreationComments C4 [1
0]	사전 훈련	806GB		공통 크롤.	AutomatedA는 수십억 개의 멀티링구얼 데이터셋으로 구성되어 있
4 [11]	사전 학습	38.49TB		커먼 크롤	자동화된 C4의 다국어 확장 mC4 데이터셋은 Common Crawl의 71개 월별 웹 스크랩을 사용하여 cld3로 100개 이상의 언어를 식별합니다.
파일 [301]	사전 학습	825GB		Common Crawl, PubMed Central, OpenWebText2, ArXiv, GitHub, Books3 및 기타들	자동화된 대규모 데이터셋은 22개의 하위 데이터셋 구성 요소
	사전 훈련	1.61TB		498 Hugging Face 데이터셋	자동화된 46개 자연어 및 13개 프로그래밍 언어 구계
대량 텍스트 [116]	프리트레	10.5TB		MassiveWeb, 책, 뉴스, 위키백과, GitHub, C4	99%의 데이터는 영어로 되어 있습니다.
위키백과 [303]	사전 훈련			위키백과	위키백과의 자동 덤프
RedPajama [304]	사전 훈련	5TB		CommonCrawl, C4, Wikipedia, Github, Books, StackExchange의 자동화된 오픈소스 LLaMA 데이터셋 복제품	
PushShift.io Reddit	사전 학습	21.1GB		레딧	Reddit의 자동 제출 및 댓글 2005년부터 2019년까지
BigPython [140]	사전 학습	5.5TB	코딩	GitHub	자동화된
프롬프트 폴 (P3) [17]	지침	12M	62	프롬프트 소스	ManualA는 PromptSource의 하위 집합으로, 다음에서 만들어 177개의 데이터셋이 요약, QA, 분류 등을 포함합니다. xP3 [154]
	지침	81M	71	P3+다국어 데이터셋	ManualExtending P3를 총 46개 언어로 확장하기
Super-NaturalInstructions (SNI) [18] 지침		1,240	1616	여러 데이터셋	ManualExtending P3에 추가 멀티-언어 데이터셋, 총 46개 언어 Flan [16]
	지침	15M	1836	Muffin+T0-SF+NIV2	ManualTotal 60개 언어
OPT-IML [97]	지침	18.1M	1667		매뉴얼
자기 지시 [19]	지침	82k	175		AutomatedGenerated 52k instructions with 82k samples. 175개의 씨앗 작업에서 얻은 샘플, GPT-3 Alp
aca [158]	지침	52k			AutomatedEmployed self-instruct 방법을 사용하여 텍스트-davinci-003에서 수집한 데
이터	지침	125k		ShareGPT	사용자에 의해 공유된 자동화된 대화 ShareGPT는 공용 API를 사용합니
다.	지침	52k		알파카	GPT-4로 자동 생성된 Alpaca 데이터셋 영어와 중국어
Unnatural Instructions [305]	지침	68k		15-Seeds (SNI)	자동화된 - LIMA [
185]	지침	1k		다양한 데이터셋	수동으로 신중하게 만들어진 샘플을 테스트하기 위해 퍼포-데이터가 적은 환경에서의 미세 조정을 통한
성능	정렬	142k			매뉴얼
Anthropic-HH-RLHF-2 [178]	정렬	39k			매뉴얼

단어 의미 불명확성 해결을 위해.

Wikitext103 [318]: 위키백과의 주요 기사에서 추출된 1억 개 이상의 토큰으로 구성된 이 데이터셋은 언어 모델링 및 번역과 같은 장기 의존성을 이해해야 하는 작업에 유용한 풍부한 자원입니다.

PG19 [319]: 이것은 Project Gutenberg의 다양한 책들로 구성된 디지털 도서관입니다. 이는 비지도 학습과 언어 모델링 연구를 촉진하기 위해 특별히 설계되었으며, 긴 형식의 콘텐츠에 특히 중점을 두고 있습니다.

C4 [10]: 깨끗하고 다국어 데이터셋인 C4는 웹 크롤링 데이터에서 수십억 개의 토큰을 제공합니다. 이는 다양한 언어로 고급 Transformer 모델을 훈련시키기 위한 포괄적인 자원입니다.

LCQMC [320]: 대규모 중국어 질문 매칭 코퍼스(LCQMC)는 의미 매칭 작업에서 모델의 성능을 평가하기 위한 데이터셋입니다. 이 데이터셋은 중국어로 된 질문 쌍과 그들의 매칭 상태를 포함하고 있어, 중국어 이해 연구에 유용한 자원입니다.

5.2.3. 스토리 클로즈 및 문장 완성

StoryCloze [334]: 새로운 “StoryCloze Test”를 도입하여 이야기를 이해하고 생성하며 스크립트 학습을 평가하기 위한 상식 추론 프레임워크입니다. 이 모델은

일관되고 의미 있는 이야기를 이해하고 생성하는 능력.

LAMBADA [335]: 이 데이터셋은 단어 예측 작업을 통해 맥락적 텍스트 이해를 평가합니다. 모델은 글의 마지막 단어를 예측해야 하는데, 이는 전체 문단이 주어질 때 인간에게는 쉽지만 마지막 문장만 주어질 때는 어렵습니다.

5.2.4. 물리적 지식과 세계 이해

PIQA [340]: 모델의 물리적 지식을 탐구하는 데이터셋으로, 그들이 실제 세계에 대해 얼마나 잘 배우고 있는지를 이해하는 것을 목표로 합니다.

TriviaQA [341]: 정보 검색(IR) 스타일의 질문 답변(QA) 작업에 초점을 맞추도록 해 및 개방형 질문 응답(QA) 작업에서 모델을 평가하는 데이터셋입니다.

ARC [342]: ARC-Challenge의 확장판으로, 이 데이터셋은 쉬운 것과 도전적인 초등학교 수준의 객관식 과학 질문을 모두 포함하고 있습니다. 이는 모델의 복잡한 질문을 이해하고 대답하는 능력을 종합적으로 테스트하는 것입니다

ARC-Easy [342]: ARC 데이터셋의 하위 집합인 ARC-Easy는 검색 기반 알고리즘이나 단어 공기 발생 알고리즘에 의해 올바르게 답변되는 질문을 포함하고 있습니다.

표 9: LLM 평가에 사용된 분류된 평가 데이터셋.

유형	데이터셋/벤치마크
멀티 태스크	MMLU [307], SuperGLUE [2], BIG-bench [308], GLUE [309], BBH [308], CUGE [310], Zero-CLUE [311], FewCLUE [312], Blended Skill Talk [313], HELM [314], KLUE-STS [315]
언어 이해	CoQA [316], WiC [317], Wikitext103 [318], PG19 [319], LCQMC [320], QQP [321], WinoGender [322], CB [323], FinRE [324], SanWen [325], AFQMC [311], BQ Corpus [326], CNSS [327], CKBQA 13 [328], CLUENER [311], Weibo [329], AQuA [330], OntoNotes [331], HeadQA [332], Twitter Dataset [333] Story Cloze 및
문장 완성	StoryCloze [334], LAMBADA [335], LCSTS [336], AdGen [337], E2E [338], CHID [339], CHID-FC [312]
물리적 지식과 세계 이해	PIQA [340], TriviaQA [341], ARC [342], ARC-Easy [342], ARC-Challenge [342], PROST [343], Open-BookQA [344], Web NLG [345], DogWhistle Insider & Outsider [346]
맥락적 언어 이해하기	RACE [347], RACE-Middle [347], RACE-High [347], QuAC [348], StrategyQA [349], Quiz Bowl [350], cMedQA [351], cMedQA2 [352], MATINF-QA [353]
상식적 추론	WinoGrande [354], HellaSwag [355], COPA [356], WSC [357], CSQA [358], SIQA [359], C3 [360], CLUEWSC2020 [311], CLUEWSC [311], CLUEWSC-FC [312], ReCoRD [361]
독해 능력	SQuAD [362], BoolQ [363], SQUADv2 [364], DROP [365], RTE [366], WebQA [367], CMRC2017 [368], CMRC2018 [369], CMRC2019 [370], COTE-BD [371], COTE-DP [371], COTE-MFW [371], MultiRC [372], Natural Questions [373], CNSE [374], DRCD [374], DuReader [375], Dureaderrobust [376], DuReader-QG [375], SciQ [377], Sogou-log [378], Dureaderrobust-QG [376], QA4MRE [379], KorQuAD 1.0 [380], CAIL2018-Task1 & Task2 [381].
수학적 추론	MATH [382], Math23k [383], GSM8K [384], MathQA [385], MGSM [386], MultiArith [387], AS-Div [388], MAWPS [389], SVAMP [390]
문제 해결	HumanEval [141], DS-1000 [391], MBPP [392], APPS [382], CodeContests [142]
자연어 추론 및 논리적 추론	ANLI [393], MNLI-m [394], MNLI-mm [394], QNLI [362], WNLI [357], OCNLI [311], CMNLI [311], ANLI R1 [393], ANLI R2 [393], ANLI R3 [393], HANS [395], OCNLI-FC [312], LogiQA [396], StrategyQA [349]
교차 언어 이해 MLQA [397], XNLI [398]	PAWS-X [399], XSum [400], XCOPA [401], XWinograd [402], TyDiQA-GoldP [403], MLSum [404]
진실성과 사실 확인 TruthfulQA [405], MultiFC [406], Fever에 관한 사실 확인 [407]	
AI의 편향성과 윤리	ETHOS [408], StereoSet [409], BBQ [410], Winobias [411], CrowS-Pairs [412]
독성	RealToxicityPrompts [413], CivilComments toxicity classification [414]
언어 번역	WMT [415], WMT20 [416], WMT20-enzh [416], EPRSTMT [312], CCPM [417]
과학적 지식	AminoProbe [148], BioLAMA [148], Chemical Reactions [148], Galaxy Clusters [148], Mineral Groups [148]
대화	위키피디아의 마법사 [418], 공감 대화 [419], DPC 생성 대화 [96], ConvAI2 [420], KdConv [421]
주제 분류	TNEWS-FC [312], YNAT [315], KLUE-TC [315], CSL [311], CSL-FC [312], IFLYTEK [422]

모델들이 고급 질문 응답을 탐색하기 시작하는 데 있어 훌륭한 출발점입니다.

ARC-Challenge [342]: 철저한 질문-답변 데이터셋인 ARC-Challenge는 단순 조회를 넘어서는 추론을 요구하는 복잡한 학년 수준의 질문들을 포함하여 모델의 진정한 이해 능력을 테스트합니다.

5.2.5. 맥락적 언어 이해

RACE [347]: RACE 데이터셋은 중국의 영어 시험에서 수집된 독해 데이터셋으로, 긴 복잡한 지문에 대한 질문을 이해하고 대답하는 AI 모델을 평가하여 실제 시험의 도전을 시뮬레이션합니다.

RACE-Middle [347]: RACE [347] 데이터셋의 또 다른 하위 집합인 RACE-Middle은 중학교 수준의 영어 시험 문제를 포함하고 있습니다. 이는 모델의 이해력을 평가하는 데 있어 약간 덜 도전적이지만 학문적으로 지향적인 평가를 제공합니다.

RACE-High [347]: RACE [347] 데이터셋의 하위 집합으로, RACE-High는 고등학교 수준의 영어 시험 문제로 구성되어 있습니다.

모델의 이해 능력을 더 학문적이고 도전적인 맥락에서 평가하기 위해 설계되었습니다.

QuAC [348]: 이 데이터셋은 숨겨진 Wikipedia 텍스트를 사용하여 학생과 교사 간의 정보 탐색 대화를 시뮬레이션합니다. 이는 기계 독해 데이터셋에서 발견되지 않는 독특한 도전 과제를 도입하여 대화 시스템을 발전시키는 데 귀중한 자원이 됩니다.

5.2.6. 상식적 추론

HellaSwag [355]: 모델이 문맥에 가장 적합한 결말을 선택하도록 도전하는 데이터셋은 Adversarial Filtering을 사용하여 생성된 텍스트가 인간에게는 비논리적이지만 종종 모델에 의해 잘못 분류되는 복잡성의 'Goldilocks' 영역을 만듭니다.

COPA [401]: 이 데이터셋은 모델의 개방형 상식 인과 추론에서의 진행 상황을 평가합니다. 각 질문은 전제와 두 개의 대안으로 구성되며, 모델은 더 그럴듯한 대안을 선택해야 하며, 이는 모델이 원인과 결과에 대해 이해하고 추론하는 능력을 테스트합니다.

WSC [357]: Winograd Schema Challenge (WSC)는

표 10: 사전 학습된 LLM이 사용하는 훈련 데이터셋과 평가 작업의 예시입니다. 여기서 “QA”는 질문-응답을, “Clf”는 분류를, “NLI”는 자연어 추론을, “MT”는 기계 번역을, “RC”는 독해를, “CR”은 상식 추론을, “MR”은 수리적 추론을, “Mem.”은 암기를 의미합니다.

모델들	훈련 데이터셋	기준치										진실한/ 편향/ 독성/ 메모.
		BIG-bench	MMLU	SuperGLUE	QACliff	NLI	MT	Clf	RC	MR	Coding	
T5	C4 [10]			최종하지만, 제가 번역할		최종하지만	최	최	GPT-3			최
mT5	mC4 [11]			최		최종하지만						
PanGu-α	1.1TB 중국어 텍스트 코퍼스			최		번		해	✓✓			
CPM-2	WuDaoCorpus [109]								최		코	
텍스	5,400만 개의 공개 리포지토리에서 Github											E
RNIE-3.0	중국어 텍스트 코퍼스, Baidu Search, 웹 텍스트, QA-long, QA-short, 시 및 구절, 의료, 법률 및 금융 분야의 도메인 특정 데이터, 5천만 개 이상의 사실이 담긴 Baidu 지식 그래프			최종합니다, 하지만 주어	진 문장을 번		최	최		최		
주라식-1	위키백과, OWT, Books, C4, Pile [301], arXiv, GitHub			최		최		최	최			
HyperCLOVA	한국 블로그, 커뮤니티 사이트, 뉴스, KIN 한국어 위키백과, 위키백과 (영어와 일본어), Modu-Corpus: 메신저, 뉴스, 구어체 및 문어체 언어 말뭉치, 웹 말뭉치					최						
위안 1.0	Common Crawl, SogouT, Sogou News, Baidu Baike, Wikipedia, Books			번역할 문장이	없습				최			
고퍼	MassiveWeb의 서브셋인 Books, C4, News, GitHub 및 Wikipedia 샘플을 MassiveText에서 가져왔습니다.	최	최	최종하지만						번역할 문		최
ERNIE-3.0 TITAN은 ERNIE 3.0과 ERNIE 3.0 광고와 동일합니다. 대립적 데이터셋, ERNIE 3.0 제어 가능한 데이터셋						정확한 영어 문장이		최	최			
GPT-NeoX-20B Pile [301]				최종하지만,		최		최		최적화		
	RoBERTa [299], Pile [301], PushShift.io 레딧 [423]				최종하지					최		최
블룸	ROOTS [13]			최		최종하지만		최			최	갈
렉티카	arXiv, PMC, Semantic Scholar, Wikipedia, StackExchange, LibreText, Open Textbooks, RefSeq Genome, OEIS, LIPID MAPS, NASA Explorer, Common Crawl, Scientific CC, Academic CC, GitHub repositories, Khan Problems, GSM 8K, OneSmallStep	최	최		최						최	입
GLaM	필터링된 웹페이지, 소셜 미디어 대화, Wikipedia, 포럼, 책, 뉴스				최		최		문	최종하지		
LaMDA	Infiniset: 공공 문서, 대화, 발화											최
MT-NLG	Common Crawl과 두 개의 스냅샷, Books3, Open WebText2, Stack Exchange, PubMed Abstracts, Wikipedia, PG-19 [242], BookCorpus2, NIH ExPorter, Pile, CC-Stories, RealNews.						최		최	최종합니		번
알파코드	선택된 GitHub 리포지토리, CodeContests: Codeforces, Description2Code, CodeNet.											번
친칠라	MassiveWeb, MassiveText Books, C4, News, GitHub, Wikipedia	번	최		최					최종하지		최
PaLM	웹페이지, 책, Wikipedia, 뉴스, 기사, 소스 코드, 소셜 미디어 대화	최			최		최			최		번
AlexaTM	위키백과, mC4			최		최종하지만				최		U
-PaLM	PaLM과 동일합니	전		최종하지만,		최		최	UL2			
				번역할 문장을	제공해 주시면						최	G
LM-130B		최	최						최			
코드젠	파일, BigQuery, BigPython											✓
LLaMA	CommonCrawl, C4, Github, Wikipedia, 책, arXiv, StackExchange		최		최					번역할 문장이	제공	자
PanGu-Σ	WuDaoCorpora, CLUE, Pile, C4, Python 코드			최종하지만,	번역할 텍스트			최				해
BloombergGPT	inPile, Pile, C4, Wikipedia	최	당					최		최종하지		✓
CodeT5+	CodeSearchNet, Github Code										최	스
타코더	The Stack v1.2		최								번	최
LaMA-2	최	최		최						입력된 영어 문장이	✓	
	웹 문서, 코드, 책, 수학, 대화			최종합니다, 하지만 제공된 영어 문장				최		최종하지만 번역할	최	최

표 11: 세부 조정된 LLM에서 사용된 훈련 데이터셋과 평가 벤치마크의 예시. "SNI"는 Super-NaturalInstructions의 약어입니다.

모델들	훈련 데이터셋	BIG-bench	MMLU	BHRAFT	FLAN	SNI	PromptSource	TyDiQA	HumanEval	MBPP	Bias/	진실한/독성
T0	프롬프트 모음	죄										죄
웹GPT	ELI5[424], ELI5 fact-check[166], TriviaQA[341], ARC-Challenge[342], ARC-Easy[342], 손으로 작성된 데이터, 인간의 시연, 모델 생성 답변 간의 비교											
Tk-INSTRUCTSNI [18]	xP3 [154]							✓				
OPT-IML	PromptSource [17], FLAN [16], SNI[425], UnifiedSKG[426], CrossFit[427], ExMix[428], T5 [10], Reasoning		죄	죄	번	죄	죄		죄			
플란	머핀, T0-SF, Niv2, CoT		죄	죄					제			
WizardCoderCodeAlpaca										죄	죄	

텍스트에서 참조를 해결해야 하는 시스템의 독해 작업으로, 종종 세계 지식과 텍스트에 대한 추론이 필요하다.

CSQA [358]: CommonsenseQA는 AI 모델이 질문을 이해하고 대답하는 능력을 평가하기 위해 상식 지식을 요구하는 질문-응답 데이터셋입니다.

5.2.7. 독해 검사

BoolQ [363]: Google 검색 쿼리에서 유래된 데이터셋인 BoolQ는 모델이 이진(예/아니오) 질문에 답하도록 도전합니다. 질문들은 자연스럽게 발생하며, 답이 포함된 위키피디아 기사에서 발췌된 단락과 쌍을 이룹니다. 이는 독해력과 추론을 시험하는 것입니다.

SQUADv2 [364]: 스탠포드 질문 답변 데이터셋(SQuAD) [362]는 크라우드 워커들이 특정 위키피디아 기사에 대해 제기한 질문들의 모음으로, 각 질문의 답은 해당 읽기 구절의 텍스트 일부입니다. SQuADv2는 원래의 SQuAD1.1 데이터셋과 50,000개 이상의 대답할 수 없는 질문을 결합하여 구성됩니다. 이 데이터셋의 목적은 모델이 주어진 맥락에 기반하여 질문을 이해하고 답변하는 능력을 평가하고, 질문이 대답할 수 없는 경우를 판별하는 것입니다.

DROP [365]: DROP, 또는 단락 내용에 대한 이산 추론(Discrete Reasoning Over the content of Paragraphs)은 모델이 다양한 독서 현상을 이해하는 능력을 테스트하기 위해 설계되었습니다. 이는 독해 능력에 대한 포괄적이고 신뢰할 수 있는 평가를 촉진합니다.

RTE [366]: 텍스트 수용성 인식(RTE) 데이터셋은 주어진 문장이 다른 문장에서 논리적으로 따르는지를 예측하고 텍스트 내 논리적 관계에 대한 모델의 이해를 평가하는 텍스트 수용성에 관한 일련의 연례 경연 대회에서 나왔습니다.

WebQA [367]: 오픈 도메인 질문 응답을 위한 데이터셋인 WebQA는 웹 기반의 질문-답변 쌍을 대량으로 제공하며, AI 모델이 웹 콘텐츠를 기반으로 질문을 이해하고 답변하는 능력을 평가하도록 설계되었습니다.

CMRC2018 [369]: 이 데이터셋은 중국어 언어 모델의 종합적인 추론 능력을 테스트하기 위해 만들어졌으며, 경계선을 넘어서 도전적인 범위 추출 형식을 가지고 있습니다.

기계 성능.

5.2.8. 수학적 추론

MATH [382]: 이 데이터셋은 AI 모델의 수학 문제 해결 능력을 평가하기 위한 플랫폼입니다. 사칙연산부터 미적분학에 이르는 다양한 수학 문제가 포함되어 있으며, 모델이 복잡한 수학 문제를 이해하고 해결하는 능력을 테스트하기 위해 설계되었습니다.

Math23k [383]: 이 데이터셋은 모델이 수학 문제를 이해하고 해결하는 능력에 도전합니다. 23,000개의 중국어 산술 문제를 포함하고 있으며, 모델은 문제 설명에 기반하여 추론 및 계산을 수행해야 합니다.

GSM8K [384]: 다양한 초등학교 수학 문제로 구성된 데이터셋으로, 모델이 다단계 수학적 추론을 수행하는 능력을 테스트합니다.

5.2.9. 문제 해결 및 논리적 추론

ANLI [393]: 자연어 추론(NLI)에서 기계 학습 모델의 강건성을 테스트하기 위해 설계된 대규모 데이터셋이 인간이 모델이 올바르게 분류할 수 없는 예제를 생성하려고 시도하는 반복적이고 적대적인 과정을 통해 생성된다.

HumanEval [141]: AI 모델의 문제 해결 능력을 평가하기 위한 데이터셋으로, 다양한 인지 능력을 요구하는 여러 가지 과제를 포함하고 있어 AI의 일반 지능을 평가하는 포괄적인 도구입니다.

StrategyQA [349]: 여러 증거를 통해 추론해야 하는 질문-응답 데이터셋으로, AI 모델의 전략적 추론 능력을 평가하며 기계가 이해하고 답변할 수 있는 한계를 넓히고 있습니다.

5.2.10. 교차 언어 이해

XNLI [398]: XNLI는 다국어 벤치마크로, MultiNLI [429] 코퍼스를 15개 언어로 확장하였으며, 여기에는 우르두와 같은 저자원 언어도 포함됩니다. 이는 교차 언어 문장 이해를 위한 모델을 테스트하며, 112,500개의 주석이 달린 쌍으로 세 가지 범주인 합의, 모순, 중립에 대해 평가합니다.

PAWS-X [399]: PAWS-X, 즉 단어 섞기에서 파생된 교차 언어의 패러프레이즈 적대자는 다국어 버전입니다.

PAWS [430] 데이터셋은 패러프레이즈 식별을 위한 것으로, 7개 언어의 예제를 포함하고 있으며, 교차 언어 패러프레이즈 식별 모델의 성능을 평가하기 위해 설계되었습니다.

5.2.11. 진실성

Truthful-QA [405]: 답변을 생성할 때 언어 모델의 진실성을 측정하는 독특한 기준입니다. 이 데이터셋은 건강, 법률, 정치 등 다양한 범주의 질문을 포함하고 있으며, 일부는 일반적인 인간의 오해에 대해 모델을 테스트하기 위해 설계되었습니다.

5.2.12. AI의 편향성과 윤리

ETHOS [408]: ETHOS는 YouTube와 Reddit 댓글로부터 구축된 혐오 발언 탐지 데이터셋입니다. 온라인 혐오 발언과의 싸움을 위한 도구로, 강력한 콘텐츠 관리를 위해 이진 및 다중 라벨 변형을 제공합니다.

StereoSet [409]: StereoSet는 언어 모델에서의 고정관념 편향의 존재를 측정하고 평가하기 위해 설계된 종합적인 데이터셋입니다. 이 데이터셋은 성별, 직업, 인종, 종교라는 네 가지 주요 분야에 초점을 맞추고 있습니다. 언어 모델링 능력에 대한 고정관념 편향을 대비시키는 것은 대규모 언어 모델의 편향을 이해하고 완화하는 데 유용한 도구를 제공합니다.

6. 응용 프로그램

대규모 언어 모델(LLMs)을 다양한 다운스트림 작업에 적용하는 것이 AI 관련 연구 커뮤니티와 산업에서 인기 있는 트렌드가 되었으며, 매일 새로운 사용 사례가 발견되고 탐구되고 있습니다. 사람과 유사한 텍스트를 이해하고 생성할 수 있는 LLM은 여러 분야에서 의미 있는 응용 프로그램을 찾았습니다. 이 섹션에서는 의학, 교육, 과학, 수학, 법률, 금융, 로봇공학 및 코딩에서 LLM의 응용 프로그램에 대한 개요를 제공합니다. 각 분야마다 다른 도전 과제가 있지만, LLM은 그 일반화 가능성을 통해 이러한 분야에 중요한 기여를 할 수 있는 기회를 열어줍니다.

일반적인 목적: LLM은 다양한 작업의 일반적인 도구로 널리 고려되고 있습니다. 이는 그들이 맥락적으로 관련된 방식으로 인간과 유사한 텍스트를 이해하고 생성하며 조작하는 고유한 능력 때문입니다. 이를 통해 간단한 언어 번역과 질문-응답부터 요약, 텍스트 생성 및 프로그래밍 도움과 같은 더 복잡한 작업까지 수행할 수 있습니다. LLM의 유용성은 그들이 처리 중인 텍스트의 특정 스타일과 어조에 적응할 수 있는 능력에 의해 더욱 향상되어, 출력 결과가 사용자 친화적이고 맥락을 인식하게 만듭니다. 일상 응용 프로그램에서 LLM은 개인 비서로 사용되어 사용자가 이메일을 작성하거나 약속을 잡는 데 도움을 줄 수 있습니다; 또한 고객 서비스에 배치되어 일반적인 질문을 처리하거나 주어진 프롬프트를 기반으로 인간과 유사한 텍스트를 생성하여 웹사이트와 같은 디지털 플랫폼을 위한 콘텐츠를 생성하는 데 적용될 수 있습니다. 더욱이 LLM은 데이터 분석에서 중요한 역할을 하여 대량의 텍스트 데이터를 필터링하고, 주요 포인트를 요약하며, 사람들이 인식하는 데 훨씬 더 오랜 시간이 걸리는 패턴을 찾아낼 수 있습니다. 광범위한 응용 프로그램에도 불구하고 LLM이 존재하는 것을 잊지 않는 것이 중요합니다.

모든 AI 시스템과 마찬가지로, 그들이 훈련받은 데이터의 품질에 따라 성능이 좌우된다.

의학: LLM의 의학 분야에 대한 적용은 의료 서비스와 연구를 재구성하고 있습니다. 예를 들어, LLM은 의사들에게 근거 기반 치료 권고를 제공하기 위해 임상 결정 지원 시스템에서 점점 더 많이 사용되고 있습니다 [436, 437, 438]. 환자 데이터와 의학 문헌을 분석함으로써 LLM은 잠재적 진단을 식별하고, 적절한 검사를 제안하며, 최적의 치료 전략을 권장하는 데 도움을 줄 수 있습니다. 뿐만 아니라, LLM은 환자와 의료 시스템 간의 상호작용을 향상시킬 수도 있습니다. 예를 들어, LLM은 챗봇 애플리케이션에서 [439, 440, 441] 사용되어 증상이나 약물에 대한 환자의 질문에 답변하고, 약속을 잡고, 심지어 필수 건강 조언을 제공할 수 있습니다. 의학 연구에 있어 LLM은 상당한 양의 의학 문헌에서 정보를 추출하고 필터링하며, 관련 연구를 식별하고, 결과를 요약하며, 미래의 연구 동향을 예측하는 데 사용됩니다 [442, 443, 444]. 의학 교육을 위해 LLM은 교육 자료 생성, 시험 문제 작성, 복잡한 의학 주제에 대한 자세한 설명 제공, 학생들에게 개인화된 피드백 제공 등을 도와줄 수 있습니다 [445, 446, 447, 448]. 또한 LLM은 환자 상호작용을 시뮬레이션하여 학생들이 임상 기술을 연습하고 향상시킬 수 있게 합니다. 더 넓은 차원에서 LLM은 매체 데이터를 분석하여 질병 발생을 감지하고, 건강 정책에 대한 대중의 감정을 모니터링하며, 명확하고 이해하기 쉬운 방식으로 건강 정보를 전파함으로써 공공 건강 이니셔티브를 지원할 수 있습니다 [449]. LLM은 데이터 프라이버시, 설명 가능성의 필요성, 편향 전파의 잠재적 위험과 같은 관련 문제를 다루며 공공 건강 이니셔티브를 지원하는 데 활용될 수 있습니다 [450, 451].

교육: LLM의 교육 분야 통합은 학습 경험, 교사 지원 및 교육 콘텐츠 개발을 향상시킬 수 있는 기회를 제공합니다. 학생들에게 LLM은 학습 스타일, 성과 및 선호도를 분석하여 맞춤형 학습 자료와 연습 문제를 제공함으로써 개인화된 학습 경험을 개발할 수 있습니다 [452]. 교사에게 LLM은 수업 계획을 만들고 과제를 채점하며 다양하고 포괄적인 교육 콘텐츠를 생성하는 데 도움을 줄 수 있어, 교육 및 학생 상호작용을 위한 시간을 크게 절약합니다 [453, 454]. 언어 학습에서 LLM은 여러 언어로 대화를 시뮬레이션하고 문법을 수정하며 어휘를 확장하고 발음을 돕는 고급 대화 파트너 역할을 하여 유창성을 위해 필요한 연습을 지원합니다 [455]. 또한, LLM은 장애가 있는 학생들을 위한 지원을 제공하여 교육의 접근성을 개선합니다. 청각 장애인을 위한 실시간 기록을 생성하고 시각 장애인을 위한 독서 지원을 제공하며 학습 장애가 있는 이들을 위해 복잡한 텍스트를 단순화할 수 있습니다 [451]. LLM이 계속 발전함에 따라 교육 분야에서의 그 응용은 실전에서 다양한 관점으로 더 많은 학생과 교사에게 혜택을 줄 수 있습니다.

과학: 의료 응용과 유사하게, LLM은 과학 문헌을 신속하게 분석하고 요약함으로써 연구 과정을 가속화할 수 있다. 이해하기 쉽고 접근 가능한 연구 요약을 제공함으로써 LLM은 연구자들이 자신의 전문 분야 외에도 최신 발견을 파악하는 데 도움을 줄 수 있다 [456, 457]. 또한, LLM은 과학자들을 지원할 수 있다.

표 12: 다양한 NLU 및 NLG 작업에서 최고 성능 LLM들의 성능 비교. 여기서 "N-Shots"는 평가 동안 모델에 제공된 예시 프롬프트의 수를 나타내며, 이는 적은 예시 또는제로 샷 학습 환경에서의 능력을 나타냅니다. "f"는 미세 조정된 버전을 의미하고, "B"는 기준을 나타냅니다.

작업	데이터셋/벤치마크	상위 1		상위 2		Top-3	
		모델 (크기) 점수 (N-샷)	모델 (크기) 점수 (N-샷)			모델 (사이즈)	점수 (N-shots)
다중 작업	BIG-bench (B)	치칠라 (70B) 65.1 (5샷)	고퍼 (280B) 53.97 (5샷)			PaLM (540B)	53.7 (5-shot)
	MMLU (B)	GPT-4 (-)	86.4 (5-shot)	Gemini (Ultra) 83.7 (5-shot)	Flan-PaLM-2 (f) (Large)	81.2 (5-shot)	Language Understanding Sup
erGLUE (B)		ERNIE 3.0 (12B)	90.6 (-)	PaLM(f) (540B)	90.4 (-)	T5 (11B)	88.9 (-)
이야기 이해 및 세대	HellaSwag	GPT-4 (-)	95.3 (10-shot)	Gemini (Ultra) 87.8 (10-shot)		PaLM-2 (Large)	86.8 (한 번에)
	StoryCloze	GPT3 (175B) 87.7	(few shot)	PaLM-2 (Large) 87.4	(one shot)	OPT (175B)	79.82 (-)
물리적 지식과 세계 이해	PIQA	PaLM-2 (Large) 85.0	(원샷)	LLaMa (65B) 82.8	(제로샷)	MT-NLG (530B)	81.99 (zero shot)
	TriviaQA	PaLM-2 (대형) 86.1	(원샷)	LLaMa-2 (70B) 85.0	(원샷)	PaLM (540B)	81.4 (one shot)
맥락적 언어 이해하기	람바다	PaLM (540B) 89.7	(few shot)	MT-NLG (530B) 87.15	(few shot)	PaLM-2 (Large)	86.9 (원샷)
상식적 추론 WinoGrande		GPT-4 (-)	87.5 (5-shot)	PaLM-2 (Large) 83.0	(one shot)	PaLM (540B)	81.1 (제로 샷)
	SIQA	LLaMA (65B) 52.3	(제로샷)	Chinchilla (70B) 51.3	(제로샷)	고퍼 (280B)	50.6 (zero shot)
독해 이해 BoolQ		PaLM(f) (540B)	92.2 (-)	T5 (11B)	91.2 (-)	PaLM-2 (Large)	90.9 (one shot)
진실성	진실한 질문-답	LLaMA (65B)	57 (-)				
수리적 추론 MATH		Gemini (Ultra) 53.2	(4-shot)	PaLM-2 (Large) 34.3	(4-shot)	LLaMa-2 (65B)	13.5 (4-shot)
	GSM8K	GPT-4 (-)	92.0 (5-shot)	PaLM-2 (Large) 80.7	(8-shot)	U-PaLM (540B)	문제 해
결 및 논리적 추론	HumanEval	Gemini(f) (Ultra) 74.4	(zero shot)	GPT-4 (-)	67.0 (제로샷)	Code Llama (34B)	48.8 (zero shot)

대규모 데이터 세트를 처리하는 능력이 인간 연구자에게는 즉각적으로 드러나지 않을 수 있는 통찰을 밝혀내기 때문에 새로운 가설과 연구 질문을 formul하는 데 중요한 역할을 한다 [458]. 게다가 LLM은 과학적 글쓰기를 위해 연구자가 문서를 작성하고 개선 사항을 제안하며 특정 형식 가이드라인을 준수하도록 도와줄 수 있다 [459, 460]. 이는 시간을 절약할 뿐만 아니라 과학적 소통의 명확성을 향상시켜, 여러 분야의 팀이 보다 효과적으로 협력할 수 있게 한다.

수학: 수학 연구 및 교육 지원을 제공하는 것 외에도, LLM은 단계별 설명을 통해 수학 문제를 해결하고 복잡한 증명과 계산을 안내함으로써 도움을 줄 수 있습니다. LLM은 추론이나 계산에서 오류를 식별하고 수정을 제안하여 학습 및 검증 목적 모두에 있어 귀중한 도구로 작용합니다 [461, 462]. LLM은 수학적 증명의 유효성을 확인하는 데 사용될 수 있으며, 이는 인간 검토 이전의 예비 필터 역할을 합니다. LLM은 수학자들의 면밀한 작업을 대체할 수는 없지만, 증명 검증 과정을 간소화하는 데 도움을 줄 수 있습니다 [463, 464]. 게다가, LLM은 비전문가가 이해할 수 있는 언어로 복잡한 개념과 발견을 번역함으로써 수학의 접근성을 높입니다 [465]. 이로 인해 이론 수학과 물리학, 공학, 경제학과 같은 응용 맥락 사이의 간극이 해소될 수 있습니다.

법: LLM은 법적 문서의 주제 분석을 지원할 수 있으며, 여기에는 데이터 세트를 위한 초기 코딩 생성, 주제 식별 및 이러한 주제에 따라 데이터 분류가 포함됩니다. 법률 전문가와 LLM 간의 이러한 협력 노력은 절도에 대한 법원 의견과 같은 법률 텍스트 분석에 효과적임이 입증되어 연구의 효율성과 질을 모두 향상시켰습니다 [466]. 또한, LLM은 법률 용어에 대한 설명 생성을 평가받았으며, 이는 판례에서 문장을 통합하여 사실 정확성과 관련성을 개선하는 데 중점을 두었습니다. 관련 판례를 LLM에 입력하면 향상된 모델이 사실적으로 부정확한 정보가 적은 더 높은 품질의 설명을 생성할 수 있습니다 [467]. 게다가 LLM은 전문 분야 지식을 활용하여 훈련될 수 있습니다.

법적 추론 작업을 수행하고 [468] 법적 질문에 답변하다 [469].

재무: BloombergGPT [151]와 같은 LLM은 광범위한 독점 재무 데이터셋으로 훈련되어 재무 작업에서 우수한 성능을 보여줍니다. 이는 특정 분야의 훈련이 산업 특유의 언어와 개념을 보다 정확하게 이해하고 처리할 수 있는 LLM을 만드는 데 가치가 있음을 나타냅니다. FinGPT [470]의 오픈 소스 모델 도입은 로보 어드바이징, 알고리즘 트레이딩, 로우 코드 솔루션과 같은 새로운 응용 프로그램을 개발하기 위한 투명하고 접근 가능한 자원을 제공하여 궁극적으로 금융 서비스의 역량을 확장합니다. BloombergGPT와 FinGPT 모두 재무 분야에 대한 LLM의 적응성을 보여주며, 전자는 맞춤형 데이터셋의 힘을 보여주고 후자는 데이터 중심 접근 방식과 맞춤화를 위한 저계수 변환 기술을 강조합니다. 또한, LLM은 복잡한 재무 작업을 실행 가능한 계획으로 나누는 능력을 보여주어 이전에는 단일 모델로는 실행할 수 없었던 종단 간 솔루션을 가능하게 합니다 [471].

로보틱스: 로보틱스 연구에서 LLM은 인간-로봇 상호작용 [28, 472, 473, 474], 작업 계획 [237], 움직임 계획 [246], 내비게이션 [246, 475], 객체 조작 [236], 개인화된 로봇 [476] 등과 같은 유망한 응용 프로그램을 가지고 있다. LLM은 로봇이 환경을 효과적으로 이해하고 협력하여 작업을 완료하기 위한 계획을 수립할 수 있도록 돕는다 [240, 26]. 또한, LLM은 로봇이 다양한 출처에서 정보를 접근하고 통합할 수 있게 하여 지속적인 학습을 촉진하고, 로봇이 새로운 기술을 습득하고 변화에 적응하며 경로를 개선할 수 있도록 돕는다 [224, 233, 234].

7. 도전과 미래 방향

GPT-4와 그 이전 모델들처럼 LLM은 자연어 처리 분야에서 상당한 발전을 이루었습니다. 그럼에도 불구하고 이러한 모델들은 일련의 도전 과제를 동반합니다. 계산 비용, 적대적 강건성, 해석 가능성은 이 모델들에 내재된 기술적 도전 과제 중 일부입니다. 또한, 이 모델들이 더 복잡한 작업을 처리할 수 있도록 확장됨에 따라

복잡하거나 역동적인 환경에서 작업을 하거나 기능을 수행하는 데 있어, 확장성, 개인 정보 보호 및 실시간 처리와 관련된 새로운 도전 과제가 발생합니다. 기초 연구의 최전선에서 다중 양식 통합과 전이 학습의 효용성이 면밀히 탐구되고 있습니다. 또한, 시간이 지남에 따라 새로운 정보에 적응할 수 있는 모델을 목표로 하는 이러한 모델의 지속적 학습 특성은 새로운 도전 과제를 제시합니다. 이러한 도전 과제는 기술적 복잡성을 강조할 뿐만 아니라 현실 세계 응용에서 LLM의 광범위한 영향과 미래 경로를 부각시킵니다. 다음 섹션에서는 이러한 도전 과제에 대해 깊이 탐구하고, 이를 해결하기 위한 지속적인 노력과 잠재적 노력을 조명합니다.

계산 비용: LLM을 훈련하는 데는 방대한 컴퓨터 자원이 필요하며, 이는 생산 비용을 증가시키고 대규모 훈련 중 상당한 에너지 소비로 인해 환경 문제를 야기합니다. 컴퓨터 자원이 증가함에 따라 성능이 향상되지만, 모델과 데이터셋의 크기가 고정된 상태에서 개선 비율은 점차 감소하며 이는 수확 체감의 법칙을 따릅니다 [477].

편향과 공정성: LLM은 훈련 데이터에서 사회적 편향을 물려받고 이를 증폭시킬 수 있습니다. 이러한 편향은 모델의 출력에 나타날 수 있으며, 이는 잠재적인 윤리적 및 공정성 문제를 초래합니다 [478].

과적합: LLM은 상당한 학습 능력을 가지고 있지만, 방대한 훈련 데이터에서 노이즈가 많거나 특이한 패턴에 과적합하기 쉬운 경향이 있습니다. 결과적으로 이러한 특성 때문에 비논리적인 응답을 생성할 수 있습니다 [479]. LLM에서 기억과 일반화에 대한 논쟁은 올바른 균형을 찾는 것입니다. 기억은 모델이 훈련 데이터에서 특정 세부 사항을 기억하게 하여 정확한 질문에 대한 정확한 답변을 제공할 수 있도록 합니다. 그러나 일반화는 모델이 이전에 보지 못한 입력에 대해 추론하고 응답을 생성할 수 있게 하여 다양한 실제 작업을 처리하는 데 필수적입니다. 올바른 균형을 찾는 것이 도전 과제입니다: 너무 많은 기억은 과적합으로 이어질 수 있으며, 이는 모델이 유연성을 잃고 새로운 입력에 어려움을 겪게 만듭니다 [480].

경제 및 연구 불평등: LLM을 훈련하고 배포하는 높은 비용은 그 개발이 자금이 풍부한 조직에 집중되게 할 수 있으며, 이는 AI에서 경제 및 연구 불평등을 악화시킬 가능성이 있습니다 [481].

추론 및 계획: 일부 추론 및 계획 작업은, 심지어 인간이 쉽게 생각하는 상식적 계획과 같은 간단해 보이는 것조차, 평가 프레임워크를 사용해 평가한 현재 LLM의 능력을 훨씬 넘어섭니다. 이는 LLM이 주로 가능성에 기반해 텍스트 완성을 생성하며 추론 능력에 대한 확실한 보장을 제공하지 않는다는 점을 고려할 때 전혀 놀라운 일이 아닙니다 [482].

환각: LLM들은 "환각"을 나타내는데, 여기서 그들은 그럴듯하게 들리지만 잘못된되거나 제공된 정보와 일치하지 않는 응답을 생성합니다 [483]. 환각은 세 가지 범주로 분류될 수 있습니다.

- 입력과 상충하는 홀로그램 현상으로, LLM이 사용자로부터 제공된 입력과 다르게 콘텐츠를 생성하는 경우를 말합니다.
- 맥락이 상충하는 환각, 여기서 LLM이 생성하는

그들이 이전에 생성한 정보와 모순되는 내용.

- 사실과 충돌하는 환각은 LLM이 확립된 세계 지식과 일치하지 않는 내용을 생성하는 것을 포함한다.

프롬프트 엔지니어링: 프롬프트는 LLM에 대한 입력 역할을 하며, 그 구문과 의미는 모델의 출력을 결정하는 데 중요한 역할을 합니다. 프롬프트 변형은 때때로 인간에게 직관에 반하는 결과를 낳을 수 있으며, 이는 프롬프트 엔지니어링을 통해 다루어집니다. 프롬프트 엔지니어링은 LLM의 응답을 효과적으로 안내하기 위해 자연어 쿼리를 설계하는 과정을 포함합니다 [484, 32].

제한된 지식: 사전 훈련 중 습득한 정보는 한정적이며 시간이 지나면서 obsolete될 수 있습니다. 업데이트된 데이터를 사용하여 모델을 재훈련하는 것은 비용이 많이 듭니다. 사실에 근거한 정확한 응답을 생성하기 위해 사람들은 retrieval augmentation pipeline [198]을 사용합니다. 그러나 사전 훈련된 모델은 retrieval augmentation generation (RAG) [6, 21]으로 훈련되지 않았으므로, 훈련 파이프라인을 조정하는 것이 필요합니다 [193, 25].

안전성과 통제 가능성: LLM을 사용하는 것은 우연히든 특정 프롬프트에 의해서든 해로운, 오해의 소지가 있거나 부적절한 콘텐츠를 생성할 위험이 동반됩니다. 이러한 모델이 안전하게 사용되도록 하는 것은 중요한 문제입니다 [485]. 보안과 개인 정보 보호: LLM은 개인 정보를 유출하고 잘못된, 비윤리적이며 부조화된 응답을 생성할 위험이 있습니다. 연구자들은 LLM의 보안을 침해하는 백도어 공격, 탈옥, 프롬프트 주입 및 데이터 오염과 같은 다양한 보안 공격을 조사해왔습니다. 따라서 LLM이 복잡한 AI 애플리케이션에 대해 안전하고 신뢰할 수 있으며 신뢰받을 수 있도록 더 나은 방어 메커니즘을 개발하는 것이 필수적입니다 [486].

다중 양식: 다중 양식 학습은 LLM이 텍스트, 이미지 및 비디오와 같은 다양한 데이터로 훈련되며, 더 풍부한 이해력을 가진 모델을 만들기를 목표로 하지만 데이터 정렬, 융합 전략 및 더 높은 컴퓨팅 수요라는 도전에 직면해 있습니다.

파국적 망각: LLM은 종종 대규모 데이터셋에서 사전 학습을 한 후, 도메인 특정 데이터로 미세 조정을 하여 훈련 자원을 줄입니다. 그러나 이들은 도메인 적응과 파국적 망각 같은 문제에 직면하여 새로운 작업을 학습할 때 원래 지식의 유지에 장애가 됩니다.

적대적 강건성: 대형 언어 모델(LLMs)은 다양한 작업에서 뛰어난 능력을 보여주지만, 미세한 의도적인 입력 변화로 인해 오작동할 수 있는 적대적 공격에 취약합니다. 특히 BERT와 같은 모델의 경우, 적대적 미세 조정이 강건성을 향상시킬 수 있지만, 때때로 일반화 능력을 저해하기도 합니다 [487]. LLM이 복잡한 시스템에 통합됨에 따라, 신뢰할 수 있는 ML 내에서 LLM에 대한 적대적 공격이라는 새로운 분야를 고려할 때, 이들의 보안 속성을 검토하는 것이 중요해 집니다 [488]. 이러한 취약성은 안전이 중요한 분야에서 두드러지며, LLM의 신뢰성을 보장하기 위해 강력한 적대적 평가 도구가 필요합니다 [489].

해석 가능성과 설명 가능성: LLM의 "블랙 박스" 특성은 그들의 의사 결정 과정을 이해하는 데 어려움을 주며, 이는 더 넓은 수용과 신뢰를 위해 매우 중요합니다.

특히 민감한 분야에서. 그들의 고도의 능력에도 불구하고, 그 작동 방식에 대한 통찰력 부족은 그들의 효과성과 신뢰성을 제한합니다 [490, 491]. 사용자 신뢰를 촉진하고 책임 있는 AI 사용을 보장하기 위해 LLM을 더 설명 가능하게 만들기 위한 노력이 이루어지고 있습니다. LLM의 응답 뒤에 있는 논리를 이해하는 것은 신뢰를 구축하고 그들이 인간의 가치와 법적 기준에 부합하는지 확인하는 데 필수적입니다.

프라이버시 문제: 대형 언어 모델(LLMs)의 복잡성과 규모가 커짐에 따라 프라이버시 문제가 심각해지고 있으며, 특히 데이터 공유와 잠재적인 오용과 관련하여 더욱 그러합니다. 악의적인 콘텐츠 생성, 필터 회피 및 데이터 프라이버시 문제가 발생할 수 있는 위험이 있으며, 이는 고객 프라이버시 보호가 중요한 전자 상거래 분야에서 특히 두드러집니다. 모델이 개인 데이터를 기반으로 훈련된 경우, 이러한 모델이 공개될 경우 추가적인 우려가 발생합니다. LLM은 훈련 세트에서 문구를 암기하는 경향이 있어, 적대자가 이를 이용해 민감한 데이터를 추출할 수 있는 위험이 있으며, 이는 개인 프라이버시에 위협이 됩니다 [492, 493].

실시간 처리: 대규모 언어 모델(LLMs)에서의 실시간 처리는 다양한 애플리케이션에 있어 매우 중요하며, 특히 모바일 AI 애플리케이션의 인기가 높아지고 정보 보안 및 개인 정보와 관련된 우려가 커지고 있는 상황에서 더욱 그렇습니다. 그러나 LLM은 종종 수백 개의 층과 수백만 개의 매개변수를 가지고 있어, 높은 계산 요구 사항과 하드웨어 플랫폼의 제한된 가치치 저장으로 인해 실시간 처리를 방해합니다. 이는 특히 엣지 컴퓨팅 환경에서 두드러집니다 [494]. MobileBERT와 같은 특정 노력은 메모리 요구 사항을 줄이는 것을 목표로 하지만, 여전히 많은 모델 층 수로 인해 상당한 실행 오버헤드에 직면해 있으며, 이로 인해 높은 추론 지연 시간이 발생합니다.

장기 의존성: 대형 언어 모델은 텍스트를 이해하고 생성하는 데 상당한 발전을 보여주었지만, 맥락을 유지하고 장기 의존성을 처리하는 데 종종 어려움을 겪습니다. 특히 복잡한 다중 턴 대화나 긴 문서에서 이러한 제한은 비논리적이거나 관련 없는 응답으로 이어질 수 있습니다.

하드웨어 가속: LLM의 성장은 이러한 모델의 훈련 및 배포와 관련된 증가하는 컴퓨팅 및 메모리 요구 사항으로 인해 상당한 하드웨어 도전 과제를 제시합니다. GPU는 LLM 훈련을 위한 하드웨어 요구 사항을 충족하는 데 중요한 역할을 하였으며, 네트워킹 산업 또한 훈련 작업 부하를 최적화하기 위해 발전하고 있습니다. 그러나 LLM의 증가하는 크기는 하드웨어 발전을 초과하고 있어 모델 추론 비용이 점점 더 증가하고 있습니다. 모델 양자화는 LLM 크기와 하드웨어 용량 간에 widening gap을 메우기 위한 유망한 접근 방식입니다 [495]. GPU나 TPU와 같은 특수 하드웨어 가속은 계산 비용을 크게 줄여 실시간 애플리케이션을 더욱 실현 가능하게 만들 수 있지만, 모든 한계를 완전히 해결하지는 못하므로 하드웨어 기술의 추가 발전이 필요합니다.

규제 및 윤리적 프레임워크: 인공지능의 급속한 발전은 OpenAI의 GPT-4 [157]와 Google의 Bard와 같은 정교한 대형 언어 모델(LLMs)의 출현을 초래했습니다. 이러한 발전은 LLM의 광범위한 사용에 동반되는 윤리적 및 사회적 문제를 관리하기 위한 규제 감독의 필요성을 강조합니다 [496]. 예를 들어, LLM은 긍정적으로 사용될 수 있는 콘텐츠를 생성할 수 있습니다.

긍정적이든 부정적이든, 책임 있는 사용을 안내하고 결과에 대한 책임을 부여하기 위해 사전 예방적인 윤리적 프레임워크와 정책 조치가 필요성을 강조하고 있다 [497]. 감사는 AI 시스템, 특히 LLM이 윤리적이고 법적으로, 그리고 기술적으로 강건하게 설계되고 배치되도록 보장하는 유망한 거버넌스 수단으로 확인되었다 [498].

8. 결론

이 기사는 LLM의 발전 상황을 종합적으로 검토하였으며, 기존 문헌에서 LLM의 중요한 발견을 요약하고, 아키텍처, 데이터셋, 훈련 파이프라인을 포함한 설계 측면에 대한 자세한 분석을 제공합니다. 우리는 다양한 LLM이 사용하는 중요한 아키텍처 구성 요소와 훈련 전략을 식별하였고, 이러한 측면은 기사 전반에 걸쳐 요약 및 논의로 제시됩니다. 또한, 우리는 제로샷 및 피샷 설정에서 LLM의 성능 차이를 논의하고, 파인튜닝의 영향을 탐구하며, 감독된 모델과 일반화된 모델, 인코더와 디코더, 인코더-디코더 아키텍처를 비교하였습니다. 다중 모달 LLM, 검색 증강 LLM, LLM 기반 에이전트, 효율적인 LLM, 데이터셋, 평가, 응용 및 도전 과제에 대한 포괄적인 검토도 제공됩니다. 이 기사는 연구자들에게 LLM의 최근 발전에 대한 통찰을 제공하고 더 나은 LLM을 개발할 수 있는 기본 개념과 세부 정보를 제공하는 귀중한 자원이 될 것으로 예상됩니다.

감사의 말: 저자/들은 Saudi Data and AI Authority (SDAIA)와 King Fahd University of Petroleum and Minerals (KFUPM)에서 제공한 지원에 감사드리며, 이는 SDAIA-KFUPM 인공지능 공동 연구 센터의 Grant No. JRC-AI-RFP-11에 따른 것입니다.

참고문헌

- A. Chernyavskiy, D. Ilvovsky, P. Nakov, Transformers: "역사의 끝" 자연어 처리에 대한?, in: 기계 학습 및 데이터베이스의 지식 발견. 연구 트랙: 유럽 회의, ECML PKDD 2021, 스페인 빌바오, 2021년 9월 13-17일, 프로시딩스, 파트 III 21, Springer, 2021, pp. 677-693. 1
- A. Wang, Y. Pruksachatkun, N. Nangia, A. Singh, J. Michael, F. Hill, O. Levy, S. Bowman, Superglue: 일반 목적의 언어 이해 시스템을 위한 더 끈끈한 벤치마크, 신경 정보 처리 시스템 발전 32 (2019). 1, 26, 29
- [3] D. Adiwardana, M.-T. Luong, D. R. So, J. Hall, N. Fiedel, R. Thoppilan, Z. Yang, A. Kulshreshtha, G. Nemade, Y. Lu, et al., 인간과 유사한 개방형 챗봇을 위한 탐색, arXiv 사전 인쇄 arXiv:2001.09977 (2020). 1
- [4] B. A. y Arcas, 대형 언어 모델은 우리를 이해하는가?, Daedalus 151 (2) (2022) 183-197. 2
- A. Radford, J. Wu, R. Child, D. Luan, D. Amodei, I. Sutskever 외, 언어 모델은 비지도 다중 과제 학습자입니다, OpenAI 블로그 1 (8) (2019) 9. 2, 7
- [6] T. Brown, B. Mann, N. Ryder, M. Subbiah, J. D. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, 외, 언어 모델은 몇 번의 학습으로 학습하는 모델이다, 신경 정보 처리 시스템 33 (2020) 1877-1901. 2, 6, 7, 8, 9, 16, 18, 23, 24, 25, 34
- J. Devlin, M.-W. Chang, K. Lee, K. Toutanova, Bert: 언어 이해를 위한 깊이 있는 양방향 변환기의 사전 훈련, arXiv 사전 인쇄 arXiv:1810.04805 (2018). 2, 18, 24

- M. E. Peters, M. Neumann, M. Iyyer, M. Gardner, C. Clark, K. Lee, L. Zettlemoyer, Deep contextualized word representations, in: NAACL-HLT, Association for Computational Linguistics, 2018, pp. 2227–2237.
- [9] M. Lewis, Y. Liu, N. Goyal, M. Ghazvininejad, A. Mohamed, O. Levy, V. Stoyanov, L. Zettlemoyer, Bart: 자연어 생성, 번역 및 이해를 위한 시퀀스-투-시퀀스 사전 훈련의 노이즈 제거, arXiv 사전 인쇄 arXiv:1910.13461 (2019). 2
- [10] C. Raffel, N. Shazeer, A. Roberts, K. Lee, S. Narang, M. Matena, Y. Zhou, W. Li, P. J. Liu, "전이 학습의 한계를 탐색하며 통합된 텍스트-투-텍스트 변환기", The Journal of Machine Learning Research 21 (1) (2020) 5485–5551. 2, 7, 8, 18, 19, 24, 25, 28, 30, 31
- [11] L. Xue, N. Constant, A. Roberts, M. Kale, R. Al-Rfou, A. Siddhant, A. Barua, C. Raffel, mt5: 대규모 다국어 사전 훈련 텍스트-텍스트 변환기, arXiv 사전 인쇄본 arXiv:2010.11934 (2020). 2, 7, 8, 24, 25, 28, 30
- [12] Z. Zhang, Y. Gu, X. Han, S. Chen, C. Xiao, Z. Sun, Y. Yao, F. Qi, J. Guan, P. Ke 외, Cpm-2: 대규모 비용 효율적인 사전 훈련된 언어 모델, AI Open 2 (2021) 216–224. 2, 8, 25
- [13] T. L. Scao, A. Fan, C. Akiki, E. Pavlick, S. Ilić, D. Hesslow, R. Castagné, A. S. Luccioni, F. Yvon, M. Gallé 외, Bloom: 176b-파라미터 오픈 액세스 다국어 언어 모델, arXiv 사전 인쇄 arXiv:2211.05100 (2022). 2, 4, 9, 11, 23, 24, 25, 30
- [14] S. Zhang, S. Roller, N. Goyal, M. Artetxe, M. Chen, S. Chen, C. Dewan, M. Diab, X. Li, X. V. Lin 외, Opt: Open pre-trained transformer language models, arXiv preprint arXiv:2205.01068 (2022). 2, 9, 11, 24, 25
- [15] A. Chowdhery, S. Narang, J. Devlin, M. Bosma, G. Mishra, A. Roberts, P. Barham, H. W. Chung, C. Sutton, S. Gehrmann, et al., Palm: Scaling language modeling with pathways, arXiv preprint arXiv:2204.02311 (2022). 2, 6, 9, 11, 23, 24, 25
- [16] H. W. Chung, L. Hou, S. Longpre, B. Zoph, Y. Tay, W. Fedus, E. Li, X. Wang, M. Dehghani, S. Brahma 외, 지침에 맞춰 미세 조정된 언어 모델의 확장, arXiv 사전 인쇄 arXiv:2210.11416 (2022). 2, 7, 11, 16, 17, 22, 24, 25, 28, 31
- [17] V. Sanh, A. Webson, C. Raffel, S. H. Bach, L. Sutawika, Z. Alyafeai, A. Chaffin, A. Stiegler, T. L. Scao, A. Raja 외, Multitask prompted training enables zero-shot task generalization, arXiv preprint arXiv:2110.08207 (2021). 2, 11, 16, 25, 28, 31
- [18] Y. Wang, S. Mishra, P. Alipoormolabashi, Y. Kordi, A. Mirzaei, A. Naik, A. Ashok, A. S. Dhanasekaran, A. Arunkumar, D. Staple 외, Super-naturalinstructions: Generalization via declarative instructions on 1600+ nlp tasks, in: Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing, 2022, pp. 5085–5109. 2, 7, 11, 16, 17, 24, 25, 28, 31
- [19] Y. Wang, Y. Kordi, S. Mishra, A. Liu, N. A. Smith, D. Khashabi, H. Hajishirzi, Self-instruct: Aligning language model with self generated instructions, arXiv preprint arXiv:2212.10560 (2022). 2, 16, 19, 22, 28
- [20] L. Ouyang, J. Wu, X. Jiang, D. Almeida, C. Wainwright, P. Mishkin, C. Zhang, S. Agarwal, K. Slama, A. Ray, et al., 인간 피드백과 함께 지침을 따르도록 언어 모델 훈련하기, 신경 정보 처리 시스템 발전 35 (2022) 27730–27744. 2, 7, 11, 16, 22
- [21] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei, N. Bashlykov, S. Batra, P. Bhargava, S. Bhosale 외, Llama 2: Open foundation and fine-tuned chat models, arXiv preprint arXiv:2307.09288 (2023). 2, 7, 10, 16, 25, 34
- [22] J. Wei, Y. Tay, R. Bommasani, C. Raffel, B. Zoph, S. Borgeaud, D. Yogatama, M. Bosma, D. Zhou, D. Metzler 외, 대형 언어 모델의 emergent abilities, arXiv 사전 인쇄본 arXiv:2206.07682 (2022). 2
- [23] T. Webb, K. J. Holyoak, H. Lu, 대형 언어 모델에서의 emergent analogical reasoning, Nature Human Behaviour 7 (9) (2023) 1526–1541. 2
- [24] D. A. Boiko, R. MacKnight, G. Gomes, 대형 언어 모델의 자율적인 emergent 과학 연구 능력, arXiv preprint arXiv:2304.05332 (2023). 2
- [25] G. Izacard, P. Lewis, M. Lomeli, L. Hosseini, F. Petroni, T. Schick, J. Dwivedi-Yu, A. Joulin, S. Riedel, E. Grave, 검색 증강 언어 모델을 활용한 소수 샷 학습, arXiv 사전 인쇄 arXiv:2208.03299 (2022). 2, 18, 19, 34
- [26] D. Driess, F. Xia, M. S. Sajjadi, C. Lynch, A. Chowdhery, B. Ichter, A. Wahid, J. Tompson, Q. Vuong, T. Yu 외, Palm-e: An embodied
- 다중 모달 언어 모델, arXiv 사전 인쇄 arXiv:2303.03378 (2023). 2, 20, 22, 33
- [27] A. Parisi, Y. Zhao, N. Fiedel, Talm: 도구 보강 언어 모델, arXiv 사전 인쇄 arXiv:2205.12255 (2022). 2, 19, 20
- B. Zhang, H. Soh, Large language models as zero-shot human models for human-robot interaction, arXiv preprint arXiv:2303.03548 (2023). 2, 33
- [29] Q. Ye, H. Xu, G. Xu, J. Ye, M. Yan, Y. Zhou, J. Wang, A. Hu, P. Shi, Y. Shi 외, mplug-owl: 모놀화가 대형 언어 모델에 다중모드 기능을 부여하다, arXiv preprint arXiv:2304.14178 (2023). 2, 22
- [30] W. Wang, Z. Chen, X. Chen, J. Wu, X. Zhu, G. Zeng, P. Luo, T. Lu, J. Zhou, Y. Qiao 등, VisionLlm: 대형 언어 모델은 비전 중심 작업을 위한 개방형 디코더이기도 하다, arXiv 사전 인쇄본 arXiv:2305.11175 (2023). 2, 22
- [31] R. Yang, L. Song, Y. Li, S. Zhao, Y. Ge, X. Li, Y. Shan, Gpt4tools: 도구를 사용하는 대형 언어 모델 교육을 위한 자기 지도 학습, arXiv preprint arXiv:2305.18752 (2023). 2, 19, 22, 23
- [32] E. Saravia, Prompt Engineering Guide, <https://github.com/dair-ai/Prompt-Engineering-Guide> (12 2022). 2, 7, 18, 34
- [33] A. Zeng, X. Liu, Z. Du, Z. Wang, H. Lai, M. Ding, Z. Yang, Y. Xu, W. Zheng, X. Xia 외, Glm-130b: 오픈 이중 언어 사전 학습 모델, arXiv 사전 인쇄 arXiv:2210.02414 (2022). 2, 10, 23, 24, 25
- [34] Y. Wang, H. Le, A. D. Gotmare, N. D. Bui, J. Li, S. C. Hoi, Codet5+: 오픈 코드 대형 언어 모델을 이용한 코드 이해 및 생성, arXiv 사전 인쇄본 arXiv:2305.07922 (2023). 2, 11, 24, 25
- [35] S. Wang, Y. Sun, Y. Xiang, Z. Wu, S. Ding, W. Gong, S. Feng, J. Shang, Y. Zhao, C. Pang 외, Ernie 3.0 titan: 언어 이해 및 생성을 위한 대규모 지식 강화 미리 학습 탐색, arXiv 사전 인쇄 arXiv:2112.12731 (2021). 2, 8, 24, 25
- [36] J. Rasley, S. Rajbhandari, O. Ruwase, Y. He, Deepspeed: 시스템 최적화가 100억 개 이상의 매개변수를 가진 딥러닝 모델 학습을 가능하게 한다, in: 제26회 ACM SIGKDD 국제 지식 발견 및 데이터 마이닝 컨퍼런스 논문집, 2020, pp. 3505–3506. 2, 5
- [37] S. Rajbhandari, J. Rasley, O. Ruwase, Y. He, Zero: 메모리 최적화 - 조단위 파라미터 모델 훈련을 향하여, SC20: 고성능 컴퓨팅, 네트워킹, 저장 및 분석에 관한 국제 회의, IEEE E, 2020, pp. 1–16. 2, 4, 24
- [38] J. He, C. Zhou, X. Ma, T. Berg-Kirkpatrick, G. Neubig, 파라미터 효율적인 전이 학습에 대한 통합된 관점, arXiv 사전 인쇄 arXiv:2110.04366 (2021). 2, 20, 21
- [39] Z. Hu, Y. Lan, L. Wang, W. Xu, E.-P. Lim, R. K.-W. Lee, L. Bing, S. Poria, Llm-adapters: 매개변수 효율적인 대규모 언어 모델의 파인튜닝을 위한 어댑터 계열, arXiv 사전 인쇄 arXiv:2304.01933 (2023). 2, 20
- [40] B. Lester, R. Al-Rfou, N. Constant, 매개변수 효율적인 프롬프트 튜닝을 위한 스케일링 힘, arXiv 사전 인쇄 arXiv:2104.08691 (2021). 2, 8, 20, 21
- [41] X. L. Li, P. Liang, Prefix-tuning: Optimizing continuous prompts for generation, arXiv preprint arXiv:2101.00190 (2021). 2, 20, 21
- [42] X. Ma, G. Fang, X. Wang, Llm-pruner: 대규모 언어 모델의 구조적 가지치기, arXiv 사전 인쇄 arXiv:2305.11627 (2023). 2, 22
- [43] R. Xu, F. Luo, C. Wang, B. Chang, J. Huang, S. Huang, F. Huang, "조밀한 것에서 희소한 것으로: 더 나은 사전 훈련된 언어 모델 압축을 위한 대조적 가지치기", in: Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 36, 2022, pp. 11547–11555. 2, 22
- [44] G. Xiao, J. Lin, M. Seznec, H. Wu, J. Demouth, S. Han, Smoothquant: 대형 언어 모델을 위한 정확하고 효율적인 포스트 트레이닝 양자화, ICML에서, Proceedings of Machine Learning Research, PMLR, 2023, pp. 38087–38099. 2, 21
- [45] C. Tao, L. Hou, W. Zhang, L. Shang, X. Jiang, Q. Liu, P. Luo, N. Wong, 생성적 사전 학습 언어 모델의 양자화를 통한 압축, arXiv 사전 인쇄본 arXiv:2203.10705 (2022). 2, 21
- A. Pal, D. Karkhanis, M. Roberts, S. Dooley, A. Sundararajan, S. Naidu, Giraffe: llms에서 컨텍스트 길이를 확장하는 모험, arXiv 사전 인쇄 arXiv:2308.10882 (2023). 2, 17
- [47] B. Peng, J. Quesnelle, H. Fan, E. Shippole, Yarn: Efficient context window extension of large language models, arXiv preprint arXiv:2309.00071 (2023). 2, 17
- [48] M. Guo, J. Ainslie, D. Uthus, S. Ontanon, J. Ni, Y.-H. Sung, Y. Yang,

- Long5: 긴 시퀀스를 위한 효율적인 텍스트-투-텍스트 변환기, arXiv preprint arXiv:21.12.07916 (2021). 2, 18
- [49] S. Chen, S. Wong, L. Chen, Y. Tian, 대형 언어 모델의 맥락 창을 위치 보간을 통해 확장하기, arXiv 사전 인쇄물 arXiv:2306.15595 (2023). 2, 17
- [50] W. X. Zhao, K. Zhou, J. Li, T. Tang, X. Wang, Y. Hou, Y. Min, B. Zhang, J. Zhang, Z. Dong 외, 대형 언어 모델에 대한 조사, arXiv 사전 인쇄 arXiv:2303.18223 (2023). 2, 3, 7
- [51] U. Naseem, I. Razzak, S. K. Khan, M. Prasad, 단어 표현 모델에 대한 포괄적인 조사: 고전에서 첨단 단어 표현 언어 모델에 이르기까지, Transactions on Asian and Low-Resource Language Information Processing 20 (5) (2021) 1–35. 2, 3
- [52] B. Min, H. Ross, E. Sulem, A. P. B. Veyseh, T. H. Nguyen, O. Sainz, E. Agirre, I. Hein, D. Roth, 최근의 자연어 처리에서 대규모 사전 훈련된 언어 모델을 통한 발전: 조사, arXiv 사전 인쇄 arXiv:2111.01243 (2021). 2, 3
- [53] C. Zhou, Q. Li, C. Li, J. Yu, Y. Liu, G. Wang, K. Zhang, C. Ji, Q. Yan, L. He, 외, pretrained foundation models에 대한 포괄적인 조사: bert에서 chatgpt까지의 역사, arXiv preprint arXiv:2302.09419 (2023). 2, 3
- [54] Q. Dong, L. Li, D. Dai, C. Zheng, Z. Wu, B. Chang, X. Sun, J. Xu, Z. Sui, 인컨텍스트 학습에 대한 조사, arXiv 사전 인쇄 arXiv:2301.00234 (2022). 2, 7, 18
- [55] J. Huang, K. C.-C. Chang, 대규모 언어 모델에서의 추론을 향하여: 조사, arXiv 사전 인쇄 arXiv:2212.10403 (2022). 2, 7, 18
- [56] Y. Wang, W. Zhong, L. Li, F. Mi, X. Zeng, W. Huang, L. Shang, X. Jiang, Q. Liu, 인간과 대형 언어 모델 정렬: 조사, arXiv 사전 인쇄 arXiv:2307.12966 (2023).
- [57] X. Zhu, J. Li, Y. Liu, C. Ma, W. Wang, 대형 언어 모델을 위한 모델 압축에 대한 조사, arXiv 사전 인쇄 arXiv:2308.07633 (2023). 2
- [58] S. Yin, C. Fu, S. Zhao, K. Li, X. Sun, T. Xu, E. Chen, 다중 양식 대형 언어 모델에 관한 조사, arXiv 사전 인쇄 arXiv:2306.13549 (2023). 2, 22, 23
- [59] J. J. Webster, C. Kit, Tokenization as the initial phase in nlp, in: COL-ING 1992 volume 4: 제14회 국제 컴퓨터 언어학 회의, 1992. 4
- [60] T. Kudo, Subword regularization: 여러 서브워드 후보를 통해 신경망 번역 모델 개선, in: 제56회 언어학회 연례회의 자료집 (제1권: 긴 논문), 2018, pp. 66–75. 4
- [61] R. Sennrich, B. Haddow, A. Birch, 회귀 단어의 신경 기계 번역을 위한 서브워드 단위, in: 제54회 컴퓨터 언어학 협회의 연례 회의 프로시딩 (1권: 논문), 2016, pp. 1715–1725. 4
- [62] M. Schuster, K. Nakajima, 일본어 및 한국어 음성 검색, in: 2012 IEEE 국제 음향, 음성 및 신호 처리 컨퍼런스 (ICASSP), IEEE, 2012, pp. 5149–5152. 4
- S. J. Mielke, Z. Alyafeai, E. Salesky, C. Raffel, M. Dey, M. Gallé, A. Raja, C. Si, W. Y. Lee, B. Sagot 외, '단어와 문자 사이: 자연어 처리에서 개방형 어휘 모델링과 토큰화의 간략한 역사', arXiv 사전인쇄 arXiv:2112.10508 (2021). 4
- [64] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, ̄. Kaiser, I. Polosukhin, Attention is all you need, Advances in neural information processing systems 30 (2017). 4, 7
- [65] O. Press, N. Smith, M. Lewis, 짧은 훈련, 긴 테스트: 선형 편향을 가진 주의(attention)는 입력 길이의 외삽을 가능하게 한다, 국제 학습 표현 회의(International Conference on Learning Representations), 2022. URL <https://openreview.net/forum?id=R8sQPpGCv0> 4, 17
- [66] J. Su, Y. Lu, S. Pan, A. Murtadha, B. Wen, Y. Liu, Roformer: 향상된 변환기와 회전 위치 임베딩, arXiv 사전 인쇄 arXiv:2104.09864 (2021). 4, 9, 17
- [67] R. Child, S. Gray, A. Radford, I. Sutskever, 희소 변환기로 긴 시퀀스 생성하기, arXiv 사전 인쇄 arXiv:1904.10509 (2019). 4, 7, 23
- [68] T. Dao, D. Fu, S. Ermon, A. Rudra, C. Ré, Flashattention: 빠르고 메모리 효율적인 I/O 인식을 갖춘 정확한 주의(attention), Neural Information Processing Systems 35 (2022) 16344–16359. 4
- [69] K. Hornik, M. Stinchcombe, H. White, 다중 피드포워드 네트워크는 보편 근사기입니다, Neural networks 2 (5) (1989) 359–366. 4
- [70] V. Nair, G. E. Hinton, 정류 선형 뉴턴이 제한된 볼츠만 머신을 개선함, in: 제27회 국제 회의 자료
- 기계 학습 (ICML-10), 2010, pp. 807–814.
- [71] D. Hendrycks, K. Gimpel, Gaussian error linear units (gelus), arXiv 사전 인쇄 arXiv:1606.08415 (2016). 4
- [72] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, R. Salakhutdinov, Dropout: 신경망의 과적합을 방지하는 간단한 방법, 기계학습 연구 저널 15 (1) (2014) 1929–1958. 4
- [73] D. Krueger, T. Maharaj, J. Kramár, M. Pezeshki, N. Ballas, N. R. Ke, A. Goyal, Y. Bengio, A. Courville, C. Pal, Zoneout: RNN을 무작위로 숨겨진 활성화를 보존하여 정규화하기, arXiv 사전 인쇄물 arXiv:1606.01305 (2016). 4
- [74] N. Shazeer, Gluevants improve transformer, arXiv preprint arXiv:2002.05202 (2020). 4
- [75] Y. N. Dauphin, A. Fan, M. Auli, D. Grangier, 게이트드 컨볼루션 네트워크를 이용한 언어 모델링, 국제 기계 학습 회의, PMLR, 2017, pp. 933–941. 4
- [76] J. L. Ba, J. R. Kiros, G. E. Hinton, Layer normalization, arXiv 사전인쇄 arXiv:1607.06450 (2016). 4
- [77] B. Zhang, R. Sennrich, Root mean square layer normalization, Advances in Neural Information Processing Systems 32 (2019). 4
- A. Baevski, M. Auli, 신경 언어 모델링을 위한 적응형 입력 표현, arXiv 사전 인쇄 arXiv:1809.10853 (2018). 4
- [79] H. Wang, S. Ma, L. Dong, S. Huang, D. Zhang, F. Wei, Deepnet: 1,000 층으로 변환기 확장하기, arXiv 사전 인쇄 arXiv:2203.00555 (2022). 4
- [80] M. Shoybi, M. Patwary, R. Puri, P. LeGresley, J. Casper, B. Catanzaro, Megatron-llm: 다중 약 파라미터 언어 모델을 모델 병렬성을 이용하여 훈련하는 방법, arXiv 사전 인쇄 arXiv:1909.08053 (2019). 4, 5
- [81] "bmtrain: 대형 모델을 위한 효율적인 훈련."
URL <https://github.com/OpenBMB/BMTrain> 4, 5
- [82] T. Wolf, L. Debut, V. Sanh, J. Chaumond, C. Delangue, A. Moi, P. Cistac, T. Rault, R. Louf, M. Funtowicz 외, Transformers: 최첨단 자연어 처리, in: 2020년 자연어 처리에 대한 경험적 방법 회의: 시스템 데모 발표, 2020, pp. 38–45. 5
- [83] J. Bradbury, R. Frostig, P. Hawkins, M. J. Johnson, C. Leary, D. Maclaurin, G. Necula, A. Paszke, J. VanderPlas, S. Wanderman-Milne 외, Jax: python+ numpy 프로그램의 조합 가능한 변환 (2018).
- [84] S. Li, J. Fang, Z. Bian, H. Liu, Y. Liu, H. Huang, B. Wang, Y. You, Colossal-ai: 대규모 병렬 학습을 위한 통합 딥 러닝 시스템, arXiv 사전 인쇄물 arXiv:2110.14883 (2021). 5
- [85] J. He, J. Qiu, A. Zeng, Z. Yang, J. Zhai, J. Tang, Fastmoe: A fast mixture-of-expert training system, arXiv preprint arXiv:2103.13262 (2021). 5
- [86] L. Huawei Technologies Co., Huawei mindspore ai development framework, in: Artificial Intelligence Technology, Springer, 2022, pp. 137–162. 5
- [87] A. Paszke, S. Gross, F. Massa, A. Lerer, J. Bradbury, G. Chanan, T. Killeen, Z. Lin, N. Gimeshein, L. Antiga 외, Pytorch: 명령형 스타일의 고성능 딥 러닝 라이브러리, Advances in neural information processing systems 32 (2019). 5
- [88] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis, J. Dean, M. Devin, S. Ghemawat, G. Irving, M. Isard 외, Tensorflow: 대규모 기계 학습을 위한 시스템., in: Osd, Vol. 16, Savannah, GA, USA, 2016, pp. 265–283. 5
- [89] T. Chen, M. Li, Y. Li, M. Lin, N. Wang, M. Wang, T. Xiao, B. Xu, C. Zhang, Z. Zhang, Mxnet: 이중 분산 시스템을 위한 유연하고 효율적인 머신 러닝 라이브러리, arXiv 사전 인쇄 arXiv:1512.01274 (2015). 5
- [90] W. Fedus, B. Zoph, N. Shazeer, Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity, The Journal of Machine Learning Research 23 (1) (2022) 5232–5270. 5, 9
- [91] N. Du, Y. Huang, A. M. Dai, S. Tong, D. Lepikhin, Y. Xu, M. Krikun, Y. Zhou, A. W. Yu, O. Firat 외, Glam: 전문가 혼합을 통한 언어 모델의 효율적인 스케일링, 국제 기계 학습 회의에서, PMLR, 2022, pp. 5547–5569. 5, 9, 23, 24, 25
- [92] X. Ren, P. Zhou, X. Meng, X. Huang, Y. Wang, W. Wang, P. Li, X. Zhang, A. Podolskiy, G. Arshinov 등, Pangu-llm: 희소한 이질적 컴퓨팅을 활용한 수조 개 매개변수 언어 모델을 향하여, arXiv 사전 인쇄 arXiv:2303.10845 (2023). 5, 10, 16, 23, 24, 25
- [93] T. Wang, A. Roberts, D. Hesslow, T. Le Scao, H. W. Chung, I. Beltagy, J. Launay, C. Raffel, 어떤 언어 모델 아키텍처와 사전 훈련

- 제로샷 일반화에 가장 적합한 목표는 무엇인가?, 국제 기계학습 회의에서, PMLR, 2022, pp. 22964–22984. 5
- [94] L. Dong, N. Yang, W. Wang, F. Wei, X. Liu, Y. Wang, J. Gao, M. Zhou, H.-W. Hon, 자연어 이해 및 생성을 위한 통합 언어 모델 사전 훈련, 신경 정보 처리 시스템 32 (2019). 6
- [95] J. Kaplan, S. McCandlish, T. Henighan, T. B. Brown, B. Chess, R. Child, S. Gray, A. Radford, J. Wu, D. Amodei, 신경 언어 모델에 대한 스케일링 법칙, arXiv 사전 인쇄 arXiv:2001.08361 (2020). 6
- [96] J. Hoffmann, S. Borgeaud, A. Mensch, E. Buchatskaya, T. Cai, E. Rutherford, D. d. L. Casas, L. A. Hendricks, J. Welbl, A. Clark, et al., Training compute-optimal large language models, arXiv preprint arXiv:2203.15556 (2022). 6, 9, 25, 29
- [97] S. Iyer, X. V. Lin, R. Pasunuru, T. Mihaylov, D. Simig, P. Yu, K. Shuster, T. Wang, Q. Liu, P. S. Koura 외, Opt-1m1: 일반화를 통한 언어 모델 지침 메타 학습의 확장, arXiv preprint arXiv:2212.12017 (2022). 7, 11, 16, 17, 22, 25, 28
- [98] Z. Sun, Y. Shen, Q. Zhou, H. Zhang, Z. Chen, D. Cox, Y. Yang, C. Gan, 인간의 최소한의 감독으로 처음부터 시작하는 원칙 기반의 언어 모델 자기 정렬, arXiv 사전 인쇄 arXiv:2305.03047 (2023). 7, 17
- [99] A. Askeel, Y. Bai, A. Chen, D. Drain, D. Ganguli, T. Henighan, A. Jones, N. Joseph, B. Mann, N. DasSarma 외, 정렬을 위한 실험실로서의 일반 언어 도우미, arXiv 사전 인쇄 arXiv:2112.00861 (2021).
- [100] D. M. Ziegler, N. Stiennon, J. Wu, T. B. Brown, A. Radford, D. Amodei, P. Christiano, G. Irving, 인간의 선호로 언어 모델 미세 조정하기, arXiv 사전 인쇄 arXiv:1909.08593 (2019). 7
- [101] S. Kim, S. J. Joo, D. Kim, J. Jang, S. Ye, J. Shin, M. Seo, The cot collection: Improving zero-shot and few-shot learning of language models via chain-of-thought fine-tuning, arXiv preprint arXiv:2305.14045 (2023). 7, 16
- [102] Q. Liu, F. Zhou, Z. Jiang, L. Dou, M. Lin, 영웅이 되기까지: 지침 튜닝에서 상징적 작업의 힘을 조사하다, arXiv 사전 인쇄 arXiv:2304.07995 (2023). 7, 16
- [103] J. Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, Q. V. Le, D. Zhou, et al., Chain-of-thought prompting elicits reasoning in large language models, Advances in Neural Information Processing Systems 35 (2022) 24824–24837. 7, 20, 23
- [104] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, D. Zhou, 자기 일관성이 언어 모델의 사고 연쇄 추론을 개선한다, arXiv 사전 인쇄를 arXiv:2203.11171 (2022). 7, 20
- [105] S. Yao, D. Yu, J. Zhao, I. Shafran, T. L. Griffiths, Y. Cao, K. Narasimhan, Tree of thoughts: Deliberate problem solving with large language models, arXiv preprint arXiv:2305.10601 (2023). 7, 20
- [106] N. Houslsby, A. Giurgiu, S. Jastrzebski, B. Morrone, Q. De Laroussilhe, A. Gesmundo, M. Attariyan, S. Gelly, 파라미터 효율적인 전이 학습을 위한 nlp, 국제 기계학습 컨퍼런스에서, PMLR, 2019, pp. 2790–2799. 7, 20
- [107] S. McCandlish, J. Kaplan, D. Amodei, O. D. Team, 대규모 배치 훈련에 대한 경험적 모델, arXiv preprint arXiv:1812.06162 (2018). 7
- [108] W. Zeng, X. Ren, T. Su, H. Wang, Y. Liao, Z. Wang, X. Jiang, Z. Yang, K. Wang, X. Zhang, et al., Pangu- α : 대규모 자기회귀 사전 훈련 중국어 언어 모델 및 자동 병렬 계산, arXiv preprint arXiv:2104.12369 (2021). 8, 23, 24, 25
- [109] S. Yuan, H. Zhao, Z. Du, M. Ding, X. Liu, Y. Cen, X. Zou, Z. Yang, J. Tang, Wudaocorpora: 대규모 중국어 말뭉치를 위한 사전 훈련 언어 모델, AI Open 2 (2021) 65–68. 8, 30
- [110] Y. Sun, S. Wang, S. Feng, S. Ding, C. Pang, J. Shang, J. Liu, X. Chen, Y. Zhao, Y. Lu 외, Ernie 3.0: 대규모 지식 향상 사전 훈련 언어 이해 및 생성, arXiv 예비 인쇄 arXiv:2107.02137 (2021). 8, 25
- [111] Z. Dai, Z. Yang, Y. Yang, J. Carbonell, Q. V. Le, R. Salakhutdinov, Transformer-xl: 고정 길이 컨텍스트를 넘어서는 주목 기계 단어 모델, arXiv 사전 인쇄 arXiv:1901.02860 (2019). 8
- [112] O. Lieber, O. Sharir, B. Lenz, Y. Shoham, Jurassic-1: 기술 세부 사항 및 평가, 백서. AI 21 Labs 1 (2021). 8, 24, 25
- [113] Y. Levine, N. Wies, O. Sharir, H. Bata, A. Shashua, 자기 주의의 깊이 효율성에 대한 한계, Neural Information Processing Systems 33 (2020) 22640–22651. 8, 11
- [114] B. Kim, H. Kim, S.-W. Lee, G. Lee, D. Kwak, D. H. Jeon, S. Park, S. Kim, S. Kim, D. Seo 외, 대규모 언어 모델이 어떤 변화를 가져올 수 있을까? 하이퍼클로바에 대한 집중 연구: 수십억 규모의 한국어 생성 사전 훈련 변환기, arXiv 사전 인쇄 arXiv:2109.04650 (2021). 8, 25
- [115] S. Wu, X. Zhao, T. Yu, R. Zhang, C. Shen, H. Liu, F. Li, H. Zhu, J. Luo, L. Xu 외, Yuan 1.0: 제로샷 및 소수샷 학습을 위한 대규모 사전 훈련 언어 모델, arXiv 사전 인쇄를 arXiv:2110.04725 (2021). 8, 24, 25
- [116] J. W. Rae, S. Borgeaud, T. Cai, K. Millican, J. Hoffmann, F. Song, J. Aslanides, S. Henderson, R. Ring, S. Young, 외 여러 저자, 언어 모델 확장: 방법, 분석 및 Gopher 훈련에서의 통찰, arXiv 사전 인쇄 arXiv:2112.11446 (2021). 8, 9, 25, 28
- [117] S. Smith, M. Patwary, B. Norick, P. LeGresley, S. Rajbhandari, J. Casper, Z. Liu, S. Prabhunoye, G. Zerveas, V. Korthikanti 외, deepspeed와 megatron을 사용하여 대규모 생성 언어 모델인 megatron-turing nlg 530b를 훈련시키다, arXiv 사전 인쇄를 arXiv:2201.11990 (2022). 8, 9, 24, 25
- [118] S. Black, S. Biderman, E. Hallahan, Q. Anthony, L. Gao, L. Golding, H. He, C. Leahy, K. McDonell, J. Phang 외, Gpt-neox-20b: 오픈 소스 자기 회귀 언어 모델, arXiv 사전 인쇄 arXiv:2204.06745 (2022). 9, 23, 24, 25
- [119] W. Ben, K. Anar, Gpt-j-6b: 60억 개 매개변수를 가진 자기 회귀 언어 모델 (2021). 9
- [120] P. Micikevicius, S. Narang, J. Alben, G. Diamos, E. Elsen, D. Garcia, B. Ginsburg, M. Houston, O. Kuchaiev, G. Venkatesh 외, 혼합 정밀도 훈련, arXiv 사전 인쇄 arXiv:1710.03740 (2017). 9, 23
- [121] N. Shazeer, A. Mirhoseini, K. Maziarz, A. Davis, Q. Le, G. Hinton, J. Dean, 엄청나게 큰 신경망: 희소 게이트 혼합 전문가가 증, arXiv 사전 인쇄 arXiv:1701.06538 (2017). 9, 23
- [122] S. Soltan, S. Ananthkrishnan, J. FitzGerald, R. Gupta, W. Hamza, H. Khan, C. Peris, S. Rawls, A. Rosenbaum, A. Rumshisky, 외, Alexatm 20b: 대규모 다국어 seq2seq 모델을 이용한 소수 샷 학습, arXiv 사전 인쇄를 arXiv:2208.01448 (2022). 9, 23, 24, 25
- [123] R. Anil, A. M. Dai, O. Firat, M. Johnson, D. Lepikhin, A. Passos, S. Shakeri, E. Taroopa, P. Bailey, Z. Chen 외, Palm 2 기술 보고서, arXiv 사전 인쇄를 arXiv:2305.10403 (2023). 9, 25
- [124] Y. Tay, J. Wei, H. W. Chung, V. Q. Tran, D. R. So, S. Shakeri, X. Garcia, H. S. Zheng, J. Rao, A. Chowdhery 외, 0.1%의 추가 계산으로 스케일링 법칙을 초월하다, arXiv 사전 인쇄 arXiv:2210.11399 (2022). 9, 24, 25
- [125] Y. Tay, M. Dehghani, V. Q. Tran, X. Garcia, J. Wei, X. Wang, H. W. Chung, D. Bahri, T. Schuster, S. Zheng 외., UL2: 언어 학습 패러다임 통합, 제11회 국제 표현 학습 컨퍼런스, 2022. 9, 10, 24, 25
- [126] Z. Du, Y. Qian, X. Liu, M. Ding, J. Qiu, Z. Yang, J. Tang, Glm: 일반 언어 모델 사전 학습과 자기 회귀 공백 채우기, in: 제60회 컴퓨터 언어학회 연례 회의 논문집 (1편: 장문), 2022, pp. 320–335. 10
- [127] H. Touvron, T. Lavril, G. Izacard, X. Martinet, M.-A. Lachaux, T. Lacroix, B. Rozière, N. Goyal, E. Hambro, F. Azhar, et al., Llama: Open and efficient foundation language models, arXiv preprint arXiv:2302.13971 (2023). 10, 23, 25
- [128] M. N. Rabe, C. Staats, Self-attention은 $O(n^2)$ 메모리를 필요로 하지 않는다, arXiv 사전 인쇄 arXiv:2112.05682 (2021). 10
- [129] V. A. Korthikanti, J. Casper, S. Lym, L. McAfee, M. Andersch, M. Shoenybi, B. Catanzaro, 대규모 변환기 모델에서 활성화 재계산 줄이기, Machine Learning and Systems 5 (2023)의 Proceedings. 10
- [130] A. Dubey, A. Jauhri, A. Pandey, A. Kadian, A. Al-Dahle, A. Letman, A. Mathur, A. Schelten, A. Yang, A. Fan 외, The llama 3 herd of models, arXiv preprint arXiv:2407.21783 (2024). 10, 25
- [131] <https://mistral.ai/news/mixtral-8x22b/>. 10, 25
- [132] <https://github.com/Snowflake-Labs/snowflake-arctic.10>, 25
- [133] <https://github.com/xai-org/grok-1.10>
- [134] <https://x.ai/blog/grok-1.5.10>
- [135] G. Team, R. Anil, S. Borgeaud, Y. Wu, J.-B. Alayrac, J. Yu, R. Soricut, J. Schalkwyk, A. M. Dai, A. Hauth 외, Gemini: 고성능 다중 모달 모델의 가족, arXiv 사전 인쇄 arXiv:2312.11805 (2023).
- [136] M. Reid, N. Savinov, D. Teplyashin, D. Lepikhin, T. Lillitrap, J.-b.

- Alayrac, R. Soricut, A. Lazaridou, O. Firat, J. Schrittwieser 외, Gemini 1.5: 수백만 개의 문맥 토큰을 통한 다중 모달 이해의 개방, arXiv 사전 인쇄 arXiv:2403.05530 (2024). 10
- [137] B. Adler, N. Agarwal, A. Aithal, D. H. Anh, P. Bhattacharya, A. Brundyn, J. Casper, B. Catanzaro, S. Clay, J. Cohen 외, Nemotron-4 340b 기술 보고서, arXiv preprint arXiv:2406.11704 (2024). 10, 25
- [138] X. Bi, D. Chen, G. Chen, S. Chen, D. Dai, C. Deng, H. Ding, K. Dong, Q. Du, Z. Fu, et al., Deepseek llm: Scaling open-source language models with longtermism, arXiv preprint arXiv:2401.02954 (2024). 10, 25
- DeepSeek-AI, A. Liu, B. Feng, B. Wang, B. Wang, B. Liu, C. Zhao, C. Deng, C. Ruan, D. Dai, D. Guo, D. Yang, D. Chen, D. Ji, E. Li, F. Lin, F. Luo, G. Hao, G. Chen, G. Li, H. Zhang, H. Xu, H. Yang, H. Zhang, H. Ding, H. Xin, H. Gao, H. Li, H. Qu, J. L. Cai, J. Liang, J. Guo, J. Ni, J. Li, J. Chen, J. Yuan, J. Qiu, J. Song, K. Dong, K. Gao, K. Guan, L. Wang, L. Zhang, L. Xu, L. Xia, L. Zhao, L. Zhang, M. Li, M. Wang, M. Zhang, M. Tang, M. Li, N. Tian, P. Huang, P. Wang, P. Zhang, Q. Zhu, Q. Chen, Q. Du, R. J. Chen, R. L. Jin, R. Ge, R. Pan, R. Xu, R. Chen, S. S. Li, S. Lu, S. Zhou, S. Chen, S. Wu, S. Ye, S. Ma, S. Wang, S. Zhou, S. Yu, S. Zhou, S. Zheng, T. Wang, T. Pei, T. Yuan, T. Sun, W. L. Xiao, W. Zeng, W. An, W. Liu, W. Liang, W. Gao, W. Zhang, X. Q. Li, X. Jin, X. Wang, X. Bi, X. Liu, X. Wang, X. Shen, X. Chen, X. Chen, X. Nie, X. Sun, Deepseek-v2: 강력하고 경제적이고 효율적인 전문가 혼합 언어 모델, CoRR abs/2405.04434(2024). 10, 25
- [140] E. Nijkamp, B. Pang, H. Hayashi, L. Tu, H. Wang, Y. Zhou, S. Savarese, C. Xiong, C. Odegen: 코드용 오픈 대형 언어 모델과 다중 전 프로그램 합성을 위한 arXiv 사전 인쇄물 arXiv:2203.13474 (2022). 11, 23, 25, 28
- [141] M. Chen, J. Tworek, H. Jun, Q. Yuan, H. P. d. O. Pinto, J. Kaplan, H. Edwards, Y. Burda, N. Joseph, G. Brockman 외, 코드로 훈련된 대규모 언어 모델 평가, arXiv 사전 인쇄 arXiv:2107.03374 (2021). 11, 25, 29, 31
- [142] Y. Li, D. Choi, J. Chung, N. Kushman, J. Schrittwieser, R. Leblond, T. Eccles, J. Keeling, F. Gimeno, A. Dal Lago, et al., Competition-level code generation with alphacode, Science 378 (6624) (2022) 1092–1097. 11, 23, 25, 29
- [143] N. Shazeer, Fast transformer decoding: One write-head is all you need, arXiv preprint arXiv:1911.02150 (2019). 11
- [144] R. Y. Pang, H. He, Demonstrations로부터 학습하여 텍스트 생성하기, arXiv 사전 인쇄 arXiv:2009.07839 (2020). 11
- R. Dabre, A. Fujita, Softmax tempering for training neural machine translation models, arXiv preprint arXiv:2009.09372 (2020).
- [146] Y. Wang, W. Wang, S. Joty, S. C. Hoi, Codet5: 식별자 인식을 고려한 코드 이해 및 생성을 위한 통합 사전 훈련된 인코더-디코더 모델, arXiv 사전 인쇄 arXiv:2109.00859 (2021). 11
- [147] R. Li, L. B. Allal, Y. Zi, N. Muennighoff, D. Kocetkov, C. Mou, M. Marone, C. Akiki, J. Li, J. Chim 외, Starcoder: may the source be with you!, arXiv preprint arXiv:2305.06161 (2023). 11, 25
- [148] R. Taylor, M. Kardas, G. Cucurull, T. Scialom, A. Hartshorn, E. Saravia, A. Poulton, V. Kerkez, R. Stojnic, Galactica: 과학을 위한 대형 언어 모델, arXiv 사전 인쇄 arXiv:2211.09085 (2022). 11, 24, 25, 29
- [149] FairScale 저자들, FairScale: 고성능 및 대규모 훈련을 위한 일반 목적의 모듈형 Pytorch 라이브러리, <https://github.com/facebookresearch/fairscale> (2021). 11
- [150] R. Thoppilan, D. De Freitas, J. Hall, N. Shazeer, A. Kulshreshtha, H.-T. Cheng, A. Jin, T. Bos, L. Baker, Y. Du 외, Lamda: 대화 응용을 위한 언어 모델, arXiv 사전 인쇄 arXiv:2201.08239 (2022). 11, 25
- [151] S. Wu, O. Irsoy, S. Lu, V. Dabravolski, M. Dredze, S. Gehrmann, P. Kambadur, D. Rosenberg, G. Mann, Bloombergpt: 금융을 위한 대형 언어 모델, arXiv 사전 인쇄 arXiv:2303.17564 (2023). 11, 25, 33
- [152] X. Zhang, Q. Yang, D. Xu, Xuanyuan 2.0: 수백억 개의 매개변수를 가진 대형 중국 금융 채팅 모델, arXiv 사전 인쇄 arXiv:2305.12002 (2023). 11, 17, 25
- [153] W. Ben, Mesh-transformer-jax: JAX를 이용한 모델 병렬 구현의 트랜스포머 언어 모델 (2021). 12, 24
- [154] N. Muennighoff, T. Wang, L. Sutawika, A. Roberts, S. Biderman, T. L. Scao, M. S. Bari, S. Shen, Z.-X. Yong, H. Schoelkopf 외, Crosslingual generalization through multitask finetuning, arXiv preprint arXiv:2211.01786 (2022). 16, 25, 28, 31
- [155] D. Yin, X. Liu, F. Yin, M. Zhong, H. Bansal, J. Han, K.-W. Chang, Dynosaur: instruction-tuning 데이터를 위한 동적 성장 패러다임
- ration, arXiv preprint arXiv:2305.14327 (2023). 16
- [156] P. Gao, J. Han, R. Zhang, Z. Lin, S. Geng, A. Zhou, W. Zhang, P. Lu, C. He, X. Yue, 외, Llama-adapter v2: 파라미터 효율적인 시각적 지칭 모델, arXiv 사전 인쇄 arXiv:2304.15010 (2023). 16, 24
- [157] Openai. gpt-4 기술 보고서 (2023). 16, 35
- [158] R. Taori, I. Gulrajani, T. Zhang, Y. Dubois, X. Li, C. Guestrin, P. Liang, T. B. Hashimoto, Stanford alpaca: An instruction-following llama model, https://github.com/tatsu-lab/stanford_alpaca (2023). 16, 25, 28
- [159] W.-L. Chiang, Z. Li, Z. Lin, Y. Sheng, Z. Wu, H. Zhang, L. Zheng, S. Zhuang, Y. Zhuang, J. E. Gonzalez, I. Stoica, E. P. Xing, Vicuna: 90%* ChatGPT 품질로 GPT-4를 능가하는 오픈 소스 챗봇 (2023년 3월). URL <https://lmsys.org/blog/2023-03-30-vicuna/> 16, 22, 25, 28
- [160] B. Peng, C. Li, P. He, M. Galley, J. Gao, GPT-4로의 지시 조정, arXiv 사전 인쇄 arXiv:2304.03277 (2023). 16, 28
- T. Liu, B. K. H. Low, Goat: 세밀하게 조정된 llama가 gpt-4보다 산수 작업에서 성능이 우수함, arXiv 사전 인쇄물 arXiv:2305.14201 (2023). 16
- [162] H. Wang, C. Liu, N. Xi, Z. Qiang, S. Zhao, B. Qin, T. Liu, Huatuo: 중국 의학 지식을 활용한 llama 모델 조정, arXiv 사전 인쇄 arXiv:2304.06975 (2023). 16
- C. Xu, Q. Sun, K. Zheng, X. Geng, P. Zhao, J. Feng, C. Tao, D. Jiang, Wizardlm: 복잡한 지시를 따르도록 대형 언어 모델을 강화하는 방법, arXiv 사전 인쇄물 arXiv:2304.12244 (2023). 16
- [164] Z. Luo, C. Xu, P. Zhao, Q. Sun, X. Geng, W. Hu, C. Tao, J. Ma, Q. Lin, D. Jiang, Wizardcoder: 코드 대형 언어 모델을 evol-instruct로 강화하기, arXiv 사전 인쇄물 arXiv:2306.08568 (2023). 16, 25
- [165] J. Menick, M. Trebacz, V. Mikulik, J. Aslanides, F. Song, M. Chadwick, M. Glaese, S. Young, L. Campbell-Gillingham, G. Irving, et al., 언어 모델이 검증된 인공구로 답변을 지원하도록 가르치기, arXiv 사전 인쇄물 arXiv:2203.11147 (2022). 17
- [166] R. Nakano, J. Hilton, S. Balaji, J. Wu, L. Ouyang, C. Kim, C. Hesse, S. Jain, V. Kosaraju, W. Saunders, 외, Webgpt: Browser-assisted question-answering with human feedback, arXiv preprint arXiv:2112.09332 (2021). 17, 19, 20, 25, 31
- [167] A. Glaese, N. McAleese, M. Tr̃ebacz, J. Aslanides, V. Firoiu, T. Ewalds, M. Rauh, L. Weidinger, M. Chadwick, P. Thacker 외, 대화 에이전트의 정렬 개선을 위한 목표한 인간 판단, arXiv 사전 인쇄 arXiv:2209.14375 (2022). 17, 20, 25
- [168] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning, C. Finn, 직접 선호 최적화: 당신의 언어 모델은 비밀리에 보상 모델입니다, arXiv 사전 인쇄 arXiv:2305.18290 (2023). 17
- H. Dong, W. Xiong, D. Goyal, R. Pan, S. Diao, J. Zhang, K. Shum, T. Zhang, Raft: 보상 순위 세분화 기법을 통한 생성 기반 모델 정렬, arXiv 사전 인쇄 arXiv:2304.06767 (2023). 17
- [170] Z. Yuan, H. Yuan, C. Tan, W. Wang, S. Huang, F. Huang, Rrhf: 인간 피드백에 맞춰 언어 모델을 슬픔 없이 정렬하기 위한 응답 순위 매기기, arXiv 사전 인쇄 arXiv:2304.05302 (2023). 17
- [171] F. Song, B. Yu, M. Li, H. Yu, F. Huang, Y. Li, H. Wang, 인간 정합성을 위한 선호 순위 최적화, arXiv 사전 인쇄 arXiv:2306.17492 (2023). 17
- [172] H. Liu, C. Sferrazza, P. Abbeel, 언어는 보상이다: 인간 피드백을 사용한 회고적 미세 조정, arXiv 사전 인쇄물 arXiv:2302.02676 (2023).
- [173] Y. Bai, S. Kadavath, S. Kundu, A. Askell, J. Kernion, A. Jones, A. Chen, A. Goldie, A. Mirhoseini, C. McKinnon 외, Constitutional ai: Harmlessness from ai feedback, arXiv preprint arXiv:2212.08073 (2022). 17
- [174] Y. Dubois, X. Li, R. Taori, T. Zhang, I. Gulrajani, J. Ba, C. Guestrin, P. Liang, T. B. Hashimoto, AlpacaFarm: 인간 피드백을 통해 학습하는 방법을 위한 시뮬레이션 프레임워크, arXiv 사전 인쇄 arXiv:2305.14387 (2023). 17
- [175] C. Si, Z. Gan, Z. Yang, S. Wang, J. Wang, J. Boyd-Graber, L. Wang, GPT-3의 신뢰성을 높이기 위한 프롬프트, arXiv 사전 인쇄 arXiv:2210.09150 (2022).
- [176] D. Ganguli, A. Askell, N. Schiefer, T. Liao, K. Lukõiūtė, A. Chen, A. Goldie, A. Mirhoseini, C. Olsson, D. Hernandez, 외, 대규모 언어 모델에서 도덕적 자기 수정의 능력, arXiv 사전 인쇄 arXiv:2302.07459 (2023). 17
- [177] A. Wei, N. Haghtalab, J. Steinhardt, Jailbroken: llm 안전 훈련이 어떻게 실패하는가?, arXiv 사전 인쇄 arXiv:2307.02483 (2023). 17

- [178] D. Ganguli, L. Lovitt, J. Kernion, A. Askell, Y. Bai, S. Kadavath, B. Mann, E. Perez, N. Schiefer, K. Ndousse, 외, 언어 모델의 위험을 줄이기 위한 레드팀 방법, 스케일링 행동 및 배운 교훈, arXiv 사전 인쇄 arXiv:2209.07858 (2022). 17, 28
- [179] S. Casper, J. Lin, J. Kwon, G. Culp, D. Hadfield-Menell, Explore, establish, exploit: Red teaming language models from scratch, arXiv preprint arXiv:2306.09442 (2023). 17
- [180] E. Perez, S. Huang, F. Song, T. Cai, R. Ring, J. Aslanides, A. Glaese, N. McAleese, G. Irving, 언어 모델을 이용한 언어 모델의 레드 팀 구성, arXiv 사전 인쇄 arXiv:2202.03286 (2022). 17
- T. Scialom, T. Chakrabarty, S. Muresan, 세밀하게 조정된 언어 모델은 지속적인 학습자입니다, 2022년 자연어 처리의 경험적 방법에 관한 회의 자료, 2022년, 6107–6122쪽. 17
- [182] Z. Shi, A. Lipani, “프리트레이닝을 중단하지 마세요? 프롬프트 기반의 파인튜닝이 강력한 학습자가 되도록 하세요,” arXiv 사전 인쇄 arXiv:2305.01711 (2023). 17
- [183] H. Gupta, S. A. Sawant, S. Mishra, M. Nakamura, A. Mitra, S. Mashetty, C. Baral, Instruction tuned models are quick learners, arXiv preprint arXiv:2306.05539 (2023). 17
- H. Chen, Y. Zhang, Q. Zhang, H. Yang, X. Hu, X. Ma, Y. Yanggong, J. Zhao, 아마도 0.5%의 데이터만 필요하다: 저훈련 데이터 지시 조정에 대한 예비 탐색, arXiv 사전 인쇄본 arXiv:2305.09246 (2023). 17
- C. Zhou, P. Liu, P. Xu, S. Iyer, J. Sun, Y. Mao, X. Ma, A. Efrat, P. Yu, L. Yu 등, Lima: Alignment에 대한 Less is more, arXiv preprint arXiv:2305.11206 (2023). 17, 25, 28
- [186] C. Han, Q. Wang, W. Xiong, Y. Chen, H. Ji, S. Wang, Lm-infinite: Simple on-the-fly length generalization for large language models, arXiv preprint arXiv:2308.16137 (2023). 17, 18
- [187] J. Ainslie, T. Lei, M. de Jong, S. Ontañón, S. Brahma, Y. Zemlyanskiy, D. Uthus, M. Guo, J. Lee-Thorp, Y. Tay 외, Colt5: 조건부 계산을 통한 더 빠른 장거리 트랜스포머, arXiv 미리 인쇄 arXiv:2303.09752 (2023). 18
- [188] J. Ding, S. Ma, L. Dong, X. Zhang, S. Huang, W. Wang, F. Wei, Longnet: Scaling transformers to 1,000,000,000 tokens, arXiv preprint arXiv:2307.02486 (2023). 18
- [189] Y. Chen, S. Qian, H. Tang, X. Lai, Z. Liu, S. Han, J. Jia, Longlora: 긴 맥락의 대형 언어 모델을 효율적으로 미세 조정하기, arXiv 사전 인쇄물 arXiv:2309.12307 (2023). 18
- [190] N. Ratner, Y. Levine, Y. Belinkov, O. Ram, I. Magar, O. Abend, E. Karpas, A. Shashua, K. Leyton-Brown, Y. Shoham, "Parallel context windows for large language models", in: Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2023, pp. 6383–6402. 18
- W. Wang, L. Dong, H. Cheng, X. Liu, X. Yan, J. Gao, F. Wei, 장기 메모리로 언어 모델 강화하기, arXiv 사전 인쇄물 arXiv:2306.07174 (2023). 18
- [192] X. Xu, Z. Gou, W. Wu, Z.-Y. Niu, H. Wu, H. Wang, S. Wang, 오픈랜미에요! 장기적인 인격 메모리를 가진 개방형 대화, arXiv 프리프린트 arXiv:2203.05797 (2022). 18
- [193] S. Borgeaud, A. Mensch, J. Hoffmann, T. Cai, E. Rutherford, K. Millican, G. B. Van Den Driessche, J.-B. Lespiau, B. Damoc, A. Clark 외, "수조 개의 토큰에서 검색을 통해 언어 모델 개선하기", International conference on machine learning, PMLR, 2022, pp. 2206–2240. 18, 19, 34
- W. Zhong, L. Guo, Q. Gao, Y. Wang, Memorybank: Enhancing large language models with long-term memory, arXiv preprint arXiv:2305.10250 (2023).
- [195] N. Shinn, F. Cassano, B. Labash, A. Gopinath, K. Narasimhan, S. Yao, Reflexion: 언어 에이전트와 언어적 강화 학습, arXiv 프리프린트 arXiv:2303.11366 14(2023). 18, 20
- [196] C. Hu, J. Fu, C. Du, S. Luo, J. Zhao, H. Zhao, Chatdb: 데이터베이스를 기호 메모리로 활용하여 llms를 증강하는 방법, arXiv 사전 인쇄 arXiv:2306.03901 (2023). 18
- [197] Z. Jiang, F. F. Xu, L. Gao, Z. Sun, Q. Liu, J. Dwivedi-Yu, Y. Yang, J. Callan, G. Neubig, Active retrieval augmented generation, arXiv preprint arXiv:2305.06983 (2023). 18
- [198] O. Ram, Y. Levine, I. Dalmedigos, D. Muhlgay, A. Shashua, K. Leyton-Brown, Y. Shoham, In-context retrieval-augmented language models, arXiv preprint arXiv:2302.00083 (2023). 18, 34
- [199] X. Li, X. Qiu, Mot: 사전 사고 및 회상이 chatgpt가 생각의 기억으로 자기 개선을 가능하게 한다, arXiv 프리프린트 arXiv:2305.05181 (2023). 18
- [200] D. Schuurmans, 메모리 강화 대형 언어 모델은 계산적으로 보편적이다, arXiv 사전 인쇄 arXiv:2301.04589 (2023). 18
- A. Modarressi, A. Imani, M. Fayyaz, H. Schütze, Ret-llm: 대형 언어 모델을 위한 일반적인 읽기-쓰기 메모리, arXiv 사전 인쇄 arXiv:2305.14322 (2023). 18
- [202] S. Robertson, H. Zaragoza, 외, 확률적 관련성 프레임워크: Bm25와 그 이상, 정보 검색의 기초 및 동향* 3 (4) (2009) 333–389. 18
- [203] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, D. Zhou, Rationale-augmented ensembles in language models, arXiv preprint arXiv:2207.00747 (2022). 18
- [204] F. Zhang, B. Chen, Y. Zhang, J. Liu, D. Zan, Y. Mao, J.-G. Lou, W. Chen, Repocode r: 리포지토리 수준의 코드 완성을 위한 반복 검색 및 생성, arXiv 사전 인쇄 arXiv:2303.12570 (2023). 18
- [205] B. Wang, W. Ping, P. Xu, L. McAfee, Z. Liu, M. Shoybi, Y. Dong, O. Kuchaiev, B. Li, C. Xiao 외, 우리는 검색을 통해 자가 회귀 언어 모델을 사전 훈련할 것인가? 포괄적인 연구, arXiv 사전 인쇄 arXiv:2304.06762 (2023). 19
- [206] L. Wang, N. Yang, F. Wei, 대형 언어 모델을 위한 맥락 내 예제 검색 학습, arXiv 사전 인쇄 arXiv:2307.07164 (2023). 19
- [207] J. Liu, D. Shen, Y. Zhang, B. Dolan, L. Carin, W. Chen, GPT-3에 대한 좋은 맥락 예시를 만드는 요소는 무엇인가?, arXiv 사전 인쇄본 arXiv:2101.06804 (2021). 19
- [208] O. Rubin, J. Herzig, J. Berant, in-context learning을 위한 프롬프트 검색 학습, arXiv preprint arXiv:2112.08633 (2021). 19
- [209] W. Shi, S. Min, M. Yasunaga, M. Seo, R. James, M. Lewis, L. Zettlemoyer, W.-t. Yih, Replug: Retrieval-augmented black-box language models, arXiv preprint arXiv:2301.12652 (2023). 19
- [210] O. Rubin, J. Berant, Long-range language modeling with self-retrieval, arXiv preprint arXiv:2306.13421 (2023). 19
- [211] K. Guu, K. Lee, Z. Tung, P. Pasupat, M. Chang, Retrieval augmented language model pre-training, in: International conference on machine learning, PMLR, 2020, pp. 3929–3938. 19
- [212] S. Hofstätter, J. Chen, K. Raman, H. Zamani, Fid-light: 효율적이고 효과적인 검색 증강 텍스트 생성, 제46회 국제 ACM SIGIR 정보 검색 및 개발 회의 발표, 2023, pp. 1437–1447.
- [213] M. Komeili, K. Shuster, J. Weston, Internet-augmented dialogue generation, arXiv preprint arXiv:2107.07566 (2021). 19
- A. Lazaridou, E. Gribovskaya, W. Stokowiec, N. Grigorev, 인터넷 증강 언어 모델을 위한 몇 가지 샷 프롬프트를 통한 개방형 질문 응답, arXiv 사전 인쇄 arXiv:2203.05115 (2022).
- [215] D. Gao, L. Ji, L. Zhou, K. Q. Lin, J. Chen, Z. Fan, M. Z. Shou, Assist-gpt: 계획하고, 실행하고, 검사하고, 학습할 수 있는 일반적으로 사용 가능한 다중 도말 어시스턴트, arXiv preprint arXiv:2306.08640 (2023). 19
- [216] P. Lu, B. Peng, H. Cheng, M. Galley, K.-W. Chang, Y. N. Wu, S.-C. Zhu, J. Gao, Chameleon: 플러그 앤 플레이 구성 추론을 위한 대형 언어 모델, arXiv 사전 인쇄 arXiv:2304.09842 (2023). 19, 20, 23
- [217] B. Paranjape, S. Lundberg, S. Singh, H. Hajishirzi, L. Zettlemoyer, M. T. Ribeiro, Art: 자동 다단계 추론 및 도구 사용을 위한 대규모 언어 모델, arXiv 사전 인쇄 arXiv:2303.09014 (2023). 19
- [218] C.-Y. Hsieh, S.-A. Chen, C.-L. Li, Y. Fujii, A. Ratner, C.-Y. Lee, R. Krishna, T. Pfister, 도구 문서화가 대형 언어 모델을 이용한 제로샷 도구 사용을 가능하게 한다, arXiv 사전 인쇄물 arXiv:2308.00675 (2023). 19
- [219] Y. Song, W. Xiong, D. Zhu, C. Li, K. Wang, Y. Tian, S. Li, Restgpt: RESTful API를 통해 대규모 언어 모델과 실제 애플리케이션을 연결하다, arXiv 예비 출판 arXiv:2306.06624 (2023). 19
- [220] S. Hao, T. Liu, Z. Wang, Z. Hu, Toolkengpt: 기존 언어 모델을 도구 임베딩을 통해 방대한 도구로 증강하기, arXiv 사전 인쇄 arXiv:2305.11554 (2023). 19
- [221] S. G. Patil, T. Zhang, X. Wang, J. E. Gonzalez, Gorilla: 대규모 언어 모델과 대규모 API 연결, arXiv 사전 인쇄 arXiv:2305.15334 (2023). 19
- [222] Q. Xu, F. Hong, B. Li, C. Hu, Z. Chen, J. Zhang, 오픈 소스 대형 언어 모델의 도구 조작 능력에 대해, arXiv 사전 인쇄 arXiv:2305.16504 (2023). 19
- [223] Y. Qin, S. Liang, Y. Ye, K. Zhu, L. Yan, Y. Lu, Y. Lin, X. Cong, X. Tang, B. Qian, et al., Toolllm: 16,000개 이상의 실제 API를 마스터하는 데 도움을 주는 대형 언어 모델, arXiv 사전 인쇄 arXiv:2307.16789 (2023). 19,

- [224] Y. Shen, K. Song, X. Tan, D. Li, W. Lu, Y. Zhuang, Hugginggpt: AI 작업을 ChatGPT와 Huggingface의 친구들로 해결하기, arXiv 사전 인쇄물 arXiv:2303.17580 (2023). 19, 20, 33
- [225] Y. Liang, C. Wu, T. Song, W. Wu, Y. Xia, Y. Liu, Y. Ou, S. Lu, L. Ji, S. Mao 등, Taskmatrix.ai: 수백만 개의 API와 기초 모델을 연결하여 작업을 완료하는 방법, arXiv 사전 인쇄물 arXiv:2303.16434 (2023). 19
- [226] D. Surís, S. Menon, C. Vondrick, Vipergpt: Visual inference via python execution for reasoning, arXiv preprint arXiv:2303.08128 (2023). 20
- A. Maedche, S. Morana, S. Schacht, D. Werth, J. Krumeich, 고급 사용자 지원 시스템, 비즈니스 및 정보 시스템 공학 58 (2016) 367–370. 20
- [228] M. Campbell, A. J. Hoane Jr, F.-h. Hsu, Deep blue, 인공지능 134 (1-2) (2002) 57–83. 20
- [229] S. Hong, X. Zheng, J. Chen, Y. Cheng, J. Wang, C. Zhang, Z. Wang, S. K. S. Yau, Z. Lin, L. Zhou 외, Metagpt: 여러 에이전트 협업 프레임워크를 위한 메타 프로그래밍, arXiv 사전인쇄물 arXiv:2308.00352 (2023). 20
- [230] Z. Xi, W. Chen, X. Guo, W. He, Y. Ding, B. Hong, M. Zhang, J. Wang, S. Jin, E. Zhou, et al., 대형 언어 모델 기반 에이전트의 부상과 잠재력: 조사, arXiv 사전 인쇄물 arXiv:2309.07864 (2023). 20
- [231] L. Wang, C. Ma, X. Feng, Z. Zhang, H. Yang, J. Zhang, Z. Chen, J. Tang, X. Chen, Y. Lin 외, 대형 언어 모델 기반 자율 에이전트에 대한 조사, arXiv 사전 인쇄물 arXiv:2308.11432 (2023). 20
- [232] W. Huang, P. Abbeel, D. Pathak, I. Mordatch, 언어 모델을 제로샷 계획자로 활용하기: 구현된 에이전트를 위한 실행 가능한 지식 추출, 국제 머신러닝 컨퍼런스에서, PMLR, 2022, pp. 9118–9147.
- [233] S. Hao, Y. Gu, H. Ma, J. J. Hong, Z. Wang, D. Z. Wang, Z. Hu, 언어 모델과의 추론은 세계 모델과의 계획이다, arXiv 사전 인쇄물 arXiv:2305.14992 (2023). 20, 33
- [234] W. Yao, S. Heinecke, J. C. Niebles, Z. Liu, Y. Feng, L. Xue, R. Murthy, Z. Chen, J. Zhang, D. Arpit, 등, Retroformer: Retrospective large language agents with policy gradient optimization, arXiv preprint arXiv:2308.02151 (2023). 20, 33
- [235] W. Huang, F. Xia, T. Xiao, H. Chan, J. Liang, P. Florence, A. Zeng, J. Tompson, I. Mordatch, Y. Chebotar, P. Sermanet, T. Jackson, N. Brown, L. Luu, S. Levine, K. Hausman, brian ichter, Inner monologue: Embodied reasoning through planning with language models, in: 6th Annual Conference on Robot Learning, 2022. URL <https://openreview.net/forum?id=3R3Pz5iOtye> 20
- [236] C. Jin, W. Tan, J. Yang, B. Liu, R. Song, L. Wang, J. Fu, Alphablock: 로봇 조작에서 비전-언어 추론을 위한 신체화된 세부 조정, arXiv 사전 인쇄물 arXiv:2305.18898 (2023). 20, 33
- [237] I. Singh, V. Blukis, A. Mousavian, A. Goyal, D. Xu, J. Tremblay, D. Fox, J. Thomas on, A. Garg, Progprompt: 대형 언어 모델을 이용한 상황적 로봇 작업 계획 생성, 2023 IEEE 국제 로봇 및 자동화 컨퍼런스(ICRA), IEEE, 2023, pp. 11523–11530. 20, 33
- [238] W. Yu, N. Gileadi, C. Fu, S. Kirmani, K.-H. Lee, M. G. Arenas, H.-T. L. Chiang, T. Er ez, L. Hasenclever, J. Humplik 외, 로봇 기술 합성을 위한 보상 언어, arXiv 사전 인쇄물 arXiv:2306.08647 (2023). 20
- [239] X. Tang, A. Zou, Z. Zhang, Y. Zhao, X. Zhang, A. Cohan, M. Gerstein, Medagents: Large language models as collaborators for zero-shot medical reasoning, arXiv preprint arXiv:2311.10537 (2023). 20
- [240] A. Brohan, Y. Chebotar, C. Finn, K. Hausman, A. Herzog, D. Ho, J. Ibarz, A. Irpan, E. Jang, R. Julian 외, "내가 말하는 대로가 아니라 내가 할 수 있는 대로 행동하라: 로봇의 가능성에 기반한 언어의 기초," 제2023년 로봇 학습 회의, PMLR, 287–318쪽. 20, 33
- H. Ha, P. Florence, S. Song, 스케일 업 및 디스틸 다운: 언어 기반 로봇 기술 습득, arXiv 사전 인쇄물 arXiv:2307.14535 (2023).
- [242] A. Rajvanshi, K. Sikka, X. Lin, B. Lee, H.-P. Chiu, A. Velasquez, Say-nav: 새로운 환경에서 내비게이션을 위한 동적 계획을 위한 대형 언어 모델의 기초, arXiv 사전 인쇄물 arXiv:2309.04077 (2023).
- [243] C. H. Song, J. Wu, C. Washington, B. M. Sadler, W.-L. Chao, Y. Su, Llm-planner: 프리샷 그라운드 계획을 위한 대형 언어 모델을 활용한 체현된 에이전트의 계획, arXiv 사전 인쇄물 arXiv:2212.04088 (2022). 20
- [244] V. S. Dorbala, J. F. Mullen Jr, D. Manocha, 구현된 에이전트가 찾을 수 있을까
- "당신의 고양이 모양 머그컵"? llm 기반 제로샷 객체 탐색, arXiv 프리프린트 arXiv:2303.03480 (2023). 20
- C. Huang, O. Mees, A. Zeng, W. Burgard, 로봇 내비게이션을 위한 시각 언어 맵, 2023 IEEE 국제 로봇 및 자동화 회의(ICRA), IEEE, 2023, pp. 10608–10615. 20
- [246] Y. Ding, X. Zhang, C. Paxton, S. Zhang, 객체 재배치를 위한 대형 언어 모델을 통한 작업 및 동작 계획, arXiv 사전 인쇄물 arXiv:2303.06247 (2023). 20, 33
- [247] X. Liu, Y. Zheng, Z. Du, M. Ding, Y. Qian, Z. Yang, J. Tang, Gpt도 이해한다, arXiv preprint arXiv:2103.10385 (2021). 20, 21
- [248] G. Chen, F. Liu, Z. Meng, S. Liang, 파라미터 효율적인 조정 재조명: 우리가 정말로 그 단계에 도달했는가?, arXiv 사전 인쇄물 arXiv:2202.07962 (2022).
- [249] Y. Wang, S. Mukherjee, X. Liu, J. Gao, A. H. Awadallah, J. Gao, Adamix: 파라미터 효율적인 대형 언어 모델 튜닝을 위한 혼합 어댑터, arXiv 사전 인쇄물 arXiv:2205.12410 1 (2) (2022) 4. 20
- [250] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, W. Chen, Lora: 대형 언어 모델의 저순위 적응, arXiv 사전 인쇄물 arXiv:2106.09685 (2021). 21, 22, 23
- [251] X. Liu, K. Ji, Y. Fu, W. Tam, Z. Du, Z. Yang, J. Tang, P-tuning: 프롬프트 튜닝은 규모와 작업에 따라 파인 튜닝과 비교할 수 있다, in: 제60회 연례 컴퓨터 언어학 회의 프로시딩스 (볼륨 2: 짧은 논문), 2022, pp. 61–68. 21
- [252] A. Razdaibiedina, Y. Mao, R. Hou, M. Khabsa, M. Lewis, A. Almahairi, Progressive prompts: Continual learning for language models, arXiv preprint arXiv:2301.12314 (2023). 21
- [253] Z.-R. Zhang, C. Tan, H. Xu, C. Wang, J. Huang, S. Huang, 파라미터 효율적인 언어 모델 미세 조정을 위한 적응형 점두사 조정으로 나아가다, arXiv 사전 인쇄물 arXiv:2305.15212 (2023). 21
- [254] E. B. Zaken, S. Ravfogel, Y. Goldberg, Bitfit: Simple parameter-efficient fine-tuning for transformer-based masked language-models, arXiv preprint arXiv:2106.10199 (2021). 21
- [255] T. Dettmers, M. Lewis, Y. Belkada, L. Zettlemoyer, Llm.int8 (): 8비트 행렬 곱셈을 대규모 변환기에 적용한 연구, arXiv 사전 인쇄물 arXiv:2208.07339 (2022). 21, 22
- E. Frantar, S. Ashkboos, T. Hoeffler, D. Alistarh, Gptq: 정밀한 훈련 후 양자화 기법을 위한 생성형 사전 훈련 변환기, arXiv preprint arXiv:2210.17323 (2022). 21
- [257] X. Wei, Y. Zhang, Y. Li, X. Zhang, R. Gong, J. Guo, X. Liu, Outlier suppression+: 대규모 언어 모델의 정확한 양자화를 위한 동등하고 최적화된 이동 및 스케일링, arXiv 사전 인쇄물 arXiv:2304.09145 (2023). 21
- [258] E. Frantar, D. Alistarh, 최적의 뇌 압축: 정확한 훈련 후 양자화 및 가지치기를 위한 프레임워크, Neural Information Processing Systems 35 (2022) 4475–4488. 21
- [259] C. Lee, J. Jin, T. Kim, H. Kim, E. Park, Owq: 대형 언어 모델에서 가중치 양자화를 위한 활성화 이탈치로부터 얻은 교훈, arXiv 사전 인쇄물 arXiv:2306.02272 (2023). 21
- [260] S. J. Kwon, J. Kim, J. Bae, K. M. Yoo, J.-H. Kim, B. Park, B. Kim, J.-W. Ha, N. Sung, D. Lee, Alphascaling: 양자화 인식을 고려한 대규모 사전 훈련 언어 모델의 파라미터 효율적인 적응, arXiv preprint arXiv:2210.03858 (2022). 21
- T. Dettmers, A. Pagnoni, A. Holtzman, L. Zettlemoyer, Qlora: 양자화된 llms의 효율적인 파인튜닝, arXiv 사전 인쇄물 arXiv:2305.14314 (2023).
- [262] Z. Liu, B. Oguz, C. Zhao, E. Chang, P. Stock, Y. Mehdad, Y. Shi, R. Krishnamoorthi, V. Chandra, Llm-qat: 데이터 없이 대규모 언어 모델을 위한 양자화 인식 훈련, arXiv 사전 인쇄물 arXiv:2305.17888 (2023). 21, 22
- [263] Y. Guo, A. Yao, H. Zhao, Y. Chen, 네트워크 스케치: 딥 CNN에서 이진 구조 활용, in: IEEE 컴퓨터 비전 및 패턴 인식 회의 프로시딩, 2017, pp. 5955–5963. 21
- [264] J. Kim, J. H. Lee, S. Kim, J. Park, K. M. Yoo, S. J. Kwon, D. Lee, 압축된 대형 언어 모델의 메모리 효율적인 미세 조정을 위한 서브 4비트 정수 양자화, arXiv 사전출판 arXiv:2305.14152 (2023).
- [265] M. Sun, Z. Liu, A. Bair, J. Z. Kolter, 대형 언어 모델을 위한 간단하고 효과적인 가지치기 접근법, arXiv 사전 인쇄물 arXiv:2306.11695 (2023). 22
- [266] Z. Wang, J. Wohlwend, T. Lei, 대규모 언어 모델의 구조적 가지치기, arXiv 사전 인쇄물 arXiv:1910.04732 (2019). 22

- [267] L. Yin, Y. Wu, Z. Zhang, C.-Y. Hsieh, Y. Wang, Y. Jia, M. Pechenizkiy, Y. Liang, Z. Wang, S. Liu, Outlier weighed layerwise sparsity (owl): 높은 희소성을 위한 llms 가 지지기의 한 비밀 재료, arXiv 사전 인쇄 arXiv:2310.05175 (2023). 22
- C. Tao, L. Hou, H. Bai, J. Wei, X. Jiang, Q. Liu, P. Luo, N. Wong, 효율적인 생성 사전 훈련 언어 모델을 위한 구조적 가지치기, 컴퓨터 언어학 협회 회의록: ACL 2023, 2023, pp. 10 880–10895. 22
- [269] J.-B. Alayrac, J. Donahue, P. Luc, A. Miech, I. Barr, Y. Hasson, K. Lenc, A. Mensch, K. Millican, M. Reynolds, et al., Flamingo: 적은 샷 학습을 위한 시각 언어 모델, Advances in Neural Information Processing Systems 35 (2022) 23716–23736. 22
- [270] J. Li, D. Li, S. Savarese, S. Hoi, Blip-2: 언어-이미지 사전 훈련을 동결된 이미지 인코더 와 대형 언어 모델로 부트스트랩하기, arXiv 사전 인쇄 arXiv:2301.12597 (2023). 22
- [271] H. Liu, C. Li, Q. Wu, Y. J. Lee, Visual instruction tuning, arXiv preprint arXiv:2304. 08485 (2023). 22
- [272] K. Li, Y. He, Y. Wang, Y. Li, W. Wang, P. Luo, Y. Wang, L. Wang, Y. Qiao, Videochat: Chat-centric video understanding, arXiv preprint arXiv:2305.06355 (2023). 22
- [273] M. Maaz, H. Rasheed, S. Khan, F. S. Khan, Video-chatgpt: 대규모 비전 및 언어 모델 을 통한 상세한 비디오 이해를 향하여, arXiv preprint arXiv:2306.05424 (2023). 22
- [274] H. Zhang, X. Li, L. Bing, Video-llama: An instruction-tuned audio-visual language model for video understanding, arXiv preprint arXiv:2306.02858 (2023). 22
- [275] X. Mei, C. Meng, H. Liu, Q. Kong, T. Ko, C. Zhao, M. D. Plumbley, Y. Zou, W. Wang, Wavcaps: ChatGPT 보조 약한 레이블의 오디오 캡셔닝 데이터셋으로 오디오-언어 다 중 모달 연구를 위한, arXiv 사전 인쇄 arXiv:2303.17395 (2023). 22
- [276] C. Lyu, M. Wu, L. Wang, X. Huang, B. Liu, Z. Du, S. Shi, Z. Tu, Macaw-llm: 이미지, 오디오, 비디오, 텍스트 통합을 통한 다중 모달 언어 모델링, arXiv 사전 인쇄 arXiv:2306. 09093 (2023). 22
- [277] D. Zhu, J. Chen, X. Shen, X. Li, M. Elhoseiny, Minigpt-4: 고급 대형 언어 모델을 통한 시각-언어 이해의 향상, arXiv 사전 인쇄 arXiv:2304.10592 (2023). 22
- [278] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly 외, 이미지 하나는 16x16 단어의 가 치가 있다: 대규모 이미지 인식을 위한 트랜스포머, arXiv 예프린트 arXiv:2010.11929 (2020). 22
- [279] W. Dai, J. Li, D. Li, A. M. H. Tiong, J. Zhao, W. Wang, B. Li, P. Fung, S. Hoi, Instruct blip: 일반 목적의 비전-언어 모델을 위한 지침 튜닝, arXiv 사전 인쇄 arXiv:2305.06500 (2023). 22
- [280] Z. Xu, Y. Shen, L. Huang, Multiinstruct: Instruction tuning을 통한 다중 모달 제로샷 학습 개선, arXiv 사전 인쇄 arXiv:2212.10773 (2022). 22
- [281] Z. Zhao, L. Guo, T. Yue, S. Chen, S. Shao, X. Zhu, Z. Yuan, J. Liu, Chatbridge: Brid ging modalities with large language model as a language catalyst, arXiv prepr int arXiv:2305.16103 (2023). 22
- [282] L. Li, Y. Yin, S. Li, L. Chen, P. Wang, S. Ren, M. Li, Y. Yang, J. Xu, X. Sun, et al., M3 i t: 다중 모달 다국어 지침 조정을 위한 대규모 데이터셋, arXiv 사전 인쇄 arXiv:2306.043 87 (2023). 22
- [283] R. Pi, J. Gao, S. Diao, R. Pan, H. Dong, J. Zhang, L. Yao, J. Han, H. Xu, L. K. T. Zha ng, Detgpt: 필요한 것을 추론을 통해 탐지하기, arXiv 사전 인쇄 arXiv:2305.14167 (20 23). 22
- [284] G. Luo, Y. Zhou, T. Ren, S. Chen, X. Sun, R. Ji, 저렴하고 빠른: 대형 언어 모델을 위한 효율적인 시각-언어 지시 조정, arXiv 사전인쇄물 arXiv:2305.15023 (2023). 22
- [285] R. Zhang, J. Han, A. Zhou, X. Hu, S. Yan, P. Lu, H. Li, P. Gao, Y. Qiao, Llama-adapt er: 제로 초기화 주의(attention)를 활용한 언어 모델의 효율적인 세부 조정, arXiv prep rint arXiv:2303.16199 (2023). 22
- A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, I. Sutskever, 대규모 약한 감독을 통한 강력한 음성 인식, 2023년 국제 기계 학습 회의, PMLR, 28492쪽
28518. 22
- [287] Z. Zhang, A. Zhang, M. Li, H. Zhao, G. Karypis, A. Smola, 언어 모델에서의 다중 모달 사고 흐름 추론, arXiv 사전 인쇄 arXiv:2302.00923 (2023). 23
- [288] J. Ge, H. Luo, S. Qian, Y. Gan, J. Fu, S. Zhan, Chain of thought prompt tuning in vision language models, arXiv preprint arXiv:2304.07919 (2023). 23
- [289] C. Wu, S. Yin, W. Qi, X. Wang, Z. Tang, N. Duan, Visual chatgpt: Talking, drawing and editing with visual foundation models, arXiv preprint arXiv:2303.04671 (2 023). 23
- [290] Z. Yang, L. Li, J. Wang, K. Lin, E. Azarnasab, F. Ahmed, Z. Liu, C. Liu, M. Zeng, L. Wang, Mm-react: ChatGPT를 활용한 다중 모달 추론 및 행동 촉진, arXiv 사전 인쇄를 arXiv:2303.11381 (2023). 23
- [291] T. Wang, J. Zhang, J. Fei, Y. Ge, H. Zheng, Y. Tang, Z. Li, M. Gao, S. Zhao, Y. Shan, et al., 무엇이든 설명하기: 다양한 다중 모드 제어를 통한 상호작용 이미지 설명, arXiv 사전 인쇄 arXiv:2305.02677 (2023). 23
- [292] X. Zhu, R. Zhang, B. He, Z. Zeng, S. Zhang, P. Gao, Pointclip v2: Clip을 강력한 3D 오픈 월드 학습에 적응시키기, arXiv 사전 인쇄 arXiv:2211.11682 (2022). 23
- [293] T. Gupta, A. Kembhavi, Visual programming: Compositional visual reasoning wi thout training, in: Proceedings of the IEEE/CVF Conference on Computer Visio n and Pattern Recognition, 2023, pp. 14953–14962.
- [294] P. Gao, Z. Jiang, H. You, P. Lu, S. C. Hoi, X. Wang, H. Li, 시각 질문 응답을 위한 내부 및 외부 모달리티 주의 흐름을 통한 동적 융합, in: 2019 IEEE/CVF 컴퓨터 비전 및 패턴 인식 회의록, pp. 6639–6648. 23
- [295] Z. Yu, J. Yu, Y. Cui, D. Tao, Q. Tian, 시각적 질문 응답을 위한 딥 모듈러 공동 주의 네트 워크, IEEE/CVF 컴퓨터 비전 및 패턴 인식 컨퍼런스 프로시딩스, 2019, pp. 6281– 6290. 23
- [296] H. You, R. Sun, Z. Wang, L. Chen, G. Wang, H. A. Ayyubi, K.-W. Chang, S.-F. Chang , Idealgpt: 대규모 언어 모델을 통한 비전 및 언어 추론을 반복적으로 분해하기, arXiv 사 전 인쇄 arXiv:2305.14985 (2023). 23
- [297] R. Zhang, X. Hu, B. Li, S. Huang, H. Deng, Y. Qiao, P. Gao, H. Li, "프롬프트 생성 후 캐시하기: 기초 모델의 연쇄가 강력한 소수 샷 학습기를 만든다," in: P roceedings of the IEEE/CVF Conference on Computer Vision and Pattern Reco gnition, 2023, pp. 15211–15222.
- [298] T. Q. Nguyen, J. Salazar, 눈물 없는 변환기: 자기 주의의 정규화를 개선하기, CoRR abs/ 1910.05895 (2019). 24
- [299] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoye r, V. Stoyanov, Roberta: 견고하게 최적화된 BERT 사전 훈련 접근법, arXiv 사전 인쇄 arXiv:1907.11692 (2019). 24, 30
- [300] X. Geng, A. Gudibande, H. Liu, E. Wallace, P. Abbeel, S. Levine, D. Song, Koala: 학습 연구를 위한 대화 모델, 블로그 게시물 (2023년 4월). URL <https://bair.berkeley.edu/blog/2023/04/03/koala/>
- [301] L. Gao, S. Biderman, S. Black, L. Golding, T. Hoppe, C. Foster, J. Phang, H. He, A. Thite, N. Nabeshima 외, The pile:An 800gb dataset of diverse text for languag e modeling, arXiv preprint arXiv:2101.00027 (2020). 28, 30
- [302] H. Laurençon, L. Saulnier, T. Wang, C. Akiki, A. Villanova del Moral, T. Le Scao, L. Von Werra, C. Mou, E. González Ponferrada, H. Nguyen, 외, The bigscience ro ots corpus: A 1.6 tb composite multilingual dataset, Advances in Neural Infor mation Processing Systems 35 (2022) 31809–31826. 28
- [303] Wikipedia. URL https://en.wikipedia.org/wiki/Main_Page 28
- [304] Together Computer, Redpajama: llama 훈련 데이터셋을 재현하기 위한 오픈 소스 레 시피 (2023년 4월). URL <https://github.com/togethercomputer/RedPajama-Data> 28
- [305] O. Honovich, T. Scialom, O. Levy, T. Schick, 비자연적인 지침: (거의) 인간의 노동 없 이 언어 모델 조정하기, arXiv 사전 인쇄 arXiv:2212.09689 (2022). 28
- [306] Y. Bai, A. Jones, K. Ndousse, A. Askell, A. Chen, N. DasSarma, D. Drain, S. Fort, D. Ganguli, T. Henighan 외, 인간 피드백을 통한 강화 학습으로 유용하고 무해한 보조자 를 훈련시키기, arXiv 사전 인쇄본 arXiv:2204.05862 (2022). 28
- [307] D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, J. Steinhardt, 대 량의 다중 작업 언어 이해 측정, arXiv 사전 인쇄 arXiv:2009.03300 (2020). 26, 29
- [308] A. Srivastava, A. Rastogi, A. Rao, A. A. M. Shoen, A. Abid, A. Fisch, A. R. Brown, A. Santoro, A. Gupta, A. Garriga-Alonso 외, Beyond

- 모방 게임: 언어 모델의 능력을 정량화하고 외삽하기, arXiv 사전 인쇄 arXiv:2206.04615 (2022). 26, 29
- [309] A. Wang, A. Singh, J. Michael, F. Hill, O. Levy, S. R. Bowman, Glue: 자연어 이해를 위한 다중 작업 벤치마크 및 분석 플랫폼, arXiv 사전 인쇄물 arXiv:1804.07461 (2018). 26, 29
- [310] Y. Yao, Q. Dong, J. Guan, B. Cao, Z. Zhang, C. Xiao, X. Wang, F. Qi, J. Bao, J. Nie, et al., Cuge: 중국어 이해 및 생성 평가 벤치마크, arXiv 사전 인쇄 arXiv:2112.13610 (2021).
- [311] L. Xu, H. Hu, X. Zhang, L. Li, C. Cao, Y. Li, Y. Xu, K. Sun, D. Yu, C. Yu 외, Clue: 중국어 이해 평가 벤치마크, arXiv 사전 인쇄 arXiv:2004.05986 (2020). 29
- [312] L. Xu, X. Lu, C. Yuan, X. Zhang, H. Xu, H. Yuan, G. Wei, X. Pan, X. Tian, L. Qin 외, Few-Shot Learning 평가 벤치마크, arXiv 사전 인쇄물 arXiv:2107.07498 (2021). 29
- [313] E. M. Smith, M. Williamson, K. Shuster, J. Weston, Y.-L. Boureau, 모든 것을 종합할 수 있습니까: 대화형 에이전트의 기술 융합 능력 평가, arXiv 사전 인쇄 arXiv:2004.08449 (2020). 29
- [314] P. Liang, R. Bommasani, T. Lee, D. Tsipras, D. Soylu, M. Yasunaga, Y. Zhang, D. Narayanan, Y. Wu, A. Kumar 등, 언어 모델의 총체적 평가, arXiv 사전 인쇄본 arXiv:2211.09110 (2022). 29
- [315] S. Park, J. Moon, S. Kim, W. I. Cho, J. Han, J. Park, C. Song, J. Kim, Y. Song, T. Oh, et al., Klue: 한국어 이해 평가, arXiv 사전 인쇄 arXiv:2105.09680 (2021). 29
- [316] S. Reddy, D. Chen, C. D. Manning, Coqa: 대화형 질문 답변 도전 과제, Computational Linguistics 협회 거래 7 (2019) 249–266. 27, 29
- [317] M.T. Pilehvar, J. Camacho-Collados, Wic: 10,000 example pairs for evaluating context-sensitive representations, arXiv preprint arXiv:1808.09121 6 (2018). 27, 29
- [318] S. Merity, C. Xiong, J. Bradbury, R. Socher, Pointer sentinel mixture models, arXiv preprint arXiv:1609.07843 (2016). 28, 29
- [319] J. W. Rae, A. Potapenko, S. M. Jayakumar, T. P. Lillicrap, Compressive transformers for long-range sequence modelling, arXiv preprint arXiv:1911.05507 (2019). 28, 29
- [320] X. Liu, Q. Chen, C. Deng, H. Zeng, J. Chen, D. Li, B. Tang, Lcqm: 대규모 중국어 질문 매칭 코퍼스, in: 제27회 국제 컴퓨터 언어학 회의 논문집, 2018, pp. 1952–1962. 28, 29
- [321] S. Iyer, N. Dandekar, K. Csernai, First quora dataset release: Questionpairs, <https://quoradata.quora.com/First-Quora-Dataset-Release-Question-Pairs>. 29
- [322] R. Rudinger, J. Naradowsky, B. Leonard, B. Van Durme, 성 편향이 코어퍼런스 해결에 미치는 영향, arXiv 사전 인쇄 arXiv:1804.09301 (2018). 29
- [323] M.-C. De Marneffe, M. Simons, J. Tonhauser, The commitmentbank: 자연 발생 대화에서의 투자 조사, in: Sinn und Bedeutung 회의록, 제23권, 2019, pp. 107–124. 29
- [324] Z. Li, N. Ding, Z. Liu, H. Zheng, Y. Shen, 다중 입자 정보와 외부 언어 지식을 활용한 중국어 관계 추출, in: 제57회 컴퓨터 언어학 회의 연례 회의 자료, 2019, pp. 4377–4386. 29
- [325] J. Xu, J. Wen, X. Sun, Q. Su, 중국 문학 텍스트를 위한 담화 수준의 명명된 개체 인식 및 관계 추출 데이터셋, arXiv 사전 인쇄물 arXiv:1711.07010 (2017). 29
- [326] J. Chen, Q. Chen, X. Liu, H. Yang, D. Lu, B. Tang, The bq corpus: A large-scale domain-specific chinese corpus for sentence semantic equivalence identification, in: Proceedings of the 2018 conference on empirical methods in natural language processing, 2018, pp. 4946–4951. 29
- [327] B. Liu, D. Niu, H. Wei, J. Lin, Y. He, K. Lai, Y. Xu, 그래픽 분해 및 컨볼루션을 이용한 기사 쌍 매칭, arXiv 사전 인쇄 arXiv:1802.07459 (2018). 29
- [328] P. Li, W. Li, Z. He, X. Wang, Y. Cao, J. Zhou, W. Xu, 개방형 사실 질문 응답을 위한 데이터셋과 신경 회귀 시퀀스 레이블링 모델, arXiv 사전 인쇄 arXiv:1607.06275 (2016). 29
- [329] N. Peng, M. Dredze, 중국 소셜 미디어를 위한 명칭 식별: 공동 훈련된 임베딩을 사용하여, 2015년 자연어 처리의 경험적 방법에 관한 학회 자료집, 2015, pp. 548–554. 29
- [330] W. Ling, D. Yogatama, C. Dyer, P. Blunsom, 비유 생성에 의한 프로그램 유도: 대수적 단어 문제를 해결하고 설명하는 방법 학습, arXiv 사전 인쇄물 arXiv:1705.04146 (2017). 29
- [331] R. Weischedel, S. Pradhan, L. Ramshaw, M. Palmer, N. Xue, M. Marcus, A. Taylor, C. Greenberg, E. Hovy, R. Belvin 외, Ontonotes release 4.0, LDC2011T03, 필라델피아, 펜실베이니아: 언어 데이터 컨소시엄 (2011). 29
- [332] D. Vilares, C. Gómez-Rodríguez, Head-qa: 복잡한 추리를 위한 의료 데이터셋, arXiv 사전 인쇄 arXiv:1906.04701 (2019). 29
- [333] S. L. Blodgett, L. Green, B. O'Connor, 소셜 미디어에서의 인구 통계적 방언 변동: 아프리카계 미국인 영어의 사례 연구, arXiv 사전 인쇄 arXiv:1608.08868 (2016). 29
- [334] N. Mostafazadeh, N. Chambers, X. He, D. Parikh, D. Batra, L. Vanderwende, P. Kohli, J. Allen, 일반적인 이야기에 대한 더 깊은 이해를 위한 말뭉치 및 평가 프레임워크, arXiv preprint arXiv:1604.01696 (2016). 28, 29
- [335] D. Paperno, G. Kruszewski, A. Lazaridou, Q. N. Pham, R. Bernardi, S. Pezzelle, M. Baroni, G. Boleda, R. Fernández, The lambada dataset: Word prediction requiring a broad discourse context, arXiv preprint arXiv:1606.06031 (2016). 28, 29
- [336] B. Hu, Q. Chen, F. Zhu, Lcsts: 대규모 중국어 짧은 텍스트 요약 데이터셋, arXiv 사전 인쇄 arXiv:1506.05865 (2015). 29
- [337] Z. Shao, M. Huang, J. Wen, W. Xu, X. Zhu, 계획 기반 계층적 변분 모델을 이용한 길고 다양한 텍스트 생성, arXiv 사전 인쇄 arXiv:1908.06605 (2019). 29
- [338] J. Novikova, O. Dušek, V. Rieser, The e2e dataset: New challenges for end-to-end generation, arXiv preprint arXiv:1706.09254 (2017). 29
- [339] C. Zheng, M. Huang, A. Sun, Chid: 대규모 중국어 관용구 데이터셋 클로즈 테스트용, arXiv 사전 인쇄 arXiv:1906.01265 (2019). 29
- [340] Y. Bisk, R. Zellers, J. Gao, Y. Choi, et al., Piqa: 자연어에서 물리적 상식에 대한 추론, in: AAAI 인공지능 콘퍼런스 논문집, Vol. 34, 2020, pp. 7432–7439. 28, 29
- [341] M. Joshi, E. Choi, D. S. Weld, L. Zettlemoyer, Triviaqa: 대규모 원거리 감독 챗봇 데이터셋을 통한 독해력 평가, arXiv 사전 인쇄 arXiv:1705.03551 (2017). 28, 29, 31
- [342] P. Clark, I. Cowhey, O. Etzioni, T. Khot, A. Sabharwal, C. Schoenick, O. Tafjord, 질문 답변 문제를 해결했다고 생각하십니까? arc, ai2 추론 도전에 도전해 보세요, arXiv 사전 인쇄 arXiv:1803.05457 (2018). 28, 29, 31
- [343] S. Aroca-Ouellette, C. Paik, A. Roncone, K. Kann, Prost: 공간과 시간에 대한 물체의 물리적 추론, arXiv 사전 인쇄 arXiv:2106.03634 (2021). 29
- [344] T. Mihaylov, P. Clark, T. Khot, A. Sabharwal, 갑옷이 전기를 통할 수 있는가? 오픈 북 질문 답변을 위한 새로운 데이터셋, arXiv 사전 인쇄 arXiv:1809.02789 (2018). 29
- [345] T. C. Ferreira, C. Gardent, N. Illyikh, C. Van Der Lee, S. Mille, D. Moussallem, A. Shmorina, 2020년 이중 언어, 양방향 webnlg+ 공유 작업 개요 및 평가 결과(webnlg+ 2020), 제3회 의미 웹에서의 자연어 생성 국제 워크숍(WebNLG+) 발표집, 2020. 29
- [346] C. Xu, W. Zhou, T. Ge, K. Xu, J. McAuley, F. Wei, 개를 부는 개 짖는 소리: 상식과 세계 지식을 이해하지 못하는 중국 데이터셋, arXiv 사전 인쇄 arXiv:2104.02704 (2021). 29
- [347] G. Lai, Q. Xie, H. Liu, Y. Yang, E. Hovy, Race: 대규모 읽기 이해 데이터셋, arXiv 사전 인쇄 arXiv:1704.04683 (2017). 29
- [348] E. Choi, H. He, M. Iyyer, M. Yatskar, W.-t. Yih, Y. Choi, P. Liang, L. Zettlemoyer, Quac: 상황에서의 질문 응답, arXiv 사전 인쇄 arXiv:1808.07036 (2018). 29
- [349] M. Geva, D. Khashabi, E. Segal, T. Khot, D. Roth, J. Berant, 아리스토텔레스는 노트 북을 사용했을까? 암묵적 추론 전략을 가진 질문 응답 벤치마크, Computational Linguistics 협회 Transactions 9 (2021) 346–361. 29, 31
- [350] J. Boyd-Graber, B. Satinoff, H. He, H. Daumé III, 퀴즈 마스터 이기가: 점진적 분류 게임의 크라우드소싱, in: 2012년 자연어 처리 및 계산적 자연어 학습에 관한 공동 회의 논문집, 2012, pp. 1290–1301. 29
- [351] S. Zhang, X. Zhang, H. Wang, J. Cheng, P. Li, Z. Ding, 중국 의료 질문 답변 매칭을 위한 엔드 투 엔드 문자 수준 다중 스케일 CNN, Applied Sciences 7 (8) (2017) 767. 29
- [352] S. Zhang, X. Zhang, H. Wang, L. Guo, S. Liu, 중국 의료 질의 응답 선택을 위한 다중 규모 주의 상호 작용 네트워크, IEEE

- Access 6 (2018) 74061–74071. 29
- [353] C. Xu, J. Pei, H. Wu, Y. Liu, C. Li, Matinf: 분류, 질문 응답 및 요약에 위한 공동 라벨링된 대규모 데이터셋, arXiv 사전 인쇄 arXiv:2004.12302 (2020). 29
- [354] K. Sakaguchi, R. L. Bras, C. Bhagavatula, Y. Choi, Winogrande: 대규모 적대적 원오 그라드 스키마 도전, Communications of the ACM 64 (9) (2021) 99–106. 27, 29
- [355] R. Zellers, A. Holtzman, Y. Bisk, A. Farhadi, Y. Choi, Hellaswag: 기계가 정말로 당신의 문장을 완성할 수 있을까?, arXiv 사전 인쇄 arXiv:1905.07830 (2019). 29
- [356] M. Roemmele, C. A. Bejan, A. S. Gordon, 그럴듯한 대안의 선택: 상식적 인과 추론의 평가, in: AAAI 봄 심포지엄: 상식적 추론의 논리적 형식화, 2011, pp. 90–95. 29
- [357] H. Levesque, E. Davis, L. Morgenstern, The winograd schema challenge, in: 제13회 국제 지식 표현 및 추론 원칙 회의, 2012. 27, 29
- [358] A. Talmor, J. Herzig, N. Lourie, J. Berant, Commonsenseqa: 상식 지식을 겨냥한 질문 응답 챌린지, arXiv 사전 인쇄 arXiv:1811.00937 (2018). 29, 31
- [359] M. Sap, H. Rashkin, D. Chen, R. LeBras, Y. Choi, Socialqa: 사회적 상호작용에 대한 상식적 추론, arXiv 사전 인쇄물 arXiv:1904.09728 (2019). 29
- [360] K. Sun, D. Yu, D. Yu, C. Cardie, 도전적인 중국어 기계 독해를 위한 사전 지식 조사, Computational Linguistics 저널 8 (2020) 141–155. 29
- [361] S. Zhang, X. Liu, J. Liu, J. Gao, K. Duh, B. Van Durme, Record: 인간과 기계의 상식 독해 이해 사이의 격차를 메우기, arXiv 사전 인쇄 arXiv:1810.12885 (2018). 29
- [362] P. Rajpurkar, J. Zhang, K. Lopyrev, P. Liang, Squad: 100,000개 이상의 질문을 통한 기계의 텍스트 이해, arXiv 사전 인쇄 arXiv:1606.05250 (2016). 29, 31
- [363] C. Clark, K. Lee, M.-W. Chang, T. Kwiatkowski, M. Collins, K. Toutanova, Boolq: 자연스러운 예/아니오 질문의 예상치 못한 난이도 탐구, arXiv 사전 인쇄물 arXiv:1905.10044 (2019). 29, 31
- [364] P. Rajpurkar, R. Jia, P. Liang, 당신이 모르는 것을 알라: Squad에 대한 답할 수 없는 질문들, arXiv 사전 인쇄 arXiv:1806.03822 (2018). 29, 31
- [365] D. Dua, Y. Wang, P. Dasigi, G. Stanovsky, S. Singh, M. Gardner, Drop: 단락에 대한 개별적 추론을 요구하는 독해 벤치마크, arXiv 사전 인쇄물 arXiv:1903.00161 (2019). 29, 31
- [366] I. Dagan, O. Glickman, B. Magnini, 파스칼 텍스트 의미 관계 인식 도전, 기계 학습 도전 워크숍, Springer, 2005, pp. 177–190. 29, 31
- [367] Y. Chang, M. Narang, H. Suzuki, G. Cao, J. Gao, Y. Bisk, Webqa: 다중 홉 및 다중 모달 QA, in: Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 16495–16504. 29, 31
- [368] Y. Cui, T. Liu, Z. Chen, W. Ma, S. Wang, G. Hu, 중국 기계 독해 이해에 대한 첫 번째 평가를 위한 데이터셋, arXiv preprint arXiv:1709.08299 (2017). 29
- [369] Y. Cui, T. Liu, W. Che, L. Xiao, Z. Chen, W. Ma, S. Wang, G. Hu, 중국 기계 독해 이해를 위한 스파인 추출 데이터셋, arXiv 사전 인쇄 arXiv:1810.07366 (2018). 29, 31
- [370] Y. Cui, T. Liu, Z. Yang, Z. Chen, W. Ma, W. Che, S. Wang, G. Hu, 중국어 기계 독해를 위한 문장 클로즈 데이터셋, arXiv preprint arXiv:2004.03116 (2020). 29
- [371] Y. Li, T. Liu, D. Li, Q. Li, J. Shi, Y. Wang, 중국 의견 대상 추출을 위한 pos와 사전을 통합한 문자 기반 bilstm-crf, 아시아 머신러닝 컨퍼런스에서, PMLR, 2018, pp. 518–533.
- [372] D. Khashabi, S. Chaturvedi, M. Roth, S. Upadhyay, D. Roth, 표면 너머를 바라보다: 여러 문장에 대한 독해 도전 과제, in: 2018년 북미 컴퓨터 언어학회: 인간 언어 기술 회의록, 1권 (장문 논문), 2018, pp. 252–262. 29
- [373] T. Kwiatkowski, J. Palomaki, O. Redfield, M. Collins, A. Parikh, C. Alberti, D. Epstein, I. Polosukhin, J. Devlin, K. Lee 외, 자연 질문: 질문 응답 연구를 위한 기준, Association for Computational Linguistics 회보 7 (2019) 453–466. 29
- [374] C. C. Shao, T. Liu, Y. Lai, Y. Tseng, S. Tsai, Drdc: 중국어 기계 독해 데이터셋, arXiv 사전 인쇄 arXiv:1806.00920 (2018). 29
- [375] W. He, K. Liu, J. Liu, Y. Lyu, S. Zhao, X. Xiao, Y. Liu, Y. Wang, H. Wu, Q. She 외, Dureader: 실제 응용 프로그램에서의 중국어 기계 독해 데이터셋, arXiv 사전 인쇄 arXiv:1711.05073 (2017). 29
- [376] H. Tang, J. Liu, H. Li, Y. Hong, H. Wu, H. Wang, Dureaderrobust: 기계 독해 모델의 강인성을 평가하기 위한 중국어 데이터셋, arXiv 사전 인쇄 arXiv:2004.11142 (2020). 29
- [377] J. Welbl, N. F. Liu, M. Gardner, Crowdsourcing multiple choice science questions, arXiv preprint arXiv:1707.06209 (2017). 29
- [378] C. Xiong, Z. Dai, J. Callan, Z. Liu, R. Power, 커널 풀링을 이용한 끝-to-end 신경 임의 순위 매기기, 제40회 국제 ACM SIGIR 정보 검색 및 개발 컨퍼런스 논문집, 2017, pp. 55–64. 29
- A. Peñas, E. Hovy, P. Forner, Á. Rodrigo, R. Sutcliffe, R. Morante, Qa4mre 2011–2013: 기계 독자를 위한 질문 응답 개요, 정보 접근 평가에서. 다국어성, 다중 매체성, 그리고 시각화: CLEF 이니셔티브의 4차 국제 회의, CLEF 2013, 스페인 발렌시아, 2013년 9월 23–26일. 프로시딩스 4, 스프링거, 2013, pp. 303–320.
- [380] S. Lim, M. Kim, J. Lee, Korquad1.0: 기계 독해를 위한 한국어 QA 데이터셋, arXiv 사전 인쇄 arXiv:1909.07005 (2019). 29
- [381] C. Xiao, H. Zhong, Z. Guo, C. Tu, Z. Liu, M. Sun, Y. Feng, X. Han, Z. Hu, H. Wang, et al., Cai2018: 판결 예측을 위한 대규모 법률 데이터셋, arXiv 사전 인쇄 arXiv:1807.02478 (2018). 29
- [382] D. Hendrycks, S. Basart, S. Kadavath, M. Mazeika, A. Arora, E. Guo, C. Burns, S. P. Urbanik, H. He, D. Song 외, "엡을 활용한 코딩 챌린지 능력 측정", arXiv 사전 인쇄 arXiv:2105.09938 (2021). 29, 31
- [383] Y. Wang, X. Liu, S. Shi, 수학 단어 문제를 위한 딥 신경망 해결기, 2017년 자연어 처리의 경험적 방법 컨퍼런스 논문집, 2017, pp. 845–854. 29, 31
- [384] K. Cobbe, V. Kosaraju, M. Bavarian, M. Chen, H. Jun, L. Kaiser, M. Plappert, J. Tworek, J. Hilton, R. Nakano 외, 수학 단어 문제를 해결하기 위한 검증기 훈련, arXiv 사전 인쇄 arXiv:2110.14168 (2021). 29, 31
- [385] J. Austin, A. Odena, M. I. Nye, M. Bosma, H. Michalewski, D. Dohan, E. Jiang, C. J. Cai, M. Terry, Q. V. Le, C. Sutton, 대형 언어 모델을 통한 프로그램 합성, CoRR abs/2108.07732 (2021). 29
- [386] F. Shi, M. Suzgun, M. Freitag, X. Wang, S. Srivats, S. Vosoughi, H. W. Chung, Y. Tay, S. Ruder, D. Zhou, et al., 언어 모델은 다국어 사고 연쇄 추론기이다, arXiv 사전 인쇄 arXiv:2210.03057 (2022). 29
- [387] S. Roy, D. Roth, 일반 산술 문제 해결, arXiv preprint arXiv:1608.01413 (2016). 29
- [388] S.-Y. Miao, C.-C. Liang, K.-Y. Su, 다양한 말 문제 해결사 평가 및 개발을 위한 코퍼스, arXiv 사전 인쇄 arXiv:2106.15772 (2021). 29
- [389] R. Koncel-Kedziorski, S. Roy, A. Amini, N. Kushman, H. Hajishirzi, Mawps: 수학 단어 문제 저장소, in: 2016년 북미 컴퓨터 언어학회 인간 언어 기술 컨퍼런스 프로시딩, 2016, pp. 1152–1157.
- A. Patel, S. Bhattamishra, N. Goyal, nlp 모델이 정말로 수학 단어 문제를 해결할 수 있는가?, arXiv 사전 인쇄 arXiv:2103.07191 (2021).
- [391] Y. Lai, C. Li, Y. Wang, T. Zhang, R. Zhong, L. Zettlemoyer, W.-t. Yih, D. Fried, S. Wang, T. Yu, Ds-1000: 데이터 과학 코드 생성을 위한 자연스럽고 신뢰할 수 있는 기준, in: 국제 기계 학습 회의, PMLR, 2023, pp. 18319–18345. 29
- [392] J. Austin, A. Odena, M. Nye, M. Bosma, H. Michalewski, D. Dohan, E. Jiang, C. Cai, M. Terry, Q. Le 등, 대형 언어 모델을 활용한 프로그램 합성, arXiv 사전 인쇄 arXiv:2108.07732 (2021). 29
- [393] Y. Nie, A. Williams, E. Dinan, M. Bansal, J. Weston, D. Kiela, Adversarial nli: 자연어 이해를 위한 새로운 기준, arXiv preprint arXiv:1910.14599 (2019). 29, 31
- A. Williams, N. Nangia, S. R. Bowman, 문장 이해를 위한 추론 기반의 광범위한 도전 과제 코퍼스, arXiv 사전 인쇄 arXiv:1704.05426 (2017). 29
- R. T. McCoy, E. Pavlick, T. Linzen, 잘못된 이유로 옳은: 진단-

- 자연어 추론에서의 구문적 휴리스틱 탐색, arXiv 사전 인쇄물 arXiv:1902.01007 (2019). 29
- [396] J. Liu, L. Cui, H. Liu, D. Huang, Y. Wang, Y. Zhang, Logiqa: 논리적 추론을 위한 기계 독해 컴프리헨션의 챌린지 데이터셋, arXiv 사전 인쇄 arXiv:2007.08124 (2020). 29
- [397] P. Lewis, B. Oğuz, R. Rinott, S. Riedel, H. Schwenk, Mlqa: 교차 언어 추출 질문 응답 평가, arXiv 사전 인쇄 arXiv:1910.07475 (2019). 29
- [398] A. Conneau, G. Lample, R. Rinott, A. Williams, S. R. Bowman, H. Schwenk, V. Stoyanov, Xnli: 교차 언어 문장 표현 평가, arXiv 사전 인쇄 arXiv:1809.05053 (2018). 29, 31
- [399] Y. Yang, Y. Zhang, C. Tar, J. Baldridge, Paws-x: 크로스-언어 적대적 데이터셋을 위한 패러프레이즈 식별, arXiv 사전 인쇄 arXiv:1908.11828 (2019). 29, 31
- [400] S. Narayan, S. B. Cohen, M. Lapata, 세부사항은 필요 없고 요약만 주세요!, 극단적 요약을 위한 주제 인식 컨볼루션 신경망, arXiv, abs (1808). 29
- [401] E. M. Ponti, G. Glavač, O. Majewska, Q. Liu, I. Vulić, A. Korhonen, Xcopa: 인과 관계에 대한 상식 추론을 위한 다국어 데이터셋, arXiv 사전 인쇄 arXiv:2005.00333 (2020). 29
- A. Tikhonov, M. Ryabinin, 모든 것은 헤드에 달려 있다: 상식 추론에서 언어 간 전이를 위한 기준으로 주의 헤드를 사용하기, arXiv 사전 인쇄 arXiv:2106.12066 (2021). 29
- [403] J. H. Clark, E. Choi, M. Collins, D. Garrette, T. Kwiatkowski, V. Nikolaev, J. Palomaki, Tydi qa: 정보 탐색 질문 응답을 위한 표방언어에서의 기준, Computational Linguistics 협회 거래 8 (2020) 454–470. 29
- [404] T. Scialom, P.-A. Dray, S. Lamprier, B. Piwowarski, J. Staiano, Mlsum: 다국어 요약 코퍼스, arXiv 사전 인쇄 arXiv:2004.14900 (2020). 29
- [405] S. Lin, J. Hilton, O. Evans, Truthfulqa: 모델이 인간의 허위 정보를 얼마나 모방하는지 측정하기, arXiv preprint arXiv:2109.07958 (2021). 29, 32
- [406] I. Augenstein, C. Lioma, D. Wang, L. C. Lima, C. Hansen, C. Hansen, J. G. Simonsen, Multifc: 실제 세계의 다중 도메인 데이터셋을 통한 주장에 대한 근거 기반 사실 확인, arXiv 사전 인쇄물 arXiv:1909.03242 (2019). 29
- [407] J. Thorne, A. Vlachos, C. Christodoulopoulos, A. Mittal, Fever: 대규모 사실 추출 및 검증용 데이터셋, arXiv 사전 인쇄 arXiv:1803.05355 (2018). 29
- [408] I. Mollas, Z. Chrysopoulou, S. Karlos, G. Tsoumakas, Ethos: 온라인 혐오 발언 탐지 데이터셋, arXiv 사전 인쇄 arXiv:2006.08328 (2020). 29, 32
- [409] M. Nadeem, A. Bethke, S. Reddy, Stereoset: 사전 훈련된 언어 모델에서 고정 관념적 편향 측정, arXiv 사전 인쇄 arXiv:2004.09456 (2020). 29, 32
- [410] A. Parrish, A. Chen, N. Nangia, V. Padmakumar, J. Phang, J. Thompson, P. M. Htut, S. R. Bowman, Bbq: 질문 응답을 위한 수작업 편향 벤치마크, arXiv 사전 인쇄 arXiv:2110.08193 (2021). 29
- J. Zhao, T. Wang, M. Yatskar, V. Ordonez, K.-W. Chang, 성별 편향이 핵심 참조 해결에 미치는 영향: 평가 및 편향 제거 방법, arXiv 사전 인쇄 arXiv:1804.06876 (2018). 29
- [412] N. Nangia, C. Vania, R. Bhalerao, S. R. Bowman, Crows-pairs: 사회적 편향을 측정하기 위한 사전 과제 데이터셋, arXiv preprint arXiv:2010.00133 (2020). 29
- [413] S. Gehman, S. Gururangan, M. Sap, Y. Choi, N. A. Smith, Realtoxicityprompts: 언어 모델에서 신경 독성 퇴화를 평가하기, arXiv 사전 인쇄 arXiv:2009.11462 (2020). 29
- [414] D. Borkan, L. Dixon, J. Sorensen, N. Thain, L. Vasserman, 실제 데이터를 사용한 텍스트 분류의 의도하지 않은 편향을 측정하기 위한 미세화된 메트릭, 2019 세계 웹 컨퍼런스의 동행 논문, 2019, pp. 491–500. 29
- [415] O. Bojar, R. Chatterjee, C. Federmann, Y. Graham, B. Haddow, M. Huck, A. J. Yepes, P. Koehn, V. Logacheva, C. Monz, et al., 2016년 기계 번역 학회 결과, in: Proceedings of the First Conference on Machine Translation: Volume 2, Shared Task Papers, 2016, pp. 131–198. 29
- [416] B. Loïc, B. Magdalena, B. Ondřej, F. Christian, G. Yvette, G. Roman, H. Barry, H. Matthias, J. Eric, K. Tom 외, 2020 기계 번역 컨퍼런스(wmt20)의 결과, in: 제5회 기계 번역 컨퍼런스 자료집, 컴퓨터 언어학회, 2020, pp. 1–55. 29
- [417] W. Li, F. Qi, M. Sun, X. Yi, J. Zhang, Ccpm: 중국 고전시 매칭 데이터셋, arXiv 사전 인쇄 arXiv:2106.01979 (2021). 29
- [418] E. Dinan, S. Roller, K. Shuster, A. Fan, M. Auli, J. Weston, Wizard of wikipedia: Knowledge-powered conversational agents, arXiv preprint arXiv:1811.01241 (2018). 29
- H. Rashkin, E. M. Smith, M. Li, Y.-L. Boureau, 공감적인 개방형 대화 모델을 향하여: 새로운 벤치마크와 데이터셋, arXiv 사전 인쇄 arXiv:1811.00207 (2018). 29
- [420] E. Dinan, V. Logacheva, V. Malykh, A. Miller, K. Shuster, J. Urbanek, D. Kiela, A. Szlam, I. Serban, R. Lowe 외, 제2회 대화형 지능 챌린지(ConvAI2), in: The NeurIPS'18 Competition: From Machine Learning to Intelligent Conversations, Springer, 2020, pp. 187–208. 29
- [421] H. Zhou, C. Zheng, K. Huang, M. Huang, X. Zhu, Kdconv: 중국의 다중 도메인 대화 데이터셋으로 다중 턴의 지식 기반 대화를 지향하다, arXiv 사전 인쇄 arXiv:2004.04100 (2020). 29
- [422] L. CO, Iflytek: 다중 범주 중국어 텍스트 분류기. 경쟁 공식 웹사이트 (2019). 29
- [423] J. Baumgartner, S. Zannettou, B. Keegan, M. Squire, J. Blackburn, The pushshift reddit dataset, in: Proceedings of the international AAAI conference on web and social media, Vol. 14, 2020, pp. 830–839. 30
- [424] A. Fan, Y. Jernite, E. Perez, D. Grangier, J. Weston, M. Auli, Eli5: 긴 형식 질문 답변, arXiv 사전 인쇄 arXiv:1907.09190 (2019). 31
- [425] Y. Wang, S. Mishra, P. Alipoormolabashi, Y. Kordi, A. Mirzaei, A. Arunkumar, A. Ashok, A. S. Dhanasekaran, A. Naik, D. Stap, et al., 1,600개 이상의 언어 작업에 대한 맥락 내 지침을 통한 일반화 벤치마킹, arXiv 사전 인쇄 arXiv:2204.07705 (2022). 31
- [426] T. Xie, C. H. Wu, P. Shi, R. Zhong, T. Scholak, M. Yasunaga, C.-S. Wu, M. Zhong, P. Yin, S. I. Wang, et al., Unifiedskg: Unifying and multitasking structured knowledge grounding with text-to-text language models, arXiv preprint arXiv:2201.05966 (2022). 31
- [427] Q. Ye, B. Y. Lin, X. Ren, Crossfit: A few-shot learning challenge for cross-task generalization in NLP, arXiv preprint arXiv:2104.08835 (2021). 31
- [428] V. Aribandi, Y. Tay, T. Schuster, J. Rao, H. S. Zheng, S. V. Mehta, H. Zhuang, V. Q. Tran, D. Bahri, J. Ni, 외, Ext5: 극한 다중 작업 확장을 위한 전이 학습, arXiv 사전 인쇄 arXiv:2111.10952 (2021). 31
- [429] A. Williams, N. Nangia, S. Bowman, 문장 이해를 위한 광범위한 사전 코퍼스, 2018년 북미 컴퓨터 언어학회: 인적 언어 기술 회의 논문집, 제1권(긴 논문), 컴퓨터 언어학회, 루이지애나주 뉴올리언스, 2018, pp. 1112–1122. doi:10.18653/v1/N18-1101. URL https://aclanthology.org/N18-1101
- [430] Y. Zhang, J. Baldridge, L. He, PAWS: Paraphrase adversaries from word scrambling, in: Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), Association for Computational Linguistics, Minneapolis, Minnesota, 2019, pp. 1298–1308. doi:10.18653/v1/N19-1131. URL https://aclanthology.org/N19-1131 32
- [431] C. Qin, A. Zhang, Z. Zhang, J. Chen, M. Yasunaga, D. Yang, "Chat-GPT가 일반 목적의 자연어 처리 작업 해결자인가?", 2023년 자연어 처리에 관한 경험적 방법 회의에서, 2023. URL https://openreview.net/forum?id=u03xn1COsO 32
- [432] M. U. Hadi, R. Qureshi, A. Shah, M. Irfan, A. Zafar, M. B. Shaikh, N. Akhtar, J. Wu, S. Mirjalili 외, 대형 언어 모델: 그 응용, 도전, 제한 및 미래 전망에 대한 종합 조사, TechRxiv (2023). 32
- [433] X. L. Dong, S. Moon, Y. E. Xu, K. Malik, Z. Yu, 차세대 지능형 어시스턴트를 위한 llm 기반 활용, in: 2023년 제29회 ACM SIGKDD 지식 발견 및 데이터 마이닝 컨퍼런스 논문집, pp. 5792–5793. 32
- [434] K. Pandya, M. Holia, 고객 서비스를 자동화하기 위한 langchain: 조직을 위한 맞춤형 오픈소스 GPT 챗봇 구축, arXiv preprint arXiv:2310.05421 (2023). 32
- [435] J. Li, B. Hui, G. Qu, B. Li, J. Yang, B. Li, B. Wang, B. Qin, R. Cao, R. Geng, et al., llm은 이미 데이터베이스 인터페이스로 사용될 수 있는가?

- 대규모 데이터베이스 기반 텍스트-투-큐엘을 위한 대형 벤치마크, arXiv 사전 인쇄물 arXiv:2305.03111 (2023). 32
- A. Rao, J. Kim, M. Kamineneni, M. Pang, W. Lie, M. D. Succi, chatgpt를 방사선학적 의사결정의 보조 도구로 평가하기, medRxiv (2023) 2023-02. 32
- [437] M. Benary, X. D. Wang, M. Schmidt, D. Soll, G. Hilfenhaus, M. Nassir, C. Sigler, M. Knödler, U. Keller, D. Beule 외, "개인화된 종양학에서 결정 지원을 위한 대형 언어 모델 활용," JAMA Network Open 6 (11) (2023) e2343689-e2343689. 32
- [438] C. M. Chiesa-Estomba, J. R. Lechien, L. A. Vaira, A. Brunet, G. Cammaroto, M. Mayo-Yanez, A. Sanchez-Barrueco, C. Saga-Gutierrez, chat-gpt의 가능성을 탐구하여 sialendoscopy 임상 의사 결정 및 환자 정보 지원을 위한 도구로 활용하기, European Archives of Oto-Rhino-Laryngology (2023) 1-6. 32
- [439] S. Montagna, S. Ferretti, L. C. Klopfenstein, A. Florio, M. F. Pengo, 만성 질환 자기 관리에서 LLM 기반 챗봇 시스템의 데이터 분석, 2023년 사회적 가치 창출을 위한 정보 기술에 관한 2023 ACM 회의록, 2023, pp. 205-212. 32
- [440] D. Bill, T. Eriksson, 인간 피드백을 통한 강화 학습을 사용하여 치료 챗봇 애플리케이션을 위한 llm 조정 (2023). 32
- [441] M. Abbasian, I. Azimi, A. M. Rahmani, R. Jain, 대화형 건강 에이전트: 개인화된 LLM 기반 에이전트 프레임워크, arXiv 사전 인쇄본 arXiv:2310.02374 (2023). 32
- K. V. Lemley, ChatGPT가 의학 문헌을 이해하는 데 도움이 되는가?, 미국 신장학회 저널 (2023) 10-1681. 32
- [443] S. Pal, M. Bhattacharya, S.-S. Lee, C. Chakraborty, 생물 의공학 및 연구를 위한 도메인 특화 차세대 대형 언어 모델(llm) 또는 chatgpt가 필요하다, 생물 의공학 연보 (2023) 1-4. 32
- [444] Y. Du, S. Zhao, Y. Chen, R. Bai, J. Liu, H. Wu, H. Wang, B. Qin, The calla dataset: Probing llms' interactive knowledge acquisition from chinese medical literature, arXiv preprint arXiv:2309.04198 (2023). 32
- A. Abd-Alrazaq, R. AlSaad, D. Alhuwail, A. Ahmed, P. M. Healy, S. Latifi, S. Aziz, R. Damseh, S. A. Alrazak, J. Sheikh 외, "의료 교육에서의 대규모 언어 모델: 기회, 도전 과제 및 미래 방향," JMIR Medical Education 9 (1) (2023) e48291. 32
- A. B. Mbakwe, I. Lourentzou, L. A. Celi, O. J. Mechanic, A. Dagan, Chatgpt가 usmle를 통과함으로써 의학교육의 결함을 조명하다 (2023). 32
- [447] S. Ahn, 대형 언어 모델이 의학교육에 미칠 임박한 영향, Korean Journal of Medical Education 35 (1) (2023) 103. 32
- [448] E. Waisberg, J. Ong, M. Masalkhi, A. G. Lee, 대형 언어 모델(llm) 기반 신경안과 의학 교육을 위한 챗봇, Eye (2023) 1-3. 32
- G. Deiana, M. Dettori, A. Arghittu, A. Azara, G. Gabutti, P. Castiglia, 인공지능과 공공 건강: 백신 신화와 오해에 대한 chatgpt 응답 평가, Vaccines 11 (7) (2023) 1217. 32
- [450] L. De Angelis, F. Baglivo, G. Arzilli, G. P. Privitera, P. Ferragina, A. E. Tozzi, C. Rizzo, Chatgpt와 대형 언어 모델의 부상: 공공 건강에서의 새로운 AI 기반 정보 전염병 위험, Frontiers in Public Health 11 (2023) 1166120. 32
- [451] N. L. Rane, A. Tawde, S. P. Choudhary, J. Rane, ChatGPT 및 기타 대형 언어 모델(LLM)의 기여와 성능: 과학 및 연구 발전을 위한 양날의 검, International Research Journal of Modernization in Engineering Technology and Science 5 (10) (2023) 875-899. 32
- [452] W. Dai, J. Lin, H. Jin, T. Li, Y.-S. Tsai, D. Gaṛevi ´c, G. Chen, "대규모 언어 모델이 학생들에게 피드백을 제공할 수 있을까? chatgpt에 대한 사례 연구", 2023 IEEE 국제 고급 학습 기술 회의 (ICALT), IEEE, 2023, pp. 323-325. 32
- [453] E. Kasneci, K. Seřler, S. Kűchemann, M. Bannert, D. Dementieva, F. Fischer, U. Gasser, G. Groh, S. Gűnnemann, E. Hűllermeier 외, Chatgpt for good? 대규모 언어 모델이 교육에 미치는 기회와 도전, Learning and individual differences 103 (2023) 102274. 32
- [454] N. Rane, Chat-GPT와 유사한 대규모 언어 모델을 통한 교육에서의 교수 및 학습 질 향상: 도전 과제, 미래 전망 및 윤리적 고려사항, 교육의 미래 전망 및 윤리적 고려사항 (2023년 9월 15일) (2023). 32
- [455] J. C. Young, M. Shishido, OpenAI의 ChatGPT의 잠재력을 조사하여 외국어로서의 영어 학습을 위한 챗봇의 대화를 생성하다, 국제 고급 컴퓨터 과학 및 응용 프로그램 저널 14 (6) (2023). 32
- [456] J. Irons, C. Mason, P. Cooper, S. Sidra, A. Reeson, C. Paris, 챗GPT가 미래 과학 작업에 미치는 영향 탐색, SocArXiv (2023). 32
- [457] P. G. Schmidt, A. J. Meir, 문학 검색 및 학술 작성을 위한 생성적 AI 활용: 과학 담론의 무결성이 위험에 처했는가?, arXiv 사전 인쇄 arXiv:2311.06981 (2023). 32
- [458] Y. Zheng, H. Y. Koh, J. Ju, A. T. Nguyen, L. T. May, G. I. Webb, S. Pan, 과학적 합성, 추론 및 설명을 위한 대규모 언어 모델, arXiv 사전 인쇄 arXiv:2310.07984 (2023). 33
- [459] B. Aczel, E.-J. Wagenmakers, 과학적 글쓰기에서 chatgpt 사용을 위한 투명성 안내, PsyArXiv (2023). 33
- [460] S. Altműe, A. Sola-Leyva, A. Salumets, 인공지능과 과학적 글쓰기: 친구인가 적인가?, Reproductive BioMedicine Online (2023). 33
- [461] S. Imani, L. Du, H. Shrivastava, Mathprompter: 대형 언어 모델을 이용한 수학적 추론, arXiv 사전 인쇄 arXiv:2303.05398 (2023). 33
- [462] Z. Yuan, H. Yuan, C. Li, G. Dong, C. Tan, C. Zhou, 대형 언어 모델을 이용한 수학적 추론 학습에 대한 스케일링 관계, arXiv 사전 인쇄 arXiv:2308.01825 (2023). 33
- K. Yang, A. M. Swope, A. Gu, R. Chalamala, P. Song, S. Yu, S. Godil, R. Prenger, A. Anandkumar, Leandojo: 검색 증강 언어 모델을 이용한 정리 증명, arXiv 사전 인쇄물 arXiv:2306.15626 (2023). 33
- [464] K. M. Collins, A. Q. Jiang, S. Frieder, L. Wong, M. Zilka, U. Bhatt, T. Lukasiewicz, Y. Wu, J. B. Tenenbaum, W. Hart 외, 상호작용을 통한 수학을 위한 언어 모델 평가, arXiv 사전 인쇄 arXiv:2306.01694 (2023). 33
- [465] Y. Liu, T. Han, S. Ma, J. Zhang, Y. Yang, J. Tian, H. He, A. Li, M. He, Z. Liu 외, ChatGPT 관련 연구 요약 및 대형 언어 모델의 미래에 대한 전망, Meta-Radiology (2023) 100017. 33
- [466] J. Drůpal, H. Westermann, J. Savelka, 대규모 언어 모델을 사용하여 경험적 법학 연구에서 주제 분석 지원하기, arXiv 사전 인쇄 arXiv:2310.18729 (2023). 33
- [467] J. Savelka, K. D. Ashley, M. A. Gray, H. Westermann, H. Xu, 증강 대형 언어 모델(gpt-4)을 활용한 법적 개념 설명, arXiv 사전 인쇄 arXiv:2306.09525 (2023). 33
- [468] N. Guha, J. Nyarko, D. E. Ho, C. Rű, A. Chilton, A. Narayana, A. Chohlas-Wood, A. Peters, B. Waldon, D. N. Rockmore 외, Legal-bench: 대규모 언어 모델에서 법적 추론을 측정하기 위해 공동으로 구축된 벤치마크, arXiv 사전 인쇄 arXiv:2308.11462 (2023). 33
- [469] J. Cui, Z. Li, Y. Yan, B. Chen, L. Yuan, Chatlaw: 통합된 외부 지식 기반이 있는 오픈 소스 법률 대형 언어 모델, arXiv 사전 인쇄 arXiv:2306.16092 (2023). 33
- H. Yang, X.-Y. Liu, C. D. Wang, Fingpt: 오픈소스 금융 대규모 언어 모델, arXiv 사전판 arXiv:2306.06031 (2023). 33
- [471] Y. Li, S. Wang, H. Ding, H. Chen, 금융 분야의 대형 언어 모델: 개관, in: 제4회 ACM 국제 AI 금융 회의록, 2023, pp. 374-382. 33
- A. Lykov, D. Tsetserukou, Llm-brain: Ai-driven fast generation of robot behaviour tree based on large language model, arXiv preprint arXiv:2305.19352 (2023). 33
- [473] E. Billing, J. Rosűn, M. Lamb, 인간-로봇 상호작용을 위한 언어 모델, ACM/IEEE 국제 인간-로봇 상호작용 회의, 2023년 3월 13-16일, 스톡홀름, 스웨덴, ACM 디지털 라이브러리, 2023, 905-906쪽. 33
- [474] Y. Ye, H. You, J. Du, Improved trust in human-robot collaboration with chatgpt, IEEE Access (2023). 33
- [475] Y. Ding, X. Zhang, C. Paxton, S. Zhang, 대규모 언어 모델의 상식 지식을 활용한 작업 및 동작 계획, RSS 2023 작업장에서의 작업 및 동작 계획 학습에서, 2023. 33
- [476] J. Wu, R. Antonova, A. Kan, M. Lepert, A. Zeng, S. Song, J. Bohg, S. Rusinkiewicz, T. Funkhouser, Tidybot: 개인화된 로봇 지원을 위한 대형 언어 모델, arXiv 사전 인쇄 arXiv:2305.05658 (2023). 33
- [477] E. Strubell, A. Ganesh, A. McCallum, 에너지 및 정책 고려사항 딥 러닝을 위한 NLP, arXiv 사전 인쇄 arXiv:1906.02243 (2019). 34
- [478] E. M. Bender, T. Gebru, A. McMillan-Major, S. Shmitchell, On the dan-

확률론적 앵무새의 위험: 언어 모델이 너무 클 수 있는가?, 2021 ACM 공정성, 책임 및 투명성 회의 자료집, 2021, pp. 610–623. 34

- C. Zhang, S. Bengio, M. Hardt, B. Recht, O. Vinyals, 심층 학습에 대한 이해는 여전히 일반화에 대한 재고를 필요로 한다, *Communications of the ACM* 64 (3) (2021) 107–115. 34
- [480] M. Tänzler, S. Ruder, M. Rei, 사전 훈련된 언어 모델에서의 기억과 일반화, *arXiv 사전 인쇄* arXiv:2105.00828 (2021). 34
- [481] S. M. West, M. Whittaker, K. Crawford, 차별화 시스템, *AI 이제* (2019) 1–33. 34
- [482] K. Valmeekam, A. Olmo, S. Sreedharan, S. Kambhampati, 대형 언어 모델은 여전히 계획을 세울 수 없다 (변화에 대한 계획 및 추론에 대한 llms 벤치마크), *arXiv 사전 인쇄* arXiv:2206.10498 (2022). 34
- [483] Y. Zhang, Y. Li, L. Cui, D. Cai, L. Liu, T. Fu, X. Huang, E. Zhao, Y. Zhang, Y. Chen 등, 인공지능 바다의 사이렌의 노래: 대형 언어 모델에서의 환각 조사, *arXiv 사전 인쇄* arXiv:2309.01219 (2023). 34
- [484] A. Webson, E. Pavlick, Do prompt-based models really understand the meaning of their prompts?, *arXiv preprint* arXiv:2109.01247 (2021). 34
- [485] O. Shaikh, H. Zhang, W. Held, M. Bernstein, D. Yang, 다시 생각해 보면, 단계별로 생각하지 말자! 제로샷 추론에서의 편향과 독성, *arXiv preprint* arXiv:2212.08061 (2022). 34
- B. C. Das, M. H. Amini, Y. Wu, 대규모 언어 모델의 보안 및 개인정보 보호 도전과제: 설문조사, *arXiv 사전 인쇄* arXiv:2402.00888 (2024). 34
- [487] X. Liu, H. Cheng, P. He, W. Chen, Y. Wang, H. Poon, J. Gao, 대적 훈련 대형 신경 언어 모델을 위한, *ArXiv* (2020년 4월). URL <https://www.microsoft.com/en-us/research/publication/adversarial-training-for-large-neural-language-models/> 34
- [488] E. Shayegani, M. A. A. Mamun, Y. Fu, P. Zaree, Y. Dong, N. Abu-Ghazaleh, 적대적 공격에 의해 드러난 대규모 언어 모델의 취약성 조사 (2023). *arXiv:2310.10844*. 34
- [489] X. Xu, K. Kong, N. Liu, L. Cui, D. Wang, J. Zhang, M. Kankanhalli, An llm can fool itself: A prompt-based adversarial attack (2023). *arXiv: 2310.13345*. 34
- [490] H. Zhao, H. Chen, F. Yang, N. Liu, H. Deng, H. Cai, S. Wang, D. Yin, M. Du, 대형 언어 모델의 설명 가능성: 조사 (2023). *arXiv:2309.01029*. 35
- [491] S. Huang, S. Mamidanna, S. Jangam, Y. Zhou, L. H. Gilpin, 대형 언어 모델은 스스로를 설명할 수 있는가? LLM이 생성한 자기 설명에 대한 연구 (2023). *arXiv:2310.11207*. 35
- [492] H. Brown, K. Lee, F. Mireshghallah, R. Shokri, F. Tramèr, 언어 모델이 프라이버시를 유지한다는 것은 무엇을 의미하는가?, 2022년 ACM 공정성, 책임성 및 투명성 회의의 진행 자료, 2022, 2280–2292쪽. 35
- [493] R. Plant, V. Giuffrida, D. Gkatzia, 당신은 당신이 쓰는 것입니다: 대형 언어 모델 시대의 프라이버시 보호, *arXiv 사전 인쇄* arXiv:2204.09391 (2022). 35
- [494] W. Niu, Z. Kong, G. Yuan, W. Jiang, J. Guan, C. Ding, P. Zhao, S. Liu, B. Ren, Y. Wang, 모바일에서 대규모 언어 모델의 실시간 실행 (2020). *arXiv:2009.06823*. 35
- C. Guo, J. Tang, W. Hu, J. Leng, C. Zhang, F. Yang, Y. Liu, M. Guo, Y. Zhu, Olive: 하드웨어 친화적인 이상치-피해자 쌍 양자화를 통한 대형 언어 모델의 가속, 2023년 제50회 국제 컴퓨터 아키텍처 심포지엄 회의록, pp. 1–15. 35
- [496] B. Meskó, E. J. Topol, 의료 분야에서 대형 언어 모델(또는 생성형 AI)에 대한 규제 감독의 필요성, *npj Digital Medicine* 6 (1) (2023) 120. 35
- [497] J. Zhang, X. Ji, Z. Zhao, X. Hei, K.-K. R. Choo, 대규모 언어 모델에 대한 윤리적 고려사항 및 정책적 함의: 책임 있는 개발과 배치를 위한 안내, *arXiv 사전 인쇄* arXiv:2308.02678 (2023). 35
- [498] J. Mökander, J. Schuett, H. R. Kirk, L. Floridi, 대규모 언어 모델 감사: 세 가지 층으로 이루어진 접근법, AI와 윤리 (2023) 1–31. 35